



VNIVERSITAT
DE VALÈNCIA [Ω] Escola Tècnica Superior
d'Enginyeria ETSE-UV

TRABAJO FIN DE GRADO

MODELIZACIÓN DE PATRONES NEURONALES A PARTIR SEÑALES EEG

AUTOR: JOSÉ JAVIER GUTIÉRREZ GIL

TUTORA: YOLANDA VIVES GILABERT

Declaración de autoría:

Yo, José Javier Gutiérrez Gil, declaro la autoría del Trabajo Fin de Grado titulado “Modelización de patrones neuronales a partir señales EEG” y que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual. El material no original que figura en este trabajo ha sido atribuido a sus legítimos autores.

Valencia, 20 de julio de 2024

Fdo: José Javier Gutiérrez Gil

Resumen:

En la última década, los avances en neurociencia, apoyados por desarrollos tecnológicos y hallazgos innovadores, han mejorado la comprensión de los mecanismos cerebrales. El presente estudio implementa un framework con una API intuitiva para estudios exhaustivos de señales EEG, abarcando desde la adquisición de datos hasta la evaluación de patrones de dinámica temporal. Se empleará el modelo Reservoir Computing (RC-ESN) para identificar y caracterizar patrones distintivos asociados con el envejecimiento neuronal. Se utilizarán tanto datos sintéticos que imitan características de EEG realistas, como datos reales obtenidos de sujetos en reposo pertenecientes a diferentes grupos etarios: jóvenes adultos y personas mayores.

El framework proporcionará herramientas avanzadas para el procesamiento y análisis de datos EEG, facilitando la investigación en neurociencia y sus aplicaciones clínicas. Diseñado para ser modular y extensible, permitirá a los usuarios personalizar y expandir sus funcionalidades según las necesidades específicas de sus estudios, asegurando que el sistema no solo sea útil en el contexto de la investigación actual, sino que también pueda adaptarse a futuras investigaciones y descubrimientos en el campo de la neurociencia.

Abstract:

In the past decade, advances in neuroscience, supported by technological developments and innovative findings, have improved our understanding of brain mechanisms. This study implements a framework with an intuitive API for comprehensive EEG signal studies, covering everything from data acquisition to the evaluation of temporal dynamics patterns. The Reservoir Computing model (RC-ESN) will be employed to identify and characterize distinctive patterns associated with neuronal aging. Both synthetic data that mimic realistic EEG characteristics and real data obtained from resting subjects in different age groups—young adults and older individuals—will be used.

The framework will provide advanced tools for EEG data processing and analysis, facilitating research in neuroscience and its clinical applications. Designed to be modular and extensible, it will allow users to customize and expand its functionalities according to the specific needs of their studies, ensuring that the system is not only useful in the context of current research but can also adapt to future investigations and discoveries in the field of neuroscience.

Resum:

En l'última dècada, els avanços en neurociència, recolzats per desenvolupaments tecnològics i descobriments innovadors, han millorat la comprensió dels mecanismes cerebrals. El present estudi implementa un framework amb una API intuïtiva per a estudis exhaustius de senyals EEG, abastant des de l'àdquisició de dades fins a l'avaluació de patrons de dinàmica temporal. S'emprarà el model Reservoir Computing (RC-ESN) per identificar i caracteritzar patrons distintius associats amb l'envelleixement neuronal. S'utilitzaran tant dades sintètiques que imiten característiques de EEG realistes, com dades reals obtingudes de subjectes en repòs pertanyents a diferents grups d'edat: joves adults i persones majors.

El framework proporcionarà eines avançades per al processament i l'anàlisi de dades EEG, facilitant la investigació en neurociència i les seues aplicacions clíniques. Dissenyat per ser modular i extensible, permetrà als usuaris personalitzar i expandir les seues funcionalitats segons les necessitats específiques dels seus estudis, assegurant que el sistema no només siga útil en el context de la investigació actual, sinó que també puga adaptar-se a futures investigacions i descobriments en el camp de la neurociència.

Agradecimientos:

En primer lugar, quiero expresar mi profundo agradecimiento a mi hijo, cuyo amor, empuje y constante apoyo han sido mi fuente de inspiración y motivación a lo largo de este viaje.

En segundo lugar, deseo agradecer al departamento de electrónica de la UV por brindarme las herramientas y el entorno propicio para desarrollar mis habilidades y conocimientos en este fascinante campo.

Un agradecimiento especial a Yolanda, mi tutora, cuya orientación experta y apoyo incondicional han sido fundamentales en mi formación académica y profesional.

A Wael, quien me otorgó la invaluable oportunidad de adentrarme en este mundo de la electrónica y la investigación, extendido mi más sincero agradecimiento por su confianza y guía.

Y por último, pero no menos importante, a todos los demás profesores que me han brindado su apoyo, conocimientos y aliento a lo largo de este camino. Su influencia ha sido incalculable en mi desarrollo académico y personal.

Gracias a cada uno de ustedes por ser parte de mi trayectoria y por creer en mí. Sin su ayuda, no habría llegado tan lejos.

Índice general

1. Introducción	13
1.1. Introducción	13
1.2. Objetivos	16
2. Estado del arte	19
2.1. Análisis de aplicaciones similares	19
2.2. Tecnologías	23
3. Marco teórico	27
3.1. Circuitos corticales y áreas funcionales	27
3.1.1. Formación y características de las señales EEG	28
3.1.2. Regiones y circuitos corticales	29
3.2. Técnicas de procesamiento de señales EEG	30
3.2.1. Preprocesamiento de señales EEG	30
3.2.2. Eliminación de artefactos	30
3.3. Aprendizaje automático en el procesamiento de señales neuronales	32
3.3.1. Aprendizaje no supervisado	32
3.3.2. Aprendizaje supervisado	33
3.4. Reservoir computing (RC)	34
3.4.1. Arquitectura del RC	35
3.4.2. Readout	38
3.4.3. Entrenamiento del RC	39
3.4.4. Hiperparámetros del RC	39
3.4.5. Estudio interno de hiperparámetros	41
4. Materiales y métodos	45
4.1. Materiales	45
4.1.1. Datos sintéticos	45
4.1.2. Conjunto de datos jóvenes adultos y mayores	46
4.2. Métodos	46
4.2.1. Desarrollo de la API de RC en python	46

4.2.2. Preprocesamiento de los datos reales	48
4.2.3. Procesamiento de datos reales con el framework del RC	49
4.3. Evaluación de resultados	51
4.3.1. Matriz de similitud	51
4.3.2. Gráficos de recurrencia	51
4.3.3. El Potencial de memoria	53
4.3.4. Búsqueda automática de hiperparámetros	53
5. Resultados	55
5.1. Datos sintéticos	55
5.1.1. Reconstrucción y predicción	55
5.1.2. Resultados del análisis no supervisado	57
5.1.3. Resultados del análisis supervisado	63
5.2. Datos reales: sujetos jóvenes adultos vs mayores	64
5.2.1. Análisis no supervisado	65
5.2.2. Análisis supervisado	71
5.2.3. Deep reservoir computing	74
6. Conclusiones	77
6.1. Conclusiones	77
6.2. Trabajo futuro	78
Bibliografía	78

Índice de figuras

2.1.	Tendencia temporal: EEG processing. (WoS)	20
2.2.	Dominio de Estudio. (WoS)	21
2.3.	J. Neural Eng. 16 (2019) 051001 (37pp): Deep learning-based electroencephalography analysis: a systematic review	23
2.4.	Número de Investigaciones Uso RC para procesamiento de señales EEG, por Año. WoS	26
3.1.	Áreas de regiones corticales	28
3.2.	Eliminación artefactos	31
3.3.	Esquema Base Reservoir Computing. Fuente [1]	34
3.4.	Arquitectura Reservoir Computing. Fuente [2]	35
3.5.	Entrnamiento RC-ESN. Fuente [3]	36
4.1.	Diagrama principal del proceso de desarrollo de RC ESN para señales EEG . . .	47
4.2.	Estudio Señales EEG jóvenes adultos vs Mayores (construcción propia y Fuente[4])	50
5.1.	Reconstrucción señales del EEG del sujeto 0	56
5.2.	Matriz Coherencia para la reconstrucción de los datos sintéticos	57
5.3.	Matriz Similitud representación interna del RC_ESN([0-19]:Sujetos jóvenes adultos; [20-40] sujetos mayores).	58
5.4.	Denograma del Clúster jerárquico para los datos EEG sintéticos([0-19]:Sujetos jóvenes adultos; [20-40] sujetos mayores).	59
5.5.	Matriz Confusión Resultados de clúster jerárquico sobre datos sintéticos(0:Grupo jóvenes adultos; 1: Grupo Mayores).	60
5.6.	Representación Kmeans de los datos sintéticos	60
5.7.	Resultado T-SNE de datos sintéticos para las dos componentes	61
5.8.	Gráficos de recurrencia para los datos sintéticos.Fila : sujetos jóvenes adultos, fila inferior: mayores.	62
5.9.	Potencial de memoria jóvenes vs mayores	63
5.10.	Matriz de similitud de datos reales preprocesados y con eliminación de artefactos ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).	66
5.11.	Matriz confusión datos reales con eliminación artefactos(0:Grupo jóvenes adultos; 1: Grupo Mayores).	66

5.12. Métricas agrupación datos reales con eliminación artefactos mediante Kmeans (0:Grupo jóvenes adultos; 1: Grupo Mayores)	67
5.13. Matriz similitud canales hemisferio izquierdo([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).	68
5.14. Matriz confusión agrupamiento mediante Kmeans para los estados internos de los canales del hemisferio izquierdo(0:Grupo jóvenes adultos; 1: Grupo Mayores).	68
5.15. Métricas del agrupamiento de los estados RC-ESN de los canales del hemisferio izquierdo con Kmeans(0:Grupo jóvenes adultos; 1: Grupo Mayores).	69
5.16. Gráficas recurrencia entre jóvenes vs mayores ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).	70
5.17. Potencial de memoria de datos jóvenes adultos vs mayores con T-test sobre la H0: Existe una diferencia estadísticamente significativa de potencial de memoria entre los dos grupos de sujetos.	70
5.18. Matriz confusión proceso de clasificación de los sujetos jóvenes adultos vs mayores mediante un modelo ridge para la capa readout del modelo RC-ESN(0:Grupo jóvenes adultos; 1: Grupo Mayores).	71
5.19. Curva roc de la evaluación del proceso de clasificación de los sujetos jóvenes adultos vs mayores mediante la capa readout ridge del modelo RC-ESN	72
5.20. Matriz confusión proceso de clasificación mediante capa de redaout 'mlp'para las representaciones internas del RC-ESN de los sujetos de estudio(0:Grupo jóvenes adultos; 1: Grupo Mayores).	73
5.21. Curva ROC del proceso de clasificación de los patrones de dinámica temporal asociadas a las señales EEG de los sujetos de estudio mediante un modelo RC-ESN con capa readout mlp	74
5.22. Matriz Similitud DeepMyRC sin reducción de dimensionalidad ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).	74

Índice de cuadros

2.1. Áreas de Conocimiento. (WoS)	20
2.2. Objetivo de estudio. (WoS)	21
2.3. Áreas de Investigación en los Últimos Tres Años. (WoS)	22
2.4. Dominios de Investigación. (WoS)	22
2.5. Examples of subjects in RC applications. Gouhei Tanaka [5]	25
2.6. Applications and related benchmark tasks of RC. Gouhei Tanaka [5]	26
3.1. Clasificación de las ondas cerebrales según su frecuencia y estado asociado.	29
5.1. Informe de evaluación del modelo RC-ESN con readout MLP para la clasificación de los sujetos en estudio entre jóvenes y mayores(0:Grupo jóvenes adultos; 1: Grupo Mayores).	72
5.2. Informe de resultados del modelo RC-ESN con readout 'mlp'para el proceso de clasificación de los sujetos en estudio entre jóvenes y mayores(0:Grupo jóvenes adultos; 1: Grupo Mayores).	73

Capítulo 1

Introducción

1.1. Introducción

La neurociencia es una disciplina científica en constante evolución, se adentra en el estudio del sistema nervioso desde diversos niveles, abordando su estructura, funciones y desarrollo. Este campo interdisciplinario ha experimentado un extenso proceso evolutivo a lo largo de décadas de investigación, desde los primeros intentos de explorar la biología molecular y celular hasta la sofisticada comprensión de la psicología y la cognición [6]. La integración de múltiples disciplinas, como la biología, la psicología, la informática y la física, ha enriquecido su enfoque, permitiendo una comprensión más profunda del complejo funcionamiento del cerebro humano¹ [7, 8].

La exploración del cerebro humano en busca de comprender su complejidad ha sido una fascinante tarea a lo largo de la historia. Desde los antiguos filósofos hasta los investigadores modernos, la intriga por comprender este órgano complejo ha impulsado avances significativos en la neurociencia. En 1888, Santiago Ramón y Cajal, considerado pionero en el campo, realizó descubrimientos fundamentales al describir las células nerviosas y sus interconexiones [9, 10]. Desde entonces, la colaboración interdisciplinaria y los avances tecnológicos han llevado a la neurociencia a nuevos horizontes. Los métodos de investigación han evolucionado desde la observación microscópica hasta las técnicas de neuroimagen de vanguardia, como la resonancia magnética funcional (fMRI) y la tomografía por emisión de positrones (PET), que permiten visualizar la actividad cerebral en tiempo real con una precisión sin precedentes² [11, 12]. La exploración y comprensión de estas señales revisten una importancia multidimensional. Orientada en revelar los enigmas de la mente humana, proporcionando una comprensión más profunda sobre la formación del pensamiento, el procesamiento emocional y la generación de comportamientos [13]. Este conocimiento no solo enriquece nuestra percepción fundamental del cerebro, sino que también tiene repercusiones directas en la promoción de la salud mental y el abordaje de trastornos neurológicos así como los mecanismos de interacción social[14].

Afrontar el conocimiento del cerebro es una tarea monumental debido a su vasta red de conexiones y la interacción entre sus millones de neuronas y sinapsis [15]. Aunque se han logrado avances significativos, aún queda mucho por descubrir. Los investigadores están enfocados en entender cómo la estructura física del cerebro se relaciona con sus funciones superiores [12, 16], así como en los mecanismos subyacentes de la memoria, el lenguaje y el comportamiento [10]. Los avances en tecnología, como la optogenética y la estimulación cerebral profunda, han permitido a los científicos manipular circuitos neuronales específicos y comprender mejor

¹Fuente: <https://www.senc.es/introduccion-historica-a-la-neurociencia/>

²Fuente: <https://www.medicalnewstoday.com/articles/248680#major-branches>

su función en la cognición y el comportamiento [17, 18]. El estudio de la descomposición y arquitectura informativa del cerebro se inscribe en esta línea de investigación, explorando cómo la información se desglosa y organiza en el complejo entramado neuronal, proporcionando una comprensión más profunda de los procesos cognitivos y conductuales fundamentales [19].

Si bien el estudio detallado de las neuronas individuales ha sido fundamental, cada vez se reconoce más que la verdadera unidad funcional del cerebro reside en conjuntos de neuronas y sus interacciones en diversos circuitos. Las investigaciones recientes han demostrado que la sinergia y la redundancia entre estas redes neuronales desempeñan un papel fundamental en la capacidad computacional del cerebro y en la generación de comportamientos complejos [20, 12, 21, 19]. Gracias a estos avances, se reconoce al cerebro como una intrincada red de regiones interconectadas, cuya actividad fluctuante y coordinada da lugar a una amplia gama de funciones cognitivas y conductuales. Este enfoque de red ha transformado la manera en que concebimos la actividad cerebral, pasando de considerar los nodos individuales como unidades independientes a comprender la importancia de las conexiones dinámicas entre ellos. Y en este sentido, el análisis de grafos ha proporcionado un marco conceptual poderoso para investigar la organización y la función cerebral [22]. Enriquecido nuestra comprensión de las redes funcionales cerebrales. Y revelando patrones de actividad sincronizada que subyacen a una variedad de procesos cognitivos y emocionales. [23] Dentro de la neurociencia, podemos encontrar diferentes paradigmas en los que engloban las múltiples teorías y modelos surgidos a lo largo de los estudios y avances tecnológicos. Entre estos paradigmas, los más relevantes son el paradigma mecanicista [24, 25], el bayesiano [26, 27, 28], el conexiónista [29] y los sistemas dinámicos [30]. Cada una de estos paradigmas ofrecen perspectivas distintas para simular los procesos cognitivos: el mecanicista considera el cerebro como una máquina [31, 32], el bayesiano se basa en la probabilidad [33, 34, 35] y el conexiónista se enfoca en los avances computacionales en machine learning y deep learning [36, 34, 37]. Estos paradigmas, junto con enfoques como el procesamiento paralelo [38] y los sistemas dinámicos [39, 40], contribuyen a una comprensión más completa de la cognición humana y su relación con la actividad neuronal. Además, permiten el desarrollo de tratamientos y estrategias de intervención que pueden mejorar significativamente nuestra comprensión y manejo de los trastornos neurológicos. Estos avances consolidan a la neurociencia cognitiva y sus diferentes vertientes como campos que proporcionan esperanza y oportunidades para el avance científico y médico. Sin embargo, aún hay un largo camino por recorrer para comprender completamente el funcionamiento del cerebro humano y abordar de manera efectiva los trastornos neurológicos.

El presente trabajo se focaliza en la interconexión de dos ramas específicas: la neurociencia computacional y la neurociencia cognitiva. Como hemos comentado anteriormente, la neurociencia cognitiva estudia los procesos mentales y cognitivos, como la atención, las emociones, la memoria, el lenguaje y la toma de decisiones, desde una perspectiva neural. Esta disciplina se basa en métodos de neuroimagen, procesamiento de señales fisiológicas y parapsicología para investigar cómo se representan y procesan la información en el cerebro [41, 42]. Por otro lado, la neurociencia computacional³, [11] es una subdisciplina que utiliza herramientas y técnicas computacionales para modelar y simular procesos neuronales y cognitivos, [16]. Su objetivo es comprender cómo funcionan los sistemas nerviosos y cómo pueden replicarse en forma de modelos computacionales. La neurociencia computacional se centra, por tanto, en el desarrollo de modelos y técnicas para analizar datos neuronales, incluyendo el procesamiento de señales neuronales como las obtenidas mediante EEG, reconstruyendo, de este modo, una simulación de la interconexión de las redes neuronales y circuitos corticales para comprender su funcionamiento [43, 44]. Estas técnicas permiten extraer información significativa de las señales neuronales, como patrones de actividad y relaciones funcionales entre regiones cerebrales, lo que es crucial

³Fuente: <https://towardsdatascience.com/a-brief-introduction-to-computational-neuroscience-part-1-42171791f613>

para entender cómo emergen los procesos mentales a partir de la actividad neuronal [45, 46].

Esta interconexión de disciplinas ha intensificado, en este último lustro, avances tecnológicos y metodológicos significativos. Desafiando nuestras concepciones sobre la mente y el cerebro, al fusionar la neurociencia, la psicología y la computación, permitiendo un enfoque más detallado del funcionamiento del cerebro humano. Lo que ha permitido abordar preguntas complejas sobre la mente y el cerebro, y promete continuar revelando nuevos conocimientos sobre la naturaleza humana.

En esta convergencia, los modelos conexionistas y los sistemas dinámicos aplicados a través de las redes neuronales recurrentes han desempeñado un papel fundamental en la evolución neurocientífica [47], permitiendo el desarrollo de modelos y técnicas para analizar datos neuronales y comprender su funcionamiento. En el ámbito de estas redes recurrentes, en los últimos años, ha emergido el Reservoir Computing (RC) como una técnica de aprendizaje automático especialmente prometedora para el procesamiento de señales neuronales [48]. Inspirado en la estructura y dinámica de los sistemas neuronales biológicos, el RC emplea una red recurrente de unidades simples, llamada "reservorio", para capturar y procesar información temporalmente dinámica. Esta técnica ha demostrado ser altamente eficaz en una variedad de tareas de procesamiento de señales, incluyendo la clasificación y predicción de series temporales, así como el análisis de datos neuronales.

El cómputo de reservorios (RC) ha emergido como una técnica innovadora en el campo del reconocimiento de patrones temporales/secuenciales en los últimos años. Su enfoque central radica en el aprovechamiento de redes neuronales recurrentes (RNN) como reservorios de información, generando respuestas dinámicas basadas en el historial de datos de entrada. La historia del Reservoir Computing se remonta a principios de los años 2000, cuando se propuso por primera vez como un enfoque novedoso para el procesamiento de señales dinámicas [48, 49]. Desde entonces, ha sido objeto de una investigación activa en campos como la ingeniería de sistemas, la inteligencia artificial y, más recientemente, la neurociencia computacional [50, 51]. Aunque las RNN han sido empleadas para este propósito desde la década de 1980, el enfoque de RC presenta notables distinciones respecto a los métodos tradicionales de entrenamiento de RNN.

Dentro del marco de RC, sobresalen dos modelos fundamentales: las redes de estados de eco (ESN) [52] y las máquinas de estado líquido (LSM) [53]. Estos modelos se desvían de las RNN convencionales en que los pesos de las conexiones recurrentes en el reservorio no son ajustados durante el entrenamiento, limitándose el ajuste únicamente a los pesos en la salida. Esta característica simplifica significativamente el proceso de entrenamiento y reduce la carga computacional. Los ESN, propuestos por Jaeger, emplean un reservorio basado en RNN compuesto por neuronas artificiales de tiempo discreto, mientras que las LSM, concebidas por Maass, buscan emular modelos de aprendizaje biológicamente relevantes utilizando redes neuronales de disparo (SNN) con conectividad recurrente. Sus ventajas incluyen su capacidad para manejar señales no lineales y su eficiencia computacional, aunque también presenta desafíos en términos de ajuste de parámetros y entrenamiento del modelo [54].

El desempeño de un sistema RC está intrínsecamente ligado al diseño del reservorio basado en RNN. En el caso de los ESN, es esencial que el reservorio posea la propiedad de estado de eco, garantizando así la eliminación gradual de cualquier información proveniente de las condiciones iniciales [52]. Por otro lado, las LSM se orientan hacia la emulación de las capacidades computacionales de los microcircuitos neurales cerebrales, enfocándose en modelar los mecanismos biológicos de procesamiento de información [53, 5].

Además de los modelos básicos de RC, se han propuesto numerosas variantes y mejoras destinadas a optimizar su rendimiento y aplicabilidad. Estas incluyen la implementación de

múltiples reservorios, la integración con otros métodos de extracción de características, el desarrollo de algoritmos de aprendizaje innovadores y la incorporación de diversos elementos de reservorio [55, 56, 57, 58, 59].

Un aspecto significativo en la evolución de RC es su implementación física utilizando sistemas y dispositivos físicos alternativos a las RNN convencionales. Esta tendencia ha generado un notable aumento en la investigación sobre RC físico, con la propuesta de diversos tipos de reservorios físicos basados en una variedad de sistemas y dispositivos, desde fluidos hasta circuitos electrónicos y sistemas ópticos. Estos sistemas físicos presentan un potencial considerable para desarrollar hardware de aprendizaje automático energéticamente eficiente y explorar la computación natural basada en sustratos innovadores como los sistemas neuromórficos [5].

A pesar de los avances significativos en el desarrollo y aplicación del Reservoir Computing, todavía existen necesidades abiertas y desafíos por abordar en su aplicación a la neurociencia. Estos incluyen la mejora de la interpretabilidad de los modelos RC, la adaptación a la naturaleza no estacionaria de las señales neuronales y la integración con otras técnicas de análisis de datos neuronales. El estudio del RC en el procesamiento de señales neuronales EEG representa una vía prometedora para abordar estas necesidades y abrir nuevas perspectivas para la comprensión del cerebro humano.

1.2. Objetivos

El proyecto desarrollará un Framework de Reservoir Computing para procesar señales EEG, enfocado en entender el envejecimiento neuronal y las funciones cognitivas. Integrará técnicas avanzadas en un sistema modular con un API para facilitar la adquisición, preprocesamiento, análisis y evaluación de datos EEG. Se investigará cómo las dinámicas temporales en datos sintéticos y reales pueden ofrecer perspectivas sobre el envejecimiento neuronal y la salud cognitiva a lo largo del tiempo, evaluando su utilidad como marcadores predictivos.

El proyecto se centra en alcanzar los siguientes objetivos específicos:

Objetivo A. Desarrollar un Framework de Reservoir Computing:

1. Crear un framework modular y adaptable que integre técnicas avanzadas de reservoir computing para el procesamiento de señales EEG.
2. Implementar un API que facilite la adquisición, preprocesamiento, análisis y evaluación de datos EEG, optimizado para la identificación de patrones complejos.

Objetivo B. Analizar Dinámicas Temporales en Señales EEG:

1. Utilizar el framework para discernir dinámicas temporales características en datos sintéticos y reales de EEG de sujetos jóvenes, adultos y mayores.
2. Investigar cómo estas dinámicas pueden relacionarse con el envejecimiento neuronal y las funciones cognitivas a lo largo del tiempo.

Objetivo C. Aplicar el Framework en el Estudio del Envejecimiento Neuronal:

1. Emplear el framework para identificar y comparar patrones distintivos entre grupos demográficos (jóvenes adultos y mayores) en reposo.
2. Evaluar la viabilidad de utilizar estos patrones como marcadores predictivos del envejecimiento neuronal y la salud cognitiva.

Impacto esperado:

El desarrollo y aplicación de este framework no solo contribuirá significativamente al campo de la neurociencia computacional, sino que también proporcionará herramientas avanzadas para investigar y comprender mejor los mecanismos subyacentes al envejecimiento neuronal. Al identificar patrones significativos en las señales EEG, se podrán establecer nuevas fronteras en la detección temprana de alteraciones cognitivas y el diseño de intervenciones personalizadas para la salud cerebral.

Capítulo 2

Estado del arte

2.1. Análisis de aplicaciones similares

La convergencia entre la neurociencia computacional, la neurociencia cognitiva y la ingeniería de sistemas ha impulsado avances significativos en el procesamiento de señales EEG (electroencefalografía). Estas disciplinas han explorado técnicas como el Reservoir Computing (RC), redes neuronales profundas (DeepNN) y aprendizaje automático (ML) para abordar objetivos tanto cognitivos como clínicos.

Esta colaboración interdisciplinaria no solo ha mejorado la comprensión de la actividad cerebral, sino que también ha catalizado el desarrollo de tecnologías innovadoras. Además, ha promovido un intercambio bidireccional de conocimientos, donde los avances tecnológicos informan la neurociencia y viceversa, inspirando nuevas aplicaciones y enfoques en ingeniería y computación.

Para contextualizar aún más, realizaremos un breve estudio bibliométrico sobre la neurociencia y el procesamiento de señales EEG. En las últimas décadas, este campo ha experimentado un notable crecimiento, evidenciado por el incremento en publicaciones en revistas especializadas y conferencias científicas. El análisis bibliométrico muestra un creciente interés en el uso del EEG para investigar funciones cognitivas y cerebrales humanas, con un enfoque particular en la detección de emociones, la interpretación de la actividad cerebral, y la plasticidad de redes neuronales y circuitos corticales. Estas investigaciones han sido impulsadas por avances en técnicas de procesamiento de señales, redes neuronales profundas y aprendizaje automático, facilitando una exploración más profunda de la información contenida en las señales EEG.

Este estudio bibliométrico se centra en analizar la evolución temporal y la cantidad de investigaciones en el procesamiento de señales EEG, clasificándolas por áreas de conocimiento y enfoques, así como identificando las principales regiones geográficas de producción científica. Para llevar a cabo este pequeño estudio, utilizaremos las bases de datos de **Web of Science**. Con los términos de búsqueda ".EEG process" ".EEG cognitive neuroscience", obtenemos **65,206 resultados desde 2000 hasta 2024** (búsqueda realizada el 6 de mayo de 2024).

Aplicando estos términos en la base de datos científica, como hemos comentado anteriormente, se observa una tendencia general creciente en el número de investigaciones en **EEG process** (figura 2.1) a lo largo de los años, indicando un aumento en el interés y la actividad de investigación en esta área. A partir del año 2010, se ha registrado un incremento más notable en el número de publicaciones, coincidiendo con avances tecnológicos significativos en la captura y análisis de señales EEG, así como un mayor interés en la neurociencia cognitiva y la aplicación del EEG en campos como la medicina, la psicología y la neurociencia. Es particularmente nota-

ble el incremento significativo en el número de publicaciones en los últimos años, destacándose los aumentos considerables en 2023 y 2024, lo que podría reflejar un enfoque intensificado en esta área de investigación y posibles avances significativos en tecnologías relacionadas con el EEG.

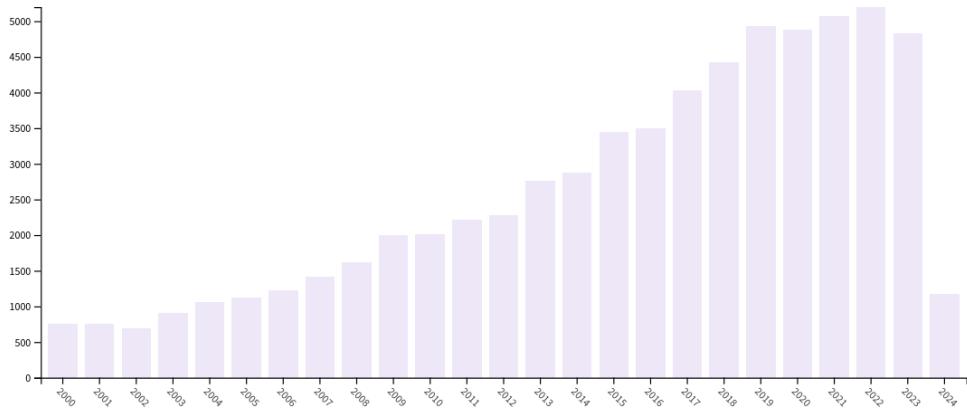


Figura 2.1: Tendencia temporal: EEG processing. (WoS)

El análisis de las áreas de investigación relacionadas con EEG process revela un enfoque predominante en las neurociencias y la neurología (tabla 2.1), seguido de cerca por las ciencias de la computación y la ingeniería. Estos hallazgos subrayan la importancia del estudio de la actividad cerebral y su aplicación en una variedad de campos, desde el diagnóstico médico hasta la comprensión del comportamiento humano. Además, la integración de técnicas de imagen médica con la EEG y el énfasis en el modelado computacional y el análisis matemático reflejan la naturaleza interdisciplinaria de la investigación en esta área. Este panorama diverso demuestra el continuo interés y la amplia aplicación de la electroencefalografía en la ciencia y la medicina contemporáneas.

Research Area	Record Count (% of 65,195)
Neurosciences Neurology	51,641 (79.210 %)
Computer Science	33,204 (50.930 %)
Engineering	32,400 (49.697 %)
Radiology Nuclear Medicine Medical Imaging	31,437 (48.220 %)
Mathematical Computational Biology	27,990 (42.933 %)
Behavioral Sciences	23,667 (36.302 %)
Communication	22,608 (34.678 %)
Psychology	21,867 (33.541 %)
Mathematics	20,288 (31.119 %)
Science Technology Other Topics	12,882 (19.759 %)
Physiology	6,735 (10.331 %)
Psychiatry	6,269 (9.616 %)
Pediatrics	6,099 (9.355 %)
Ophthalmology	5,694 (8.734 %)
Instruments Instrumentation	4,895 (7.508 %)
Automation Control Systems	4,438 (6.807 %)

Tabla 2.1: Áreas de Conocimiento. (WoS)

Los datos sobre el dominio de investigación (figura 2.2) revelan que la mayoría de las investigaciones sobre EEG process se concentran principalmente en Ciencia y Tecnología (94.27 %) y en Ciencias de la Vida y Biomedicina (87.84 %). También hay un notable interés en Ciencias Sociales (65.02 %) y en Tecnología (62.26 %). Por último, en Ciencias Físicas (35.67 %), se es-

tudian los métodos de registro y análisis de señales EEG.

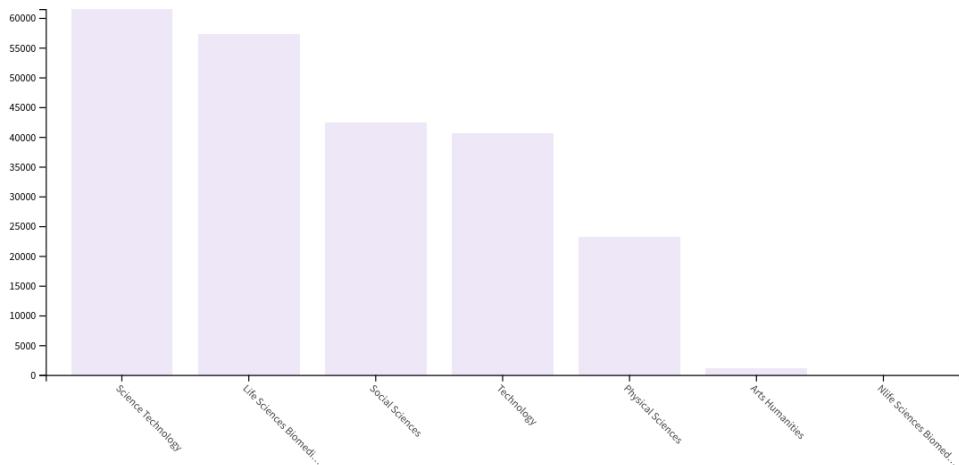


Figura 2.2: Dominio de Estudio. (WoS)

Los resultados del objetivo de estudio (tabla 2.2) confirman una variedad de conceptos principales en la investigación del procesamiento de señales EEG, desde la fisiología neural fundamental hasta aplicaciones prácticas en medicina. Términos como "Neural Coordination", "Nervous System", "Methods And Techniques", y "Human Medicine Medical Sciences" reflejan esta diversidad. Además, el interés en enfoques computacionales y modelado matemático está indicado por términos como "Computational Biology", "Mathematical Biology", mientras que la inclusión de "Behavior", "Psychiatry", "Pediatrics" subraya la relevancia clínica y conductual de esta investigación.

Major Concepts	Record Count	% of 65,195
Neural Coordination	11,939	18.313 %
Nervous System	10,629	16.303 %
Methods And Techniques	9,632	14.774 %
Human Medicine Medical Sciences	8,792	13.486 %
Neurology	7,090	10.875 %
Computational Biology	4,796	7.356 %
Behavior	4,350	6.672 %
Psychiatry	3,608	5.534 %
Models And Simulations	2,049	3.143 %
Medical Sciences	1,798	2.758 %
Mathematical Biology	1,705	2.615 %
Pediatrics	1,555	2.385 %
Computer Applications	1,299	1.992 %
Pharmacology	1,280	1.963 %

Tabla 2.2: Objetivo de estudio. (WoS)

En los últimos tres años, se observa un significativo incremento y atención en la investigación en neurociencia (tabla ??), destacando las Neurociencias y Neurología que abarcan aproximadamente el 83.5 % del total de investigaciones. Este aumento indica un renovado interés en el estudio del sistema nervioso y la actividad cerebral. Paralelamente, la prominencia de áreas como Ciencias de la Computación, Ingeniería y Biología Computacional, todas con más del 50 % del total, reflejan un creciente interés en la aplicación de tecnologías de inteligencia artificial como el aprendizaje automático y profundo en la neurociencia. Estas técnicas son cada vez más utilizadas para analizar grandes volúmenes de datos neuronales y modelar procesos cerebrales

complejos. Además, la intersección entre la neurociencia y la informática se evidencia en áreas como Radiología, Medicina Nuclear e Imágenes Médicas, que emplean avanzadas técnicas de imagen en la investigación cerebral. Por último, la inclusión de disciplinas como Comunicación, Ciencias del Comportamiento y Psicología subrayan un enfoque interdisciplinario en el estudio de la mente y el cerebro, aprovechando las técnicas de IA para el análisis de datos y la modelización de procesos cognitivos.

Research Areas	Record Count	% of 11,215
Neurosciences Neurology	9,364	83.495 %
Computer Science	6,036	53.821 %
Engineering	6,003	53.527 %
Radiology Nuclear Medicine Medical Imaging	5,935	52.920 %
Mathematical Computational Biology	5,914	52.733 %
Communication	4,469	39.848 %
Behavioral Sciences	3,652	32.564 %
Psychology	3,613	32.216 %
Mathematics	2,963	26.420 %
Science Technology Other Topics	2,386	21.275 %
Instruments Instrumentation	1,303	11.618 %
Psychiatry	1,109	9.889 %
Automation Control Systems	878	7.829 %
Robotics	761	6.786 %
Physiology	760	6.777 %
Physics	702	6.259 %
Ophthalmology	646	5.760 %
Chemistry	624	5.564 %
General Internal Medicine	582	5.189 %
Pediatrics	582	5.189 %

Tabla 2.3: Áreas de Investigación en los Últimos Tres Años. (WoS)

Al integrar conceptos clave y dominios en las áreas de investigación, se destaca una conexión profunda y multidimensional. Las Neurociencias y la Neurología dominan en Ciencia y Tecnología, así como en Ciencias de la Vida y Biomedicina, centradas en la Coordinación Neural y el Sistema Nervioso. La Informática, Ingeniería y Biología Computacional, también prominentes, se vinculan con técnicas avanzadas y Biología Computacional. Disciplinas como Ciencias Sociales, Físicas y Humanidades enriquecen el estudio interdisciplinario, ofreciendo perspectivas y métodos diversos para comprender mejor los fenómenos cerebrales.

Research Domains	Record Count	% of 11,215
Science Technology	10,633	94.811 %
Life Sciences Biomedicine	10,078	89.862 %
Social Sciences	7,587	67.650 %
Technology	6,709	59.822 %
Physical Sciences	3,662	32.653 %
Arts Humanities	140	1.248 %

Tabla 2.4: Dominios de Investigación. (WoS)

Este estudio no puede concluir sin mencionar el artículo de Yannick Roy titulado [60], el cual proporciona una visión exhaustiva de cómo las tecnologías de aprendizaje profundo están transformando la investigación en el análisis de EEG. Se destaca la proliferación de

estudios donde se han aplicado modelos profundos en diversas áreas del análisis de datos EEG (figura 5.3), evidenciando la adaptación de técnicas provenientes de la visión por computadora e inteligencia artificial. Entre las arquitecturas más utilizadas se encuentran las redes neuronales convoluciones (CNN), así como los autoencoders y redes recurrentes. Estos hallazgos subrayan la importancia del aprendizaje profundo para mejorar la eficiencia y precisión en aplicaciones clave de EEG, demostrando su versatilidad y potencial en este campo de investigación.

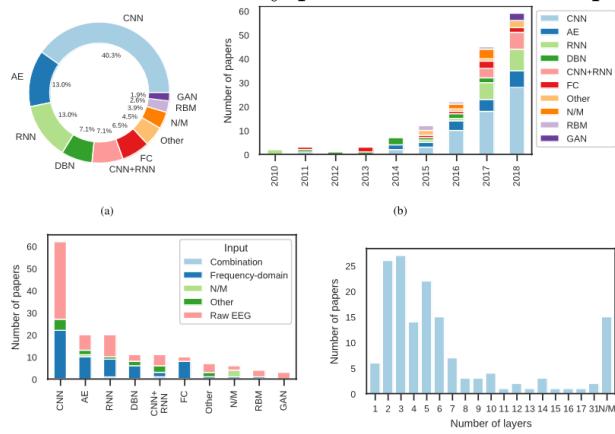


Figura 2.3: J. Neural Eng. 16 (2019) 051001 (37pp): Deep learning-based electroencephalography analysis: a systematic review

En la Figura 5.3 se observa que el 40 % de los estudios utilizaron CNNs, mientras que RNNs y autocodificadores fueron elegidos por alrededor del 13 % cada uno. Además, las combinaciones de CNNs y RNNs se emplearon en el 7 % de los estudios. La profundidad de las arquitecturas utilizadas sugiere que el uso de modelos menos profundos podrían ser más efectivos, ya que la mayoría de los estudios fijan redes con como máximo 10 capas internas.

2.2. Tecnologías

El análisis en reservorios, ejemplificado por las Redes de Estado de Eco (ESN), emergió como uno de los campos de estudio más dinámicos durante los primeros años del 2000. Su capacidad para procesar series temporales de manera eficiente y sencilla lo posicionó como una herramienta esencial en el dominio del aprendizaje supervisado. A pesar de que estas metodologías son más antiguas que los enfoques de aprendizaje profundo, continúan siendo relevantes en la actualidad gracias a su facilidad de implementación y excelentes resultados obtenidos.

La técnica computacional del Reservoir Computing (RC), en particular, ha ganado prominencia nuevamente debido en parte a la necesidad de un procesamiento rápido y eficaz de sistemas temporales dinámicos, una demanda cada vez más evidente en diversos campos científicos. Y más concretamente por el avance de los estudios en el campo del procesamiento de señales neuronales y la neurociencia computacional, donde se está utilizando de manera efectiva, lo que subraya su relevancia continua en la vanguardia de la investigación científica.

El campo del procesamiento de señales neuronales y la neurociencia computacional ha sido objeto de diversas investigaciones y aplicaciones, especialmente en lo que respecta al uso de técnicas como el Reservoir Computing (RC). Si bien existen otros enfoques similares, como las Redes Neuronales Artificiales (ANNs), las Máquinas de Soporte Vectorial (SVM) y las Redes Neuronales Recurrentes (RNNs), cada uno con sus propias características y aplicaciones específicas, el RC se destaca por su capacidad para manejar eficientemente señales temporales y secuenciales.

Las ANNs, aunque versátiles en una variedad de aplicaciones, pueden ser difíciles de entrenar y sensibles a la inicialización de parámetros. Las SVM, por su parte, son sólidas en términos teóricos pero pueden no ser adecuadas para modelar datos temporales. Las RNNs, aunque útiles para modelar secuencias temporales, pueden sufrir de problemas de gradientes durante el entrenamiento.

En contraste, el Reservoir Computing (RC) se destaca por su capacidad para modelar la dinámica temporal de las señales cerebrales de manera robusta y eficiente. Esta capacidad es especialmente relevante en el procesamiento de señales EEG dentro de campos como la neurociencia computacional y la interfaz cerebro-máquina [61, 62, 63, 64].

Las señales EEG son inherentemente temporales y muestran patrones complejos de actividad neuronal que cambian con el tiempo. El RC, con su arquitectura recurrente simple y su fase de entrenamiento única, es capaz de capturar y modelar estas dinámicas temporales de manera precisa. Esto permite una representación más fiel de la actividad cerebral y una mejor comprensión de los procesos neuronales subyacentes [65].

Además, el RC ha demostrado ser efectivo en la construcción de interfaces cerebro-máquina, donde se utilizan señales EEG para controlar dispositivos externos o interactuar con entornos virtuales. La capacidad del RC para manejar señales temporales en tiempo real lo hace ideal para aplicaciones en las que se requiere una respuesta rápida y precisa basada en la actividad cerebral [62, 66, 64].

En lugar de realizar un estudio bibliométrico sobre la tecnología de RC, se reconoce la existencia de investigaciones exhaustivas y detalladas en este ámbito, como el artículo de Gouhei Tanaka [5] y el reciente estudio bibliométrico de Fabian Corrêa Cardoso [67]. Estos trabajos proporcionan análisis completos y tablas (tabla 2.5 y tabla 2.6) que resaltan la relevancia del RC en diversas áreas de la física e ingeniería, haciendo innecesaria la replicación de un estudio bibliométrico adicional en este momento.

Category	Examples
Biomedical	EEG, fMRI, ECG, EMG, heart rates, biomarkers, BMI, eye movement, mammogram, lung images. Images, videos. Speech, sounds, music, bird calls.
Vehicles	Robots, sensors, motors, compressors, controllers, actuators.
Power plants	Power lines, renewable energy, engines, fuel cells, batteries, gas flows, diesel oil, coal mines, hydraulic excavators, steam generators, roller mills, footbridges, air conditioners.
Pattern classification	Spoken digit recognition, waveform classification, human action recognition, handwritten digit image recognition.
Time series forecasting	Chaotic time series prediction, NARMA time series prediction.
Pattern generation	Sine-wave generation, limit cycle generation, channel equalization.
Environmental	Wind power and speed, ozone concentration, PM2.5, wastewater, rainfall, seismicity.
Security	Cryptography.
Financial	Stock price, stock index, exchange rate.
Social	Language, grammar, syntax, smart phone.

Tabla 2.5: Examples of subjects in RC applications. Gouhei Tanaka [5]

Category	Benchmark tasks
Pattern classification	Spoken digit recognition (Verstraeten, Schrauwen, Stroobandt and Van Campenhout, 2005), Waveform classification (Paquot et al., 2012), Human action recognition (Soh & Demiris, 2012), Handwritten digit image recognition (Jalalvand, Van Wallendael, & Van de Walle, 2015)
Time series forecasting	Chaotic time series prediction (Jaeger, 2001), NARMA time series prediction (Jaeger, 2003)
Pattern generation	Sine-wave generation (Jaeger, 2002b), Limit cycle generation (Hauser, Ijspeert, Füchslin, & Maass, 2012)
Adaptive filtering and control	Channel equalization (Jaeger & Haas, 2004)
System approximation	Temporal XOR task (Bertschinger & Natschläger, 2004), Temporal parity task (Bertschinger & Natschläger, 2004)
Short-term memory	Memory capacity (Jaeger, 2002a)

Tabla 2.6: Applications and related benchmark tasks of RC. Gouhei Tanaka [5]

Para no concluir esta sección sin consultar también la base de datos Web of Science, hemos investigado el número de estudios relacionados con el procesamiento de señales EEG utilizando Reservoir Computing, revelando una evolución significativa en los últimos años (figura 2.4), como se muestra en la siguiente gráfica.

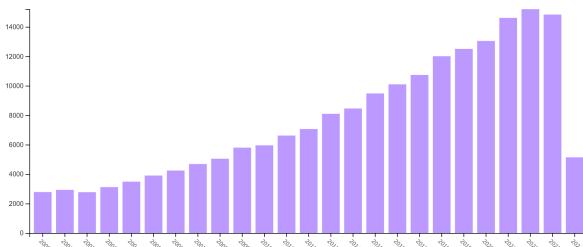


Figura 2.4: Número de Investigaciones Uso RC para procesamiento de señales EEG, por Año. WoS

Capítulo 3

Marco teórico

3.1. Circuitos corticales y áreas funcionales

El estudio del cerebro humano representa un desafío formidable, siendo uno de los sistemas más complejos conocidos por la humanidad. A lo largo del tiempo, la neuroimagen y la electrofisiología han sido herramientas vitales para desentrañar los misterios de la actividad cerebral. En sus inicios, estas disciplinas se centraban en la identificación de regiones específicas asociadas a ciertas tareas o patrones locales de actividad. Sin embargo, la comprensión actual del cerebro ha evolucionado hacia la percepción de la actividad cerebral como un fenómeno temporal y espacialmente extendido. Hoy en día, se reconoce al cerebro como una intrincada red de regiones interconectadas, cuya actividad fluctuante y coordinada da lugar a una amplia gama de funciones cognitivas y conductuales¹.

El cerebro humano presenta una arquitectura neuronal altamente compleja, compuesta por una variedad de tipos de neuronas y redes interconectadas que dan lugar a una rica diversidad de circuitos corticales². Los circuitos corticales representan la base funcional de esta organización, constituidos por redes de neuronas interconectadas que procesan información a través de conexiones sinápticas específicas. Estas conexiones permiten la comunicación eficiente entre diferentes áreas corticales: frontal, parietal, temporal y occipital, cada uno con funciones especializadas. El lóbulo frontal, por ejemplo, es crucial para funciones ejecutivas, toma de decisiones y control motor, mientras que el lóbulo parietal está implicado en la percepción sensorial y la integración espacial. El lóbulo temporal es esencial para el procesamiento auditivo y la memoria, y el lóbulo occipital se encarga principalmente del procesamiento visual.

Estas áreas (figura 3.1) comparten una composición celular básica de neuronas excitatorias e inhibidoras, cuyas conexiones forman circuitos que procesan información y cuya disfunción subyace a trastornos neurológicos y psiquiátricos como convulsiones, demencia y esquizofrenia. [68]

¹Disponible en: <https://github.com/jogugil/MyRC/wiki>.

²Disponible en: <https://github.com/jogugil/MyRC/wiki>.

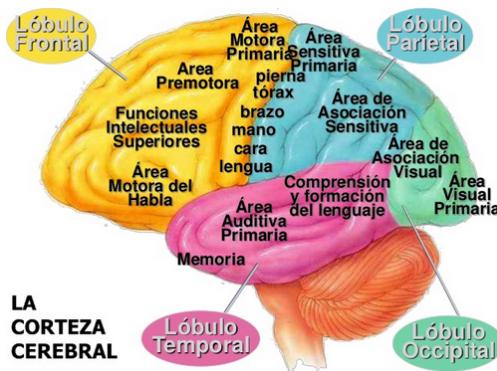


Figura 3.1: Áreas de regiones corticales

Estos circuitos, distribuidos a lo largo de diferentes regiones cerebrales, desempeñan roles específicos en el procesamiento de información y la generación de patrones de actividad neuronal. Además, la arquitectura neuronal del cerebro exhibe una organización meticulosa en múltiples niveles, desde las conexiones sinápticas a nivel microscópico hasta las interacciones entre regiones corticales a nivel macroscópico. Esta intrincada red de neuronas y conexiones desempeña un papel fundamental en la generación y transmisión de señales eléctricas, las cuales pueden ser registradas mediante técnicas como la electroencefalografía (EEG). Esta comprensión profunda sienta las bases para explorar las técnicas de procesado de señales temporales presentes en los EEG, con el fin de capturar patrones complejos de actividad neuronal y, con ello, conocer aspectos de la cognición del sujeto, como sus emociones, estados neuronales, movimientos o percepciones visuales y/o auditivas.

Para obtener información detallada sobre las funciones específicas de cada lóbulo cortical y su contribución a la actividad cerebral, se puede consultar la web del proyecto³. En esta página, también se profundiza en los diferentes tipos de interfaces cerebro-computadora y las señales cerebrales que capturan, proporcionando una visión técnica más completa de estos sistemas.

3.1.1. Formación y características de las señales EEG

Las señales de electroencefalografía (EEG) son la manifestación directa de la actividad eléctrica del cerebro, principalmente generadas por potenciales postsinápticos de neuronas piramidales en la corteza cerebral. Estos potenciales crean campos eléctricos detectables en el cuero cabelludo, registrados de manera no invasiva mediante electrodos superficiales. Las señales EEG resultan de la superposición de corrientes sinápticas sincronizadas de grandes poblaciones neuronales, formando dipolos eléctricos cuyos campos se suman y se detectan a nivel macroelectrodo. La amplitud y frecuencia de las ondas EEG proporcionan información sobre la dinámica de la actividad neuronal subyacente.

Las ondas EEG se clasifican en varios tipos, cada una con características de frecuencia, amplitud específicas u funcionalidad específica (tabla 3.1).

³Disponible en: <https://github.com/jogugil/MyRC/wiki>.

Onda	Frecuencia (Hz)	Estado
Delta	0.5 - 4	Sueño, reparación, resolución de problemas complejos, inconsciencia, profunda inconsciencia
Theta	4 - 8	Creatividad, percepción, estados profundos, inconsciencia, estado meditativo óptimo, depresión, ansiedad, distracción
Alfa	8 - 13	Alerta y tranquilidad, preparación, meditación, profundamente relajado
Alfa inferior	8 - 10	Recordando
Alfa superior	10 - 13	Optimizar el rendimiento cognitivo
SMR (ritmo sensoriomotor)	13-15	Estado de alerta mental, relajación física
Beta	15 - 20	Pensar, enfocar, atención sostenida, tensión, estado de alerta, emoción
Beta alto	20 - 32	Intensidad, estado de hiper-alerta, ansiedad
Gamma	32 - 100	Aprendizaje, procesamiento cognitivo, tareas de resolución de problemas, agudeza mental, actividad cerebral, organización del cerebro

Tabla 3.1: Clasificación de las ondas cerebrales según su frecuencia y estado asociado.

3.1.2. Regiones y circuitos corticales

La relación entre los circuitos corticales y las señales EEG es crucial para comprender la generación de patrones específicos de actividad eléctrica en el cerebro. El análisis de señales EEG permite observar cómo la actividad de redes neuronales específicas dentro de los circuitos corticales se sincroniza, es decir, cómo las neuronas en diferentes áreas del cerebro coordinan su actividad para generar ondas eléctricas medibles. Por ejemplo, las ondas alfa, que emergen de la corteza occipital, indican estados de relajación y procesamiento visual básico, mientras que las ondas beta, predominantes en las regiones frontales, reflejan una mayor actividad cognitiva. Este conocimiento es fundamental para la investigación en neurociencia, el desarrollo de interfaces cerebro-computadora y el diagnóstico clínico de trastornos neurológicos.

Este estudio se enfoca en analizar las señales EEG en reposo de jóvenes adultos y adultos mayores para explorar las diferencias en la función cognitiva entre estos grupos etarios. Las señales EEG pueden mostrar variaciones significativas en las características eléctricas del cerebro, evidenciando distintos patrones de actividad neuronal en diversas regiones cerebrales según la edad. La investigación examinará cómo varía la actividad cerebral con la edad utilizando el estado de reposo para evaluar la actividad basal del cerebro y su relación con la cognición en diferentes grupos etarios.

Mediante el registro de la actividad cerebral cerca de la superficie del cuero cabelludo con electrodos específicos, se identificarán patrones asociados con diversos estados cognitivos y emocionales. Este enfoque permite evaluar ritmos y patrones cerebrales característicos que pueden cambiar con la edad, proporcionando una comprensión más detallada de las diferencias

entre jóvenes adultos y adultos mayores.

3.2. Técnicas de procesamiento de señales EEG

El procesamiento de señales EEG es un paso crucial en el análisis de la actividad cerebral y su relación con la cognición y el comportamiento. Antes de realizar cualquier análisis, es necesario realizar un preprocesamiento de las señales EEG para mejorar su calidad y eliminar artefactos que puedan distorsionar los resultados.

Dado que los datos se nos proporcionan en bruto, se requerirá un preprocesamiento para asegurar la calidad de las señales EEG y eliminar posibles artefactos. Esto implica la aplicación de filtros para eliminar el ruido y la interpolación para manejar los artefactos causados por movimientos oculares y musculares.

3.2.1. Preprocesamiento de señales EEG

El preprocesamiento de las señales EEG comienza con la aplicación de filtros para eliminar el ruido no deseado y las frecuencias irrelevantes. Los tipos de filtros que se pueden aplicar incluyen:

- **Filtros de paso bajo:** Utilizados para eliminar el ruido de alta frecuencia, como el generado por el movimiento muscular.
- **Filtros de paso alto:** Empleados para eliminar el ruido de baja frecuencia, como el generado por la línea eléctrica.

3.2.2. Eliminación de artefactos

La eliminación de artefactos del EEG comprende una serie de métodos para la reducción o cancelación de ruido, producido por señales subyacentes asociadas a procesos fisiológicos originadas por la misma fuente.

En el contexto de señales del cerebro obtenidas a partir de un interfaz cerebro-computador (BCI), un artefacto generalmente se refiere a cualquier interferencia no deseada o distorsión en la señal que puede deberse a factores externos o internos. Estos artefactos pueden afectar la calidad de las señales de EEG (electroencefalograma), que son cruciales para el análisis de estados neuronales y cognitivos en estudios de EEG en reposo, especialmente en poblaciones de sujetos jóvenes, adultos y mayores.

Los artefactos en las señales EEG son perturbaciones no deseadas que pueden ser causadas por diversos factores, como el movimiento muscular, el movimiento ocular, interferencias electromagnéticas externas, variaciones en la impedancia de los electrodos o artefactos ambientales. Estos artefactos pueden distorsionar la señal cerebral subyacente y dificultar la interpretación precisa de los datos EEG (Figura 3.2).

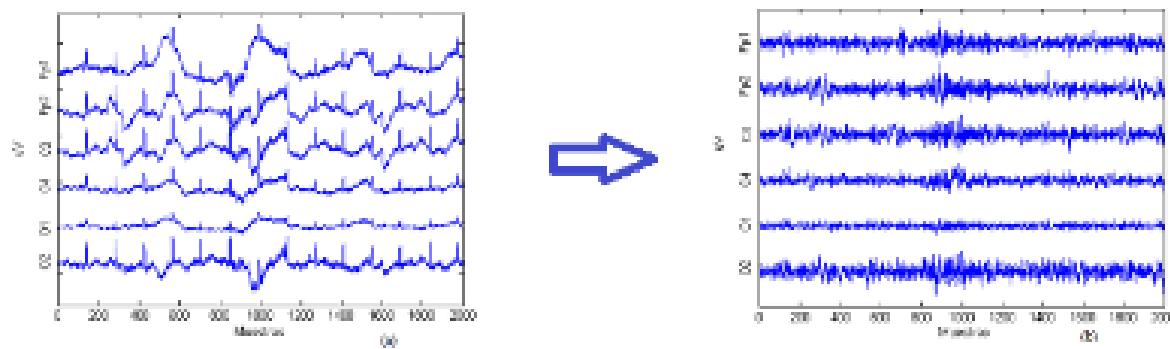


Figura 3.2: Eliminación artefactos

En estudios de EEG en reposo, la influencia de los artefactos puede variar entre sujetos jóvenes adultos y mayores. Por ejemplo:

- **Sujetos jóvenes adultos:** Es más probable que presenten artefactos debido a movimientos oculares rápidos y actividad muscular involuntaria, ya que tienden a ser más activos incluso en reposo.
- **Sujetos mayores:** Es probable que experimenten más artefactos cardiacos debido a variaciones fisiológicas asociadas con la edad, así como posibles problemas con la colocación de electrodos debido a cambios en la piel y el tejido subyacente.

Existen diversas técnicas para la eliminación de artefactos en las señales de EEG. A continuación, se describen algunas de las más utilizadas, junto con sus fundamentos matemáticos y una evaluación de su idoneidad para el análisis de EEG en reposo.

- **ICA (Análisis de componentes independientes):**

- El ICA es una técnica de procesamiento de señales que descompone las señales EEG en componentes independientes. Algunos de estos componentes pueden corresponder a artefactos, que pueden ser identificados y eliminados para limpiar la señal EEG. Formalmente, el ICA se puede definir como sigue:

$$X = AS$$

donde X es la matriz de señales EEG observadas, A es la matriz de mezcla que describe la mezcla lineal de las señales de origen, y S es la matriz de señales de origen independientes.

- **Ventajas:** Es eficaz para separar fuentes independientes, lo cual es útil cuando las señales de EEG contienen múltiples tipos de artefactos superpuestos.
- **Desventajas:** Requiere una cantidad significativa de datos y puede ser computacionalmente costosa. Además, la identificación de componentes específicos como artefactos puede ser subjetiva.
- **Idoneidad para EEG en reposo:** Es una técnica poderosa, especialmente útil en estudios donde los artefactos son complejos y múltiples. Sin embargo, puede ser excesiva para estudios sencillos de EEG en reposo si los artefactos son menos frecuentes o más fácilmente manejables.

- **Rechazo de segmentos contaminados:**

- Esta técnica implica identificar segmentos de la señal EEG que contienen artefactos evidentes y eliminarlos del análisis. No requiere fórmulas matemáticas específicas, pero se puede formalizar como un proceso de ventana móvil para detectar umbrales:

$$S(t) = \begin{cases} S(t) & \text{si } |S(t)| < \text{umbral} \\ 0 & \text{si } |S(t)| \geq \text{umbral} \end{cases}$$

donde $S(t)$ es el segmento de la señal en el tiempo t .

- **Ventajas:** Es sencillo de implementar y puede eliminar eficazmente segmentos gravemente contaminados.
- **Desventajas:** Puede resultar en la pérdida de datos valiosos si los segmentos contaminados son extensos o frecuentes.
- **Idoneidad para EEG en reposo:** Adecuada para estudios donde los artefactos son raros y fáciles de identificar. Sin embargo, puede no ser ideal si los artefactos son frecuentes, ya que se perdería demasiada información.

Existen diversas librerías que facilitan la eliminación de artefactos en señales EEG. A continuación se describen algunas de las más utilizadas:

- **MNE-Python:** MNE-Python es una librería en Python para el análisis de datos de EEG y MEG. Incluye funciones robustas para el preprocesamiento de datos, como la eliminación de artefactos a través de técnicas de filtrado, ICA y corrección de línea base.
- **EEGLAB:** EEGLAB es una herramienta de código abierto para MATLAB, diseñada para el análisis de datos EEG. Proporciona funciones para el filtrado, la detección y la eliminación de artefactos, con soporte para técnicas como ICA.
- **YASA:** YASA es una librería en Python orientada al análisis del sueño, pero también útil para el análisis de EEG en general. Ofrece funciones para la detección de eventos y la eliminación de artefactos.
- **Scikit-learn (FastICA):** Scikit-learn es una librería en Python para aprendizaje automático, que incluye el módulo ‘FastICA’ para realizar Análisis de Componentes Independientes de manera eficiente.

3.3. Aprendizaje automático en el procesamiento de señales neuronales

El campo del procesamiento de señales neuronales se ha beneficiado enormemente del avance del aprendizaje automático (Machine Learning), una poderosa herramienta que permite la extracción de información y la toma de decisiones a partir de datos complejos y dinámicos. El aprendizaje automático capacita a los sistemas informáticos para aprender patrones y realizar tareas específicas sin la necesidad de ser programados explícitamente.

3.3.1. Aprendizaje no supervisado

La técnica de aprendizaje no supervisado se orienta a identificar los estados neuronales presentes en las señales EEG, así como los tipos y número de patrones que podemos encontrar.

Esta búsqueda se realiza sin ayuda externa, ya que no contamos con etiquetas que nos indiquen si un tipo de señal EEG corresponde a un patrón de estado emocional o a cualquier otra categoría. La idea es procesar las señales EEG y obtener los patrones de la dinámica temporal existente en dichas señales de cada electrodo del EEG. Previamente a la aplicación de técnicas de reducción de dimensionalidad como el t-SNE, es fundamental aplicar un método de agrupamiento para identificar las estructuras subyacentes en los datos:

- **K-means:** Este algoritmo busca particionar los datos en K clústers, minimizando la varianza dentro de cada grupo. Es eficiente y fácil de implementar, pero requiere especificar el número de clústers de antemano.
- **Clustering jerárquico:** Construye una jerarquía de clusters, ya sea de manera aglomerativa (comenzando con puntos individuales y fusionándolos) o divisiva (comenzando con todos los puntos y dividiéndolos). Este método no necesita especificar el número de clusters de antemano y produce una dendrograma que puede ser útil para decidir el número de clusters.
- **t-SNE (t-Distributed Stochastic Neighbor Embedding)** es una técnica de reducción de dimensionalidad que convierte similitudes entre datos de alta dimensión en probabilidades conjuntas y luego minimiza la divergencia de Kullback-Leibler entre estas probabilidades conjuntas en el espacio de menor dimensión y las probabilidades conjuntas en el espacio original. Se usa principalmente para la visualización de datos de alta dimensión en 2D o 3D. Proporciona una representación visual donde puntos similares están más cerca unos de otros, permitiendo identificar agrupaciones y patrones en los datos.

Estas técnicas no supervisadas son fundamentales para entender la estructura intrínseca de los datos EEG, ya que nos permiten identificar patrones y agrupaciones sin necesidad de etiquetas, lo que es crucial en etapas exploratorias y de preprocesamiento en estudios neurocientíficos.

3.3.2. Aprendizaje supervisado

El aprendizaje supervisado es una metodología en la que el algoritmo de aprendizaje se entrena utilizando ejemplos etiquetados, es decir, pares de entrada-salida previamente asociados. Este enfoque es ampliamente utilizado en el procesamiento de señales neuronales para tareas como la clasificación de patrones, la detección de anomalías y la predicción de eventos. Por ejemplo, en el análisis de señales EEG, se puede emplear el aprendizaje supervisado para clasificar diferentes estados mentales, como la atención y la relajación, a partir de las características extraídas de las señales cerebrales. El aprendizaje supervisado puede dividirse en dos categorías principales: clasificación y regresión.

Clasificación

En la clasificación, el objetivo es asignar una etiqueta discreta a una instancia de entrada. Algunos modelos populares para la clasificación son:

Máquinas de soporte vectorial (SVM): SVM es un algoritmo que encuentra el hiperplano óptimo que separa las clases en el espacio de características, maximizando el margen entre las clases. Es eficaz en espacios de alta dimensión y puede utilizarse con kernels para manejar datos no lineales.

Redes neuronales artificiales (ANN): Las ANN están inspiradas en la estructura del cerebro humano y consisten en capas de neuronas interconectadas. Son capaces de aprender representaciones complejas de los datos y son ampliamente utilizadas para tareas de clasificación complejas, especialmente con la llegada de técnicas de deep learning.

Regresión ridge: La regresión Ridge es una variante de la regresión lineal que incluye un término de penalización en la función de pérdida para evitar el sobreajuste. Este término de regularización ayuda a mantener los coeficientes ajustados y a mejorar la generalización del modelo. Es especialmente útil cuando las características de entrada están altamente correlacionadas.

Este modelos supervisados son fundamentales en el análisis de señales EEG, ya que permiten la identificación precisa de estados mentales y la predicción de eventos basados en patrones neuronales.

3.4. Reservoir computing (RC)

El análisis de las señales EEG implica el uso de técnicas avanzadas de procesamiento de señales, como las redes neuronales recurrentes (RNN). Las RNN, modelos de aprendizaje automático, capturan la dinámica temporal de las señales EEG, lo que proporciona una mejor comprensión de los patrones de actividad cerebral a lo largo del tiempo ([ver la web del proyecto⁴](#)). Esto permitirá identificar características distintivas en las señales EEG de jóvenes adultos y adultos mayores, profundizando así en la comprensión de los cambios asociados con el envejecimiento cerebral. Tal como se indica en el apéndice existen diferentes tipos de Reservoir Computing, a lo largo del documento cuando hagamos referencia a Reservoir Computing nos estaremos haciendo referencia al modelo Echo State Network (RC ESN) (figura 3.3).

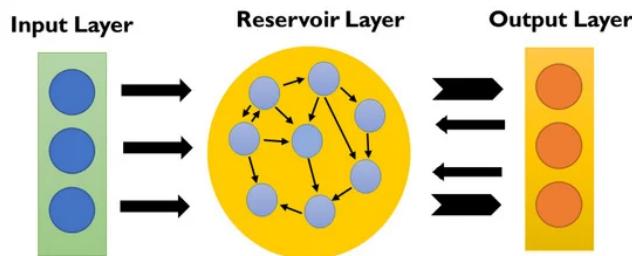


Figura 3.3: Esquema Base Reservoir Computing. Fuente [1]

En este contexto, el Reservoir Computing (RC) emerge como una técnica poderosa y efectiva en el análisis de señales EEG. A diferencia de las redes recurrentes tradicionales, que suelen trabajar con características temporales, frecuenciales y tiempo-frecuenciales extraídas de las señales EEG preprocesadas, el RC puede obtener patrones dinámicos de las series temporales en bruto sin necesidad de extracción previa de características. Este enfoque puede distinguir entre dos grupos de sujetos (jóvenes adultos y adultos mayores) y clasificar cada EEG según su grupo.

Al combinar la capacidad del RC para analizar y predecir patrones de actividad con la información de las señales EEG, se espera identificar diferencias significativas en la actividad cerebral entre jóvenes adultos y adultos mayores en reposo. Evaluar estas capacidades del RC permitirá determinar su eficacia para discernir y clasificar las diferencias en la actividad cerebral asociadas con la edad, profundizando así en la relación entre la actividad cerebral y el proceso de envejecimiento.

⁴Disponible en: <https://github.com/jogugil/MyRC/wiki>

Para lograr esto, se emplearán tanto un enfoque no supervisado, que genere agrupaciones distintas de actividad cerebral para ambos grupos, como un enfoque supervisado, que clasifique correctamente las señales EEG en bruto sin necesidad de extracción previa de características. Además, se aplicarán técnicas de imagen, como las gráficas de recurrencia, para identificar los patrones dinámicos de la información procesada por el RC.

El Reservoir Computing (RC) es una técnica de aprendizaje automático basada en redes neuronales recurrentes con una arquitectura única. Su principal característica es la presencia de una capa de reservorio"de neuronas recurrentes con conexiones aleatorias y una capa de salida entrenable. Esta arquitectura permite que el reservorio capture y procese información de manera eficiente, lo que lo hace especialmente útil para aplicaciones con datos altamente dinámicos y no lineales, como el procesamiento de señales neuronales.

3.4.1. Arquitectura del RC

La arquitectura del RC consta de tres partes principales (figura 3.4):

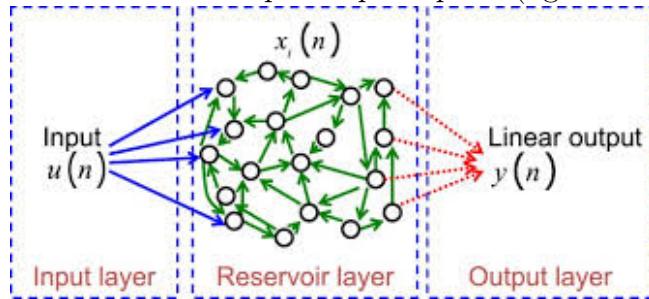


Figura 3.4: Arquitectura Reservoir Computing. Fuente [2]

- 1. Capa de entrada:** Esta capa recibe las señales de entrada y las presenta al reservorio. Puede incluir la codificación de la información temporal y espacial de las señales, como en el caso del procesamiento de señales EEG.

$$\mathbf{x}(t) = \mathbf{W}_{in}\mathbf{u}(t) + \mathbf{b}_{in} \quad (3.1)$$

donde:

- $\mathbf{x}(t)$ es el estado de las neuronas de entrada en el tiempo t .
- \mathbf{W}_{in} es la matriz de pesos de la capa de entrada.
- $\mathbf{u}(t)$ es el vector de entrada en el tiempo t .
- \mathbf{b}_{in} es el vector de sesgo de la capa de entrada.

2. Reservorio

Esta capa está formada por un conjunto de neuronas recurrentes interconectadas con conexiones aleatorias. El reservorio (figura 3.5) actúa como una memoria dinámica que captura la información temporal de las entradas.

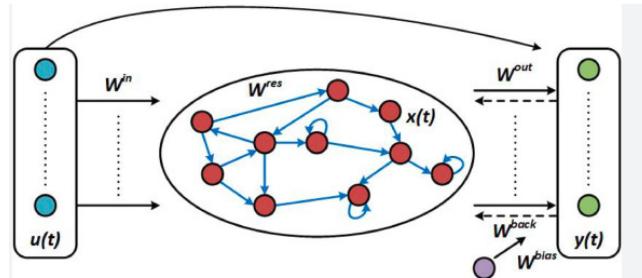


Figura 3.5: Entrnamiento RC-ESN. Fuente [3]

La ecuación que describe la evolución temporal del estado del reservorio es la siguiente:

$$\mathbf{x}(t+1) = \sigma(\mathbf{W}_{res}\mathbf{x}(t) + \mathbf{W}_{in}\mathbf{u}(t) + \mathbf{b}_{res}) \quad (3.2)$$

donde:

- $\mathbf{x}(t)$ es el estado del reservorio en el tiempo t .
- \mathbf{W}_{res} es la matriz de pesos recurrentes del reservorio.
- σ es la función de activación no lineal (generalmente y por historia se suele usar tangente hiperbólica).
- \mathbf{b}_{res} es el vector de sesgo del reservorio.

Las conexiones recurrentes permiten que el reservorio mantenga una memoria a corto plazo de las entradas pasadas, lo cual es crucial para capturar la dinámica temporal de las señales EEG. Las conexiones de retroalimentación en esta capa permiten que las salidas anteriores del modelo se retroalimentan como entradas adicionales al reservorio, mejorando la modelización de la dinámica temporal.

Funciones de activación

En Reservoir Computing, la elección de la función de activación en la capa de reservorio juega un papel crucial en el rendimiento y la capacidad de generalización del modelo. Aquí se analizan las características específicas de las funciones de activación tanh y ReLU en el contexto de Reservoir Computing:

- **Tanh (Tangente hiperbólica):**

- Ventajas:
 - Proporciona una no linealidad suave que ayuda a capturar relaciones complejas en los datos temporales.
 - La salida de tanh está acotada en el rango [-1, 1], lo que puede ayudar a mantener la estabilidad dinámica del reservorio.
 - La tangente hiperbólica facilita la generación de dinámicas no lineales, lo que es esencial para la memoria a corto plazo y la representación de patrones temporales en Reservoir Computing.
- Desventajas:
 - La función tanh puede sufrir de saturación en los extremos, lo que puede afectar la capacidad del reservorio para capturar la variabilidad en los datos.
 - La tangente hiperbólica no permite la activación dispersa [69] , lo que podría limitar la capacidad del modelo para manejar datos con patrones dispersos.

- **ReLU (Unidad Lineal Rectificada):**

- Ventajas:
 - La ReLU proporciona una activación no lineal en la región positiva, lo que puede mejorar la capacidad del reservorio para capturar señales con variabilidad dinámica.
 - La función ReLU permite la activación dispersa [69] , lo que podría ser beneficioso para reducir la redundancia en los datos de entrada y mejorar la eficiencia computacional del modelo.
 - Al no sufrir de saturación en los extremos, la ReLU podría ser más efectiva en la representación de señales con amplitudes variables.
- Desventajas:
 - La ReLU puede causar el fenómeno de "neuronas muertas"(dead neurons) donde las unidades de activación permanecen inactivas para entradas negativas, lo que podría afectar la dinámica del reservorio. +
 - Algunos estudios han sugerido que la ReLU puede ser más sensible al ruido en comparación con la tangente hiperbólica, lo que podría impactar la robustez del modelo en entornos con alta variabilidad.

La elección entre tanh y ReLU en Reservoir Computing depende del contexto específico del problema, la naturaleza de los datos y las características del reservorio. Es crucial realizar experimentos y ajustar los parámetros del modelo para optimizar el rendimiento en la tarea deseada.

3. **Capa de salida (readout):** La capa de salida está formada por neuronas entrenables que reciben la información del reservorio y generan las predicciones o clasificaciones finales.

$$\mathbf{y}(t) = \mathbf{W}_{out}\mathbf{r}(t) + \mathbf{b}_{out} \quad (3.3)$$

donde:

- $\mathbf{y}(t)$ es el vector de salida en el tiempo t .
- \mathbf{W}_{out} es la matriz de pesos de la capa de salida.
- \mathbf{b}_{out} es el vector de sesgo de la capa de salida.

A diferencia del reservorio, los pesos \mathbf{W}_{out} en la capa de salida son entrenables. Este entrenamiento se realiza típicamente usando métodos de regresión lineal, lo cual es computacionalmente eficiente. La capa de salida convierte la representación interna de las señales EEG, mantenida en el reservorio, en una predicción o clasificación interpretable. En los siguientes apartados desarrollaremos esta capa de salida más en profundidad.

Justificación de la arquitectura

La arquitectura del RC ofrece varias ventajas específicas:

- **Simplicidad y eficiencia:** La capa de entrada y el reservorio no requieren entrenamiento, lo que reduce significativamente la complejidad computacional. Solo la capa de salida es entrenable, lo que simplifica el proceso de ajuste del modelo.
- **Captura de dinámica temporal:** Gracias a las conexiones recurrentes y de retroalimentación en el reservorio, el RC puede capturar y modelar eficazmente la dinámica temporal de las señales EEG, que es crucial para comprender los patrones de actividad cerebral.

- **Proyección a espacios de mayor dimensión:** La proyección de las señales de entrada a un espacio de mayor dimensión en el reservorio facilita la separación de características complejas y no lineales, mejorando la capacidad del modelo para distinguir entre diferentes patrones de señal.
- **Eficiencia en la extracción de características:** La capacidad del RC para trabajar con las señales en bruto, sin necesidad de una extracción de características previa, permite una modelización más directa y potencialmente más precisa de las señales EEG.

3.4.2. Readout

El framework a desarrollar tendrá unos modelos de readout básicos que se podrán parametrizar como una regresión ridge, un modelo clasificador One-vs-Rest (OVR), un modelo Support Vector Machine (SVCM) y un clasificador de perceptrón multicapa (MLPClassifier). A continuación, se explican cada uno de estos métodos:

- **Regresión ridge:** Es una extensión de la regresión lineal que incluye una penalización para evitar el sobreajuste. La ecuación de la regresión ridge es similar a la de la regresión lineal, pero añade un término de regularización:

$$\min_{\beta} \left(\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p \beta_j^2 \right) \quad (3.4)$$

donde λ es el parámetro de regularización que controla el grado de penalización.

- **Clasificador de perceptrón multicapa (MLPClassifier):** Es una red neuronal artificial compuesta por una capa de entrada, una o más capas ocultas y una capa de salida. Utiliza funciones de activación no lineales para aprender relaciones complejas entre las variables de entrada y la variable de salida. La función de costo a minimizar es:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m L(y_i, f(x_i; \theta)) + \lambda \sum_{j=1}^p \theta_j^2 \quad (3.5)$$

donde L es la función de pérdida, λ es el parámetro de regularización y θ son los pesos de la red.

- **Máquinas de vectores de soporte (SVM):** Es un método de clasificación que encuentra el hiperplano óptimo que separa las clases en el espacio de características. La ecuación general del hiperplano es:

$$f(x) = \beta_0 + \sum_{i=1}^n \beta_i x_i \quad (3.6)$$

donde los coeficientes β se determinan para maximizar el margen entre las clases. La función objetivo a minimizar es:

$$\min_{\beta} \left(\frac{1}{2} \sum_{j=1}^p \beta_j^2 + C \sum_{i=1}^n \max(0, 1 - y_i(\beta_0 + \sum_{j=1}^p \beta_j x_{ij})) \right) \quad (3.7)$$

donde C es el parámetro de regularización.

- **Clasificador One-vs-Rest (OVR)**: Es una estrategia de clasificación para problemas multiclase que entrena un clasificador independiente por cada clase, donde cada clasificador aprende a distinguir una clase de todas las demás. Si se utiliza con un clasificador base como la regresión logística, la función objetivo de cada clasificador es:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [y_i \log(f(x_i; \theta)) + (1 - y_i) \log(1 - f(x_i; \theta))] + \lambda \sum_{j=1}^p \theta_j^2 \quad (3.8)$$

donde $f(x_i; \theta)$ es la probabilidad predicha por el modelo base para la clase específica.

El readout debe ser entrenado previamente con los datos de entrenamiento, utilizando los valores de la representación interna del modelo RC-ESN generados con dichos datos. Posteriormente, se evaluará el readout con la representación interna proporcionada por el modelo RC-ESN usando los datos de test o validación. Por lo tanto, hay que considerar dos fases: en la primera, se entrena el modelo RC-ESN y la capa de readout con los datos de entrenamiento; en la segunda, se valida la capa de readout con la representación interna generada por el modelo RC-ESN con los datos de test o validación. Este enfoque se aplica exclusivamente a métodos supervisados, permitiendo realizar tareas de clasificación utilizando modelos de aprendizaje automático con gran flexibilidad en el análisis y procesamiento de las señales EEG.

3.4.3. Entrenamiento del RC

Las ecuaciones diferenciales que rigen el entrenamiento del RC son:

$$\mathbf{x}(t+1) = f(\mathbf{W}_{in}\mathbf{u}(t) + \mathbf{W}_{res}\mathbf{x}(t) + \mathbf{W}_{fb}\mathbf{y}(t)) \quad (3.9)$$

$$\mathbf{y}(t) = g(\mathbf{W}_{out}\mathbf{x}(t)) \quad (3.10)$$

Donde:

- $\mathbf{x}(t)$ es el estado del reservorio en el tiempo t .
- $\mathbf{u}(t)$ es la entrada en el tiempo t .
- $\mathbf{y}(t)$ es la salida en el tiempo t .
- \mathbf{W}_{in} , \mathbf{W}_{res} y \mathbf{W}_{fb} son las matrices de pesos de las conexiones de entrada, reservorio y retroalimentación, respectivamente.
- \mathbf{W}_{out} es la matriz de pesos de la capa de salida.
- $f(\cdot)$ y $g(\cdot)$ son funciones de activación.

La representación interna del RC se refiere al estado dinámico del reservorio en respuesta a las entradas. Esta representación encapsula la información temporal y espacial de las señales de entrada y es crucial para la generación de predicciones precisas por parte del modelo.

3.4.4. Hiperparámetros del RC

Los hiperparámetros comunes en la arquitectura del RC incluyen la cantidad de neuronas en el reservorio, la conectividad del reservorio, la función de activación, y los parámetros de regularización. Estos hiperparámetros afectan la capacidad y el rendimiento del modelo, y su selección óptima es crucial para obtener resultados satisfactorios.

Ecuaciones de estado de las neuronas

Las ecuaciones de estado de las neuronas describen cómo cambian las actividades de las neuronas en respuesta a las entradas y las conexiones sinápticas entre ellas. Por lo general, estas ecuaciones toman la forma de ecuaciones diferenciales ordinarias (ODE) o ecuaciones diferenciales estocásticas (SDE), dependiendo del modelo específico del reservorio.

La forma general de una ecuación de estado de una neurona podría ser:

$$\frac{dx_i(t)}{dt} = -x_i(t) + \sum_j W_{ij} f(x_j(t)) + I_i(t) \quad (3.11)$$

Donde:

- $x_i(t)$ es la actividad de la neurona i en el tiempo t .
- W_{ij} es el peso sináptico entre la neurona i y la neurona j .
- f es una función de activación que describe cómo se transforma la actividad de entrada en la actividad de salida de la neurona.
- $I_i(t)$ es una corriente de entrada externa a la neurona i .

Los parámetros como W_{ij} y la función de activación tienen un impacto significativo en la dinámica del reservorio.

Ecuaciones de conectividad del reservorio

Las ecuaciones de conectividad del reservorio describen cómo se conectan las neuronas dentro del reservorio, es decir, la estructura de la red neuronal recurrente. Por lo general, estas ecuaciones definen las conexiones sinápticas ponderadas entre las neuronas.

La forma general de una ecuación de conectividad del reservorio podría ser:

$$W_{ij} = peso(d_{ij}) \quad (3.12)$$

Donde:

- W_{ij} es el peso sináptico entre la neurona i y la neurona j .
- d_{ij} es una medida de la distancia entre las neuronas i y j .
- $peso(d)$ es una función que asigna un peso a la conexión en función de la distancia entre las neuronas.

La función de peso y la medida de distancia son parámetros clave que afectan la topología y la eficiencia del reservorio para procesar información.

Ecuación de salida

La ecuación de salida en el modelo de reservorio generalmente se define como:

$$y(t) = W_{out}x(t) + b_{out} \quad (3.13)$$

Donde:

- $y(t)$ es el vector de salida del sistema en el tiempo t .
- W_{out} es una matriz de pesos que transforma las actividades del reservorio en la salida.
- $x(t)$ es el vector de actividades del reservorio en el tiempo t .
- b_{out} es el vector de sesgo de la salida.

Los parámetros como W_{out} y b_{out} controlan cómo se combinan las actividades del reservorio para producir la salida del sistema.

Estas ecuaciones son fundamentales para el procesamiento de señales en el RC y su comprensión es crucial para el diseño y la optimización de modelos efectivos.

3.4.5. Estudio interno de hiperparámetros

Para relacionar los hiperparámetros con las ecuaciones diferenciales del Reservoir Computing (RC) y explicar cómo afectan el comportamiento del modelo, podemos considerar los siguientes hiperparámetros comunes en la arquitectura del RC:

- **Cantidad de neuronas en el reservorio (N):** Este hiperparámetro controla el tamaño del reservorio, es decir, el número de neuronas recurrentes interconectadas en la capa del reservorio. Una mayor cantidad de neuronas puede aumentar la capacidad del reservorio para capturar la información temporal de las entradas. Matemáticamente, esto se relaciona con la dimensionalidad del estado del reservorio $\mathbf{x}(t)$ en las ecuaciones diferenciales del RC. Aumentar el número de neuronas puede conducir a una representación interna más compleja y rica en información. Matemáticamente, podemos representarlo como:

$$\mathbf{x}(t) \in \mathbb{R}^N \quad (3.14)$$

Donde N es el número de neuronas en el reservorio.

- **Conectividad del reservorio (\mathbf{W}_{res} y \mathbf{W}_{fb}):** Este hiperparámetro controla la densidad de conexiones entre las neuronas en el reservorio, definida por el radio espectral de la matriz de pesos. Puede definir cuántas conexiones se forman entre las neuronas y con qué probabilidad. Matemáticamente, la conectividad del reservorio afecta las matrices de peso \mathbf{W}_{res} y \mathbf{W}_{fb} en las ecuaciones diferenciales del RC. Un mayor grado de conectividad puede aumentar la capacidad del reservorio para procesar información compleja y dinámica.
- **Función de activación ($f(\cdot)$):** La función de activación determina cómo las entradas y los estados del reservorio se transforman en salidas. Puede ser una función lineal o no lineal, como la función sigmoide o la tangente hiperbólica. Matemáticamente, la función de activación $f(\cdot)$ en las ecuaciones diferenciales del RC controla la no linealidad de las dinámicas del reservorio. Cambiar la función de activación puede afectar la capacidad del modelo para capturar relaciones no lineales en los datos de entrada.

- **Parámetros de regularización:** Estos parámetros controlan la complejidad del modelo y ayudan a prevenir el sobreajuste. Pueden incluir la fuerza de regularización en las matrices de peso del reservorio y de salida. Matemáticamente, la regularización se puede incorporar como términos adicionales en las ecuaciones de entrenamiento del RC. Ajustar estos parámetros puede influir en la capacidad del modelo para generalizar a datos no vistos y evitar el sobreajuste.

Los parámetros de regularización influyen en \mathbf{W}_{res} y \mathbf{W}_{out} (3.15)

Donde \mathbf{W}_{out} es la matriz de pesos que transforma las actividades del reservorio en la salida del sistema.

- **Parámetro de fuga (α):** El parámetro de fuga controla la tasa a la que la actividad de las neuronas en el reservorio decrece con el tiempo. Matemáticamente, este parámetro se incluye en las ecuaciones de estado de las neuronas recurrentes como un término de fuga. Se puede expresar como:

$$\frac{dx_i(t)}{dt} = -\alpha x_i(t) + \sum_j W_{ij} f(x_j(t)) + I_i(t) \quad (3.16)$$

Donde α representa el parámetro de fuga.

- **Radio Espectral**

El radio espectral es un hiperparámetro crucial en el Reservoir Computing (RC), ya que determina la estabilidad y dinámica del reservorio. El radio espectral se define como el valor absoluto del mayor autovalor de la matriz de pesos recurrentes \mathbf{W}_{res} . Matemáticamente, el radio espectral $\rho(\mathbf{W}_{res})$ se expresa como:

$$\rho(\mathbf{W}_{res}) = \max |\lambda_i|$$

donde λ_i son los autovalores de la matriz \mathbf{W}_{res} .

El radio espectral influye directamente en la dinámica interna del reservorio. Si el radio espectral es menor que 1, las actividades de las neuronas tienden a decaer con el tiempo, lo que contribuye a la estabilidad del sistema. Si el radio espectral es mayor que 1, las actividades neuronales pueden crecer exponencialmente, llevando a inestabilidades y comportamientos caóticos. En el contexto del RC, un radio espectral adecuadamente ajustado permite que el reservorio retenga información temporal sin que las dinámicas se vuelvan inestables.

Sabemos que la dinámica del estado del reservorio $x(t)$ se describe mediante la siguiente ecuación diferencial, que incorpora el término de la matriz de pesos recurrentes \mathbf{W}_{res} :

$$\frac{dx(t)}{dt} = -\alpha x(t) + \mathbf{W}_{res} f(x(t)) + I(t)$$

En esta ecuación, el radio espectral $\rho(\mathbf{W}_{res})$ afecta el comportamiento de $\mathbf{W}_{res} f(x(t))$, influyendo en cómo las neuronas del reservorio se activan y evolucionan temporalmente.

- **Parámetro de ruido (σ):** El parámetro de ruido introduce una componente estocástica en las ecuaciones de estado de las neuronas, lo que puede ayudar a mejorar la capacidad del modelo para generalizar a nuevos datos y prevenir el sobreajuste. Matemáticamente, este parámetro se agrega como una fuente de ruido en las ecuaciones de estado de las

neuronas, y puede tener la forma de una señal de ruido blanco gaussiano. La ecuación de estado modificada con el parámetro de ruido se ve así:

$$\frac{dx_i(t)}{dt} = -x_i(t) + \sum_j W_{ij}f(x_j(t)) + I_i(t) + \sigma\xi(t) \quad (3.17)$$

Donde σ representa el parámetro de ruido y $\xi(t)$ es una variable aleatoria que sigue una distribución gaussiana con media cero y varianza unitaria.

El aumento o disminución de cada hiperparámetro puede afectar el comportamiento del modelo de diferentes maneras:

- **Cantidad de neuronas en el reservorio:** Un reservorio más grande puede capturar mejor la complejidad de las señales de entrada, pero también puede aumentar el riesgo de sobreajuste y requerir más datos para el entrenamiento.
- **Conectividad del reservorio:** Una mayor conectividad puede mejorar la capacidad del reservorio para modelar relaciones temporales complejas, pero también puede aumentar la complejidad computacional y el riesgo de overfitting.
- **Impacto del Radio Espectral en el Estado Interno del RC** Un aumento en el radio espectral tiende a hacer que el sistema sea más reactivo a las entradas y las actividades internas se amplifiquen. Esto puede mejorar la capacidad del reservorio para capturar y procesar señales complejas y dinámicas. Sin embargo, si el radio espectral es demasiado alto, puede llevar a inestabilidad y comportamiento caótico, dificultando el aprendizaje efectivo y la generalización. Disminuir el radio espectral puede hacer que el reservorio sea más estable y menos propenso a inestabilidades. Esto puede ser beneficioso para mantener una dinámica controlada y evitar el sobreajuste. Sin embargo, un radio espectral demasiado bajo puede resultar en una falta de sensibilidad a las entradas y una pérdida de la capacidad del reservorio para capturar dinámicas temporales complejas, limitando la riqueza de la representación interna.
- **Función de activación:** La elección de la función de activación puede afectar la capacidad del modelo para capturar relaciones no lineales en los datos de entrada. Algunas funciones de activación pueden introducir no linealidades más fuertes, lo que puede mejorar la capacidad de modelado del RC en datos altamente no lineales.
- **Parámetros de regularización:** Ajustar los parámetros de regularización puede ayudar a controlar el equilibrio entre el ajuste a los datos de entrenamiento y la generalización a nuevos datos. Un valor demasiado alto de los parámetros de regularización puede llevar a un modelo demasiado simplificado y un subajuste, mientras que un valor demasiado bajo puede conducir a un sobreajuste.
- **Parámetro de fuga (α):** El parámetro de fuga controla la tasa a la que la actividad de las neuronas en el reservorio decae con el tiempo. Aumentar el valor de α acelera la tasa de decaimiento de la actividad neuronal, lo que puede llevar a una rápida pérdida de información temporal en el reservorio. Por otro lado, disminuir el valor de α puede resultar en una actividad neuronal más persistente, lo que permite que el reservorio retenga información temporal durante períodos más largos. Sin embargo, un valor demasiado bajo de α puede hacer que el reservorio sea demasiado sensible a las entradas pasadas, lo que dificulta la adaptación a nuevas señales de entrada.

- **Parámetro de ruido (σ):** El parámetro de ruido introduce una componente estocástica en las ecuaciones de estado de las neuronas, lo que puede ayudar a mejorar la capacidad del modelo para generalizar a nuevos datos y prevenir el sobreajuste. Aumentar el valor de σ aumenta la magnitud del ruido en las actividades neuronales, lo que puede aumentar la capacidad del modelo para explorar diferentes estados internos y mejorar su capacidad de generalización. Sin embargo, un exceso de ruido puede dificultar la interpretación de las señales neuronales y afectar negativamente la precisión de las predicciones del modelo. Por otro lado, disminuir el valor de σ reduce la influencia del ruido en las actividades neuronales, lo que puede hacer que el modelo sea más determinista y menos propenso a sobreajustarse a datos ruidosos. Sin embargo, un valor demasiado bajo de σ puede hacer que el modelo sea menos robusto a la variabilidad en los datos de entrada y reducir su capacidad para generalizar a nuevos contextos.

PCA (Análisis de componentes principales)

PCA es una técnica estadística que transforma los datos originales en un conjunto de componentes principales ortogonales que explican la mayor variabilidad posible. Matemáticamente, PCA se define como:

$$\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T \quad (3.18)$$

donde \mathbf{X} es la matriz de datos original, \mathbf{U} y \mathbf{V} son matrices ortogonales y Σ es una matriz diagonal con los valores singulares. La transformación de PCA se realiza seleccionando los primeros k componentes principales que explican la mayor parte de la varianza en los datos.

Tensor PCA

Tensor PCA es una extensión de PCA que se aplica a datos multidimensionales (tensores) en lugar de matrices. Esta técnica es útil para manejar la estructura inherente de los datos en múltiples dimensiones. La descomposición en componentes principales de un tensor \mathcal{X} se puede definir como:

$$\mathcal{X} = \mathcal{G} \times_1 \mathbf{U}^{(1)} \times_2 \mathbf{U}^{(2)} \times_3 \cdots \times_n \mathbf{U}^{(n)} \quad (3.19)$$

donde \mathcal{G} es el núcleo del tensor y $\mathbf{U}^{(i)}$ son matrices ortogonales correspondientes a cada modo del tensor.

El uso de PCA o Tensor PCA permite reducir la dimensionalidad de la representación interna del RC, facilitando el proceso de readout y mejorando la eficiencia del modelo. La elección entre PCA y Tensor PCA depende de la naturaleza y dimensionalidad de los datos, así como de los requisitos específicos del análisis.

Capítulo 4

Materiales y métodos

4.1. Materiales

Con el objetivo de explorar la idoneidad de utilizar RC para el análisis de señales EEG, utilizaremos tanto datos sintéticos como datos reales.

4.1.1. Datos sintéticos

Para crear datos sintéticos de EEG representativos de jóvenes adultos y adultos mayores, se siguieron los siguientes pasos clave:

1. **Modelo Generativo:** Se utilizó un modelo generativo basado en procesos estocásticos, como modelos de autoregresión (AR) y procesos de Gauss, para simular la dinámica temporal y espacial de las señales EEG reales.
2. **Simulación de Electrodos:** Se generaron múltiples canales de datos sintéticos con características específicas para cada región del cerebro, variando en frecuencia y amplitud para reflejar la diversidad en la actividad cerebral.
3. **Patrones de Edad:** Se incorporaron patrones distintivos para jóvenes adultos y adultos mayores. Los jóvenes adultos presentan ondas alfa y beta prominentes, mientras que los adultos mayores muestran mayor actividad en bandas delta y theta, con ajustes en la sincronización y coherencia entre canales.
4. **Ruido Realista:** Se añadió ruido a las señales sintéticas, incluyendo artefactos como interferencias electromagnéticas y movimientos oculares, para simular condiciones más realistas en las señales EEG.

El conjunto de datos sintéticos se crea utilizando la función `generate_synthetic_eeg_data(n_subjects_per_group, n_samples_per_subject, n_channels, sr)`. En este estudio, se generan 20 sujetos jóvenes y 20 sujetos mayores, resultando en un total de 40 sujetos. Cada sujeto tiene un EEG con 10 canales, y cada canal contiene una señal de 2000 muestras procesadas con una frecuencia de muestreo de 512 Hz. Como se indica en la sección de análisis, para que los datos sean realistas, se añaden ondas asociadas a las señales EEG junto a un proceso autorregresivo y otro gaussiano, lo que permite reproducir la dinámica temporal de las señales y la interacción entre canales. Además, se añade ruido aleatorio a las señales para imitar las condiciones reales de captura de datos EEG.

n_subjects_per_group	20
n_samples_per_subject	2000
n_channels	10
sampling rate	512

La función devuelve ya una matriz tridimensional que se puede usar directamente con el modelo MyRC.

Para más detalles sobre el API del framework desarrollado, se puede acceder a la web del proyecto¹, que contiene notebooks y scripts de ejemplo para su uso². También puedes consultar el apéndice asociado en el presente documento.

4.1.2. Conjunto de datos jóvenes adultos y mayores

Los datos empleados en este estudio consisten en señales EEG (Electroencefalografía) temporales obtenidas de diferentes sujetos. Los sujetos se dividen en dos grupos principales: jóvenes adultos y adultos mayores (young/old). Las señales EEG fueron recopiladas utilizando sistemas de registro EEG estándar que incluyen múltiples canales para capturar la actividad eléctrica del cerebro en distintas regiones.

En nuestro problema, disponemos de 47 archivos (23 archivos de sujetos Young y 24 de sujetos Old). Cada uno conteniendo datos EEG de un sujeto. Cada registro EEG consiste en 73 canales, con un mínimo de 164,352 muestras por canal. Cada archivo tiene un número específico de muestras, adquiridas a una frecuencia de 512 kHz. Durante el preprocesamiento de los datos, se reducirá la frecuencia de muestreo a un factor de 4 y se limitará la señal al tamaño mínimo de 39,680 muestras.

Para aplicar Reservoir Computing ESN, procesaremos las señales mediante la creación de datasets con señales procesadas y una división en conjuntos de canales. Esta división puede realizarse utilizando diferentes cortes anatómicos, como el sagital, que divide en hemisferio derecho e izquierdo, o el coronal, que proporciona ejemplos de listados de canales. Para el trabajo, hemos decidido utilizar todos los canales disponibles. Para la comparación de resultados, emplearemos únicamente los canales del hemisferio izquierdo. El análisis más detallado, que implicará identificar los canales que muestran una función cognitiva más distintiva entre los dos grupos de sujetos en estudio, se dejará para un trabajo futuro.

4.2. Métodos

4.2.1. Desarrollo de la API de RC en python

Se distinguen tres fases clave que se identifican en la Figura 4.1:

¹<https://github.com/jogugil/MyRC/wiki>

²https://github.com/jogugil/MyRC/blob/main/synthetic_eeg_v10.ipynb

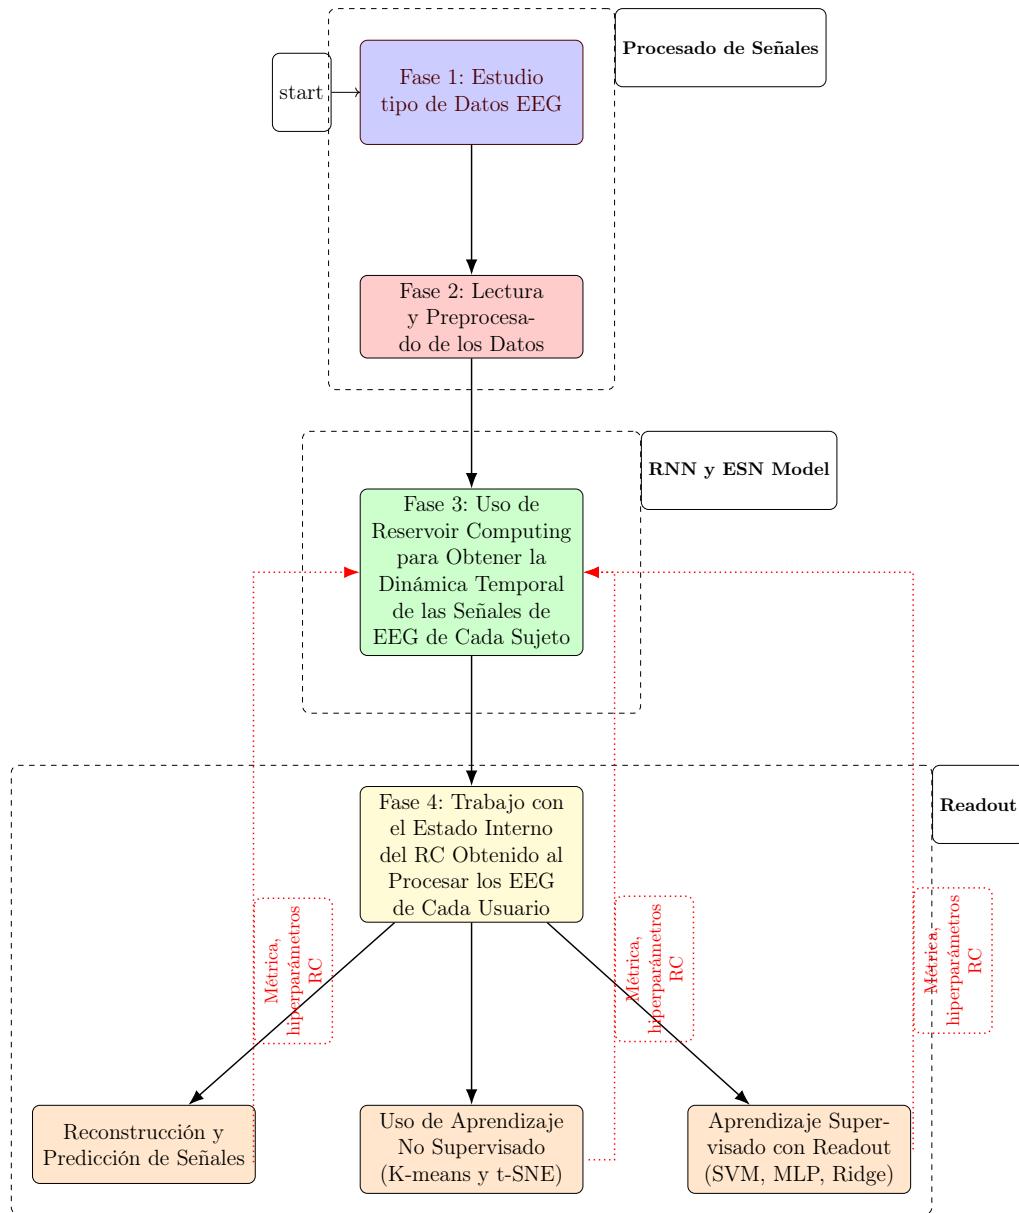


Figura 4.1: Diagrama principal del proceso de desarrollo de RC ESN para señales EEG

Para cada una de estas fases, se desarrollará una librería específica que incluirá las clases, objetos y funciones necesarias para su implementación. Para contener estas clases y funciones se crearan se crea un módulo denominado `/base` que contendrá todos los paquetes (librerías Python) que se utilizarán en el proyecto.

La implementación del Reservoir Computing (RC) se ha dividido en dos objetos: uno que define la arquitectura base de un RC y otro que implementa la lógica específica de un Echo State Network (ESN). De esta manera, si queremos modificar la lógica para procesar la entrada de otra forma, podríamos hacerlo fácilmente. Además, si deseamos explorar arquitecturas más complejas como deepESN, esta estructura modular nos permitirá adaptarnos sin grandes cambios.

Para lograr esto, crearemos dos clases independientes. Una clase definirá un objeto que mantenga la arquitectura básica de cualquier RC, con una capa de entrada, una capa interna o reservorio, y una capa de salida. La segunda clase instanciará un objeto ESN, que permitirá que el RC se comporte como un ESN, procesando la información como una serie temporal y capturando su dinámica temporal. De esta forma, en el futuro, podremos modificar la lógica del reservorio interno sin afectar la arquitectura estándar del RC.

1. Separación de la arquitectura y la lógica
2. Modularidad
3. Facilidad de adaptación
4. Instanciación de objetos específicos
5. Mantenimiento de la arquitectura estándar

Tanto la clase MyESN como MyRC y el módulo tensorPCA.py se incluye en un módulo creado para ello denominado `MyRC.py`.

Para más detalles sobre el API del framework desarrollado, incluyendo notebooks, scripts de ejemplo, código fuente y documentación, consulte el sitio web del proyecto³ y el repositorio GitHub⁴. Estos recursos incluyen ejemplos prácticos y una guía completa sobre el uso del framework en diferentes contextos de aplicación.

Para implementar y validar el framework se utilizan los datos sintéticos. Para ello se aplica la reconstrucción y predicción de las señales, un análisis no supervisado con agrupamiento jerárquico, gráficos de recurrencia y potencial de memoria y un análisis supervisado mediante modelos aprendizaje automático.

4.2.2. Preprocesamiento de los datos reales

El framework desarrollado contiene un módulo en Python llamado `eeg.py` específicamente para el procesamiento de señales EEG. Este módulo incluye la clase `EEG_data` y funciones auxiliares diseñadas para automatizar los procesos necesarios en el manejo de datos EEG. Estas funciones están destinadas a trabajar desde la manipulación inicial de los datos de los sujetos hasta la creación de una matriz tridimensional que organiza la información por sujetos, número de muestras y número de canales.

La lectura y manipulación de los ficheros que contienen los datos de EEG para cada sujeto se realiza mediante la librería MNE⁵. Dentro de este marco, se ha desarrollado la clase `EEG_Data`, la cual se encarga de gestionar los datos crudos del archivo, también conocidos como datos raw". Esta clase proporciona funciones básicas para la lectura, filtrado y eliminación de artefactos, utilizando el API de MNE para realizar estas acciones de manera eficiente y cumplir con los objetivos específicos de cada función implementada.

Las señales EEG suministradas están en su forma cruda, lo que implica que deben pasar por un proceso de preprocesamiento antes de poder ser analizadas. Este preprocesamiento incluye varias etapas esenciales para asegurar la calidad de los datos. Las etapas que se pueden aplicar son:

- **Filtrado de señales** Etapa obligatoria. Se aplica un filtro paso bajo, por debajo de los 50 Khz para eliminar el ruido por red eléctrica y sus armónicos (100KHz, 150KHZ, etc...). Este filtro suele eliminar también ruido de alta frecuencia. Además, se aplica un filtro paso alto con una frecuencia de corte muy baja (0.2), eliminando así un posible ruido de frecuencia extremadamente baja.

³<https://github.com/jogugil/MyRC/wiki>

⁴<https://github.com/jogugil/MyRC>

⁵<https://mne.tools/stable/index.html>

- **Eliminación de artefactos.** Método opcional. Se ha utilizado la librería MNE-Python, que proporciona herramientas avanzadas para la detección y eliminación de artefactos mediante técnicas como el Análisis de Componentes Independientes (ICA).
 - Asociado a **eventos de movimientos**. Se utiliza el método ICA que proporciona el API mne. Para ello asociamos los canales externos [EX..] y de movimiento [alto, bajo, derecha, izquierda] a los tipos de canal ECG y EOG respectivamente. Posteriormente el api realiza una correlación de los eventos encontrados en dichas señales, eliminando así los segmentos asociados.
 - Asociado a **interacción entre electrodos**. En este caso usamos el método ICA, también del API mne. Se centra en calcular los histogramas de las amplitudes de las componentes independientes asociadas a la señal procesada. Y se marca como componente con artefacto si la densidad de dicho hidrograma no se acerca a una distribución normal. Empleamos el test de chi.cuadrado. y/o la similitud entre la normal asociada al histograma.
- **Segmentación de datos:** Para el experimento donde el estudio se realiza a través de la extracción de características se debe segmentar las señales temporales. Las señales EEG se segmentan en ventanas temporales para su análisis. Esta segmentación permite una mejor gestión de los datos y facilita la aplicación de técnicas de procesamiento y análisis posteriores.
- **Extracción de características:** El framework desarrollado permite la extracción de características de las señales EEG. Esto incluye la comparativa de cómo el modelo RC-ESN procesa estas señales utilizando características extraídas en lugar de las señales directas de cada canal EEG del sujeto. Cada señal en el EEG representa la actividad neuronal de una región de la corteza cerebral, obtenida a través de electrodos del interfaz BCI utilizados.

4.2.3. Procesamiento de datos reales con el framework del RC

El siguiente paso en nuestro análisis es aplicar el Reservoir Computing (RC) a las señales EEG preprocesadas. El RC es una técnica poderosa para analizar señales temporales, ya que puede capturar patrones dinámicos complejos en los datos. Al parametrizar adecuadamente el RC, podemos utilizar los transitorios internos generados por el RC para entrenar modelos de clasificación o clustering que diferencien entre los dos grupos de sujetos. Los pasos que se han seguido en este estudio son los siguientes:

- **Configuración del RC:** El RC se configura con hiperparámetros específicos que controlan su dinámica interna. Estos parámetros deben ajustarse cuidadosamente para optimizar la captura de patrones en las señales EEG.
- **Modelos de readout:** Utilizamos diferentes modelos de readout como regresión ridge, una capa totalmente conectada (mlpClassifier) o un modelo de maquina vector soporte (SVM) para realizar un proceso de clasificación sobre la representación interna del RC. Estos modelos se pueden parametrizar con los parámetros del diccionario de configuración que aporta el API del modelo RC-ESN.⁶ Es crucial considerar los hiperparámetros introducidos en la configuración del RC para la capa de readout al aplicar la clasificación.

⁶Para más detalles y ejemplos sobre la aplicación de estos conceptos, consulta el proyecto en línea disponible en <https://github.com/jogugil/MyRC>.

Estos parámetros pueden ajustarse según los resultados de la clasificación, permitiendo al RC-ESN volver a entrenarse y validarse. Una buena estrategia es recolectar las representaciones internas del modelo RC-ESN en las fases de entrenamiento y validación, y luego realizar una búsqueda en rejilla (*grid search*) independiente para el modelo de readout deseado. Una vez obtenidos los hiperparámetros, se pueden introducir en los parámetros de configuración del RC-ESN para la capa de readout seleccionada. De esta manera, es posible ajustar la capa de readout externamente al modelo RC-ESN. Un ejemplo detallado de cómo proceder está disponible en el repositorio del proyecto.⁷

- **Análisis de resultados:** Una vez que el modelo de readout está entrenado, analizamos los resultados para identificar los patrones dinámicos que distinguen entre jóvenes adultos y mayores. Este análisis nos permitirá evaluar la efectividad del RC-ESN y los modelos de readout en la identificación de diferencias significativas en la actividad cerebral entre los dos grupos de sujetos. Como se indica en el trabajo, se han introducido unos modelos de aprendizaje automático básicos que pueden ser optimizados de forma externa con las representaciones internas de entrenamiento y validación. Del mismo modo, se puede utilizar otro modelo de aprendizaje automático para clasificación más sofisticado con dichas representaciones internas. Y que evaluarían de forma externa, pero de igual manera, la capacidad del modelo RC-ESN para reconocer patrones de dinámica temporal base para estos dos grupos de sujetos.

Tras examinar todas las partes cruciales del trabajo, resumimos el proyecto con el diagrama de procesos básicos que se presenta en la Figura 4.2. Este diagrama ilustra los pasos fundamentales que debemos llevar a cabo.

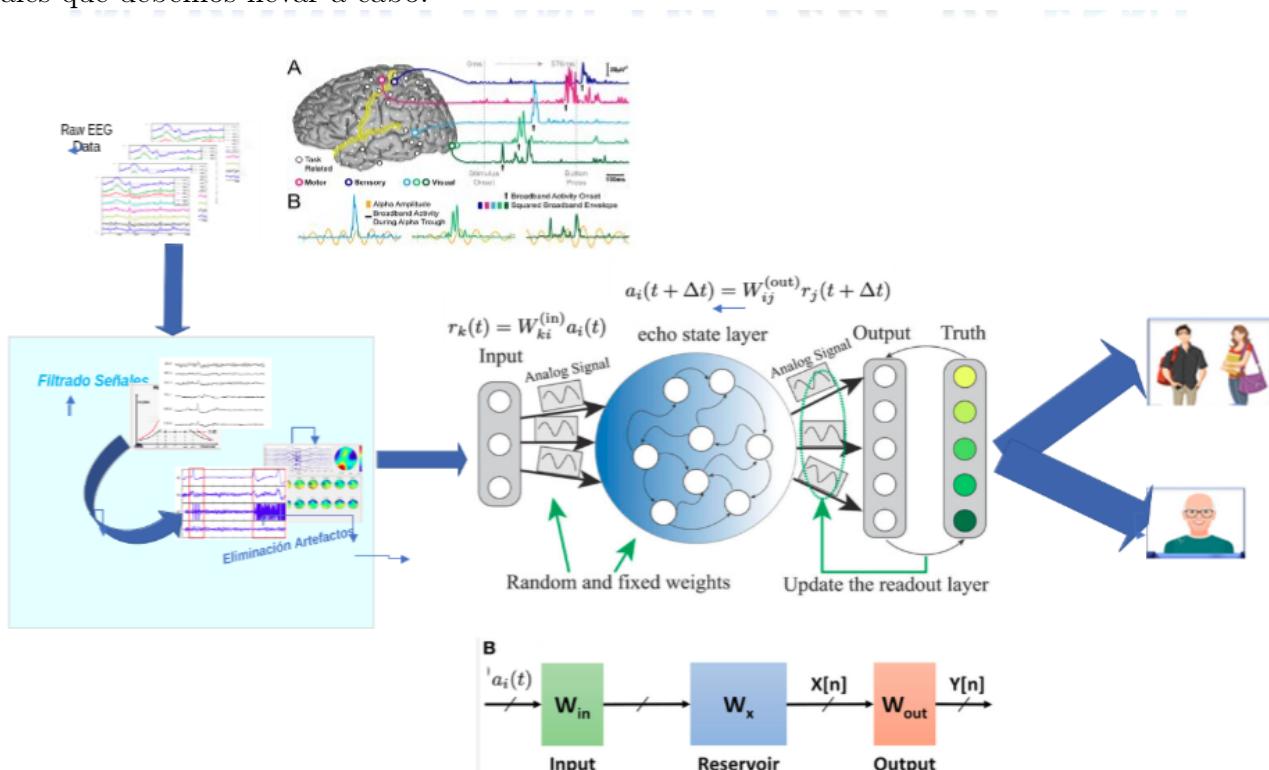


Figura 4.2: Estudio Señales EEG jóvenes adultos vs Mayores (construcción propia y Fuente[4])

⁷En la web del proyecto: <https://github.com/jogugil/MyRC>

4.3. Evaluación de resultados

Para evaluar los resultados obtenidos mediante técnicas no supervisadas y encontrar patrones distintivos entre jóvenes adultos y mayores recolectados por el RC, nos centraremos en dos medidas ampliamente utilizadas en neurociencia y procesamiento de señales EEG: los gráficos de recurrencia y la memoria de potencia

4.3.1. Matriz de similitud

En este estudio, empleamos la matriz de similitud para analizar la similitud en la dinámica temporal de la actividad neuronal entre los sujetos en estudio [70], [71]. Esta matriz se calcula utilizando la distancia coseno entre los estados internos de cada sujeto, obtenidos del modelo Reservoir Computing (RC-ESN). Los estados internos de cada sujeto encapsulan los patrones internos de la dinámica temporal de su actividad neuronal, proporcionando una representación detallada y específica de cómo evoluciona su actividad cerebral en el tiempo.

La matriz de similitud nos permite visualizar y cuantificar las relaciones entre estos patrones internos de dinámica temporal. La similitud entre los estados internos de los sujetos i y j se calcula como:

$$\text{Similitud}(i, j) = 1 - \frac{\mathbf{x}_i \cdot \mathbf{x}_j}{\|\mathbf{x}_i\| \|\mathbf{x}_j\|}$$

donde \mathbf{x}_i y \mathbf{x}_j son los vectores de estados internos de los sujetos i y j respectivamente, $\mathbf{x}_i \cdot \mathbf{x}_j$ representa el producto punto y $\|\mathbf{x}_i\|$ es la norma del vector \mathbf{x}_i .

Al comparar las distancias coseno entre los estados internos de diferentes sujetos, podemos identificar qué sujetos presentan patrones de actividad neuronal similares. Esto es crucial para nuestro objetivo, ya que deseamos comprender cómo varía la actividad cerebral en diferentes grupos etarios y cómo estas variaciones se relacionan con la cognición.

Interpretar la matriz de similitud nos permitirá identificar agrupaciones de sujetos con patrones de dinámica temporal similares, lo que puede indicar similitudes en sus procesos cognitivos o en su estado neuronal basal. Por ejemplo, sujetos con alta similitud en sus estados internos podrían compartir características cognitivas o estar en etapas similares de envejecimiento neuronal. Este análisis nos aportará información valiosa sobre las diferencias y similitudes en la función cerebral entre jóvenes adultos y adultos mayores, ayudándonos a avanzar en el entendimiento de cómo la edad afecta la actividad neuronal y la cognición.

4.3.2. Gráficos de recurrencia

Para visualizar patrones distintivos entre jóvenes adultos y mayores capturados por la representación interna del modelo RC_ESN, emplearemos gráficos de recurrencia. Estos gráficos nos permitirán identificar posibles patrones retenidos por el modelo [72], [73], [74].

La idea es verificar la existencia de patrones similares entre sujetos jóvenes adultos y distintivos entre éstos y los sujetos mayores.

Utilizar gráficas recurrentes con la salida de tu ESN es una excelente manera de visualizar y analizar los patrones dinámicos en tus señales temporales. `pyunicorn` y `scikit-mobility` son herramientas útiles que pueden facilitar este análisis, proporcionando visualizaciones claras y detalladas de las recurrencias en tus datos.

¿Qué es una gráfica de recurrencia?

Una gráfica recurrente es una representación bidimensional que muestra los momentos en los que un sistema dinámico retorna a estados similares. Se basa en el concepto de "recurrencia", que es la tendencia de los sistemas dinámicos a visitar los mismos estados o estados similares a lo largo del tiempo.

Para una serie temporal ($\{x_i\}_{i=1}^N$), la gráfica recurrente se define como una matriz (R) donde cada elemento ($R_{i,j}$) se determina de la siguiente manera:

$$R_{i,j} = \Theta(\epsilon - \|x_i - x_j\|), \quad (4.1)$$

Aquí:

- x_i y x_j son los puntos en el espacio de fases (generalmente reconstruido mediante el método de retardos).
- $\|\cdot\|$ es una norma (comúnmente la norma euclídea).
- ϵ es un umbral de recurrencia.
- Θ es la función escalón de Heaviside, que es 1 si el argumento es positivo y 0 en caso contrario.

Reconstrucción del espacio de fases: Si los datos originales están en una serie temporal unidimensional, se reconstruye el espacio de fases utilizando el método de retrasos (delay embedding):

$$\mathbf{x}(t) = [x(t), x(t + \tau), x(t + 2\tau), \dots, x(t + (m - 1)\tau)], \quad (4.2)$$

Donde τ es el retraso de tiempo y m es la dimensión de incrustación.

Construcción de la matriz de recurrencia: Con el espacio de fases reconstruido, se calcula la matriz de recurrencia usando la definición mencionada.

Visualización: La matriz de recurrencia se visualiza como una imagen donde los valores de 1 (o verdaderos) se representan como puntos negros y los valores de 0 (o falsos) se representan como puntos blancos. Esta visualización aporta las siguientes conclusiones:

- **Diagonales:** Indican que el sistema sigue un patrón similar en el tiempo, mostrando periodicidad o recurrencia.
- **Verticales/horizontales:** Sugieren estados estacionarios o lentos cambios en la dinámica.
- **Blancos:** Áreas sin recurrencia, indicando transiciones o cambios en el estado del sistema.
- **Estructuras complejas:** Pueden revelar dinámicas caóticas o comportamientos no lineales complejos.

4.3.3. El Potencial de memoria

El potencial de memoria se define como el instante de tiempo t en el cual la distancia euclíadiana entre el estado inicial y_0 y el estado y_t de la serie temporal cae por debajo de un umbral de tolerancia ϵ :

$$t = \min \{t \in \mathbb{N} \mid \|y_t - y_0\| < \epsilon\} \quad (4.3)$$

Donde:

- y_0 es el estado inicial de la serie temporal.
- y_t es el estado en el tiempo t .
- ϵ es el umbral de tolerancia para considerar la repetición del patrón.

Resultados del cálculo del potencial de memoria:

El resultado obtenido para cada representación de serie temporal es un valor de t , indicando el primer momento en el cual se detecta que el sistema retorna a un estado similar al inicial dentro del umbral especificado [72],[75],[76], [77]. Este valor proporciona insights sobre la duración de los patrones recurrentes en los datos de EEG, destacando diferencias significativas entre grupos etarios y permitiendo una evaluación detallada de la estabilidad temporal de las representaciones generadas por el modelo RC_ESN.

4.3.4. Búsqueda automática de hiperparámetros

Dado el considerable esfuerzo requerido para encontrar el valor óptimo de los hiperparámetros que permitan agrupar a los sujetos en las dos clases de población, se han implementado dos scripts para abordar esta tarea de manera automatizada. Aunque los resultados del trabajo no se han obtenido directamente con estos scripts, estos se han desarrollado para complementar el framework y facilitar su uso en investigaciones futuras. Los scripts utilizan métodos similares al enfoque Gridsearch, empleando técnicas de optimización como los algoritmos genéticos y la optimización bayesiana.

- **Probabilidad Bayesiana:** Se utiliza la librería **scikit-optimize**. La librería scikit-optimize proporciona herramientas avanzadas para la optimización de hiperparámetros mediante técnicas de optimización secuencial basadas en modelos probabilísticos. Entre estas herramientas, destaca la función `gp_minimize`, la cual se fundamenta en la optimización bayesiana utilizando procesos gaussianos para explorar de manera eficiente el espacio de búsqueda de los hiperparámetros. Este enfoque se basa en la construcción de un modelo probabilístico de la función objetivo (generalmente una métrica de rendimiento como la precisión o el error) y utiliza la información obtenida de las evaluaciones previas para dirigir la búsqueda hacia regiones prometedoras del espacio de hiperparámetros.

Esta librería se basa en la función `gp_minimize` que realiza una búsqueda adaptativa iterativa, ajustando continuamente el modelo probabilístico a medida que se realizan nuevas evaluaciones de la función objetivo. De este modo, no solo explora de manera sistemática el espacio de hiperparámetros, sino que también aprovecha la incertidumbre del modelo para equilibrar la exploración (buscar nuevas áreas) y la explotación (buscar áreas con buenos resultados previos). Esto permite encontrar configuraciones de hiperparámetros que optimicen el rendimiento del modelo, incluso en espacios de búsqueda complejos

y de alta dimensionalidad. A esta función se le pasa el espacio y dominio de los posibles valores para cada uno de los hiperparámetros a encontrar y la función de evaluación. Esta función de evaluación devolverá el valor de la métrica asociada al clústering realizado en cada instante con los valores de los parámetros encontrados en ese momento. Por lo que de todos los parámetros asociados al diccionario de configuración creado para el API del modelo RC. Se escogen aquellos que se desean evaluar y se crea un espacio de dominios de posibles valores:

```
space = [
    Real(0.1, 0.5, name='spectral_radius'),
    Real(0.1, 0.9, name='leak'),
    Real(0.1, 1.0, name='input_scaling'),
    Integer(100, 1000, name='n_internal_units'),
    Integer(2, 10, name='n_dim')
]
```

Un ejemplo de script centrado en esta técnica se tiene en el archivo `rc_bayes_v00.py` almacenado en el proyecto MyRC de Github⁸.

Otra opción de algoritmos con probabilidad bayesiana para la búsqueda de los valores óptimos de los hiperparámetros del modelo es usar la librería `optuna`, Un ejemplo subido a la web del proyecto en GitHub es `myrc_parameter_search`. Este notebook busca los ficheros de Youngers y Olders a partir del valor de los parámetros de configuración del entorno (se aplica el método ICA para eliminar artefactos o no se aplica, se utiliza extracción de características o se usa las señales EEG directamente, etc..). Esta librería es más rápida y necesita menos memoria RAM para su uso, lo que le hace ser más eficiente y eficaz par dicho cometido.

- **Algoritmo Genético:** Se utiliza la librería `deap`. Esta librería aporta todos los interfaces para poder implementar las acciones de creación de nuevas poblaciones, mutaciones y a función fitness sobre la cual se basará para encontrar la mejor población. Para nuestro caso un individuo de la población será un vector con aquellos hiperparámetros cuyos valores óptimos deseamos encontrar. En cada población se tendrá unos valores determinados dentro de un intervalo de dominio posible de valores. En cada mutación se modificará los valores de estos hiperparámetros según las funciones de mutación que se haya implementado.

Para obtener el valor de fitness se utiliza la métrica de accuracy o f1 sobre el clustering realizado. Unos scripts tipo son (`rc_ga_v00.py` y `rc_ga_v10.py`) que se encuentran en el proyecto subido a Github⁹.

⁸Disponible en <https://github.com/jogugil/MyRC>

⁹<https://github.com/jogugil/MyRC>

Capítulo 5

Resultados

5.1. Datos sintéticos

5.1.1. Reconstrucción y predicción

Con los estados internos obtenidos para cada sujeto al final del procesamiento del RC, reconstruiremos la señal resultante para cada canal del EEG de cada sujeto. Lo ideal es que las señales sean lo más parecidas posibles, demostrando que el RC es capaz de capturar la dinámica temporal de las series procesadas, logrando una reconstrucción muy similar. Es importante tener en cuenta que en los datos sintéticos hemos añadido ruido, y deseamos estudiar la robustez del RC ante dicho ruido.

Utilizaremos un procedimiento similar para calcular las predicciones de una porción futura de la señal. Para ello, predecimos el segmento temporal deseado, utilizando como valor Y la porción temporal de la señal original. Es decir, tomaremos una señal original de un cierto canal y la dividiremos en datos de entrenamiento y predicción. Con la parte de entrenamiento entrenaremos un modelo de Machine Learning, utilizando la porción de predicción como `y_true` para la posterior predicción.

Para reconstruir el EEG de cada sujeto, hemos optado por realizar una simple regresión Ridge. Una vez entrenado, con los parámetros que devuelve la regresión podemos reconstruir las señales de cada canal y con la función `predict` predicaremos la porción de señal original que hemos cortado para dicho cometido.

Evaluaremos la calidad de la reconstrucción de manera visual, representando en una gráfica tanto la señal original como la señal reconstruida (Figura 5.1). Posteriormente, utilizaremos el RMSE y la coherencia como métricas. Se espera un RMSE bajo y una alta coherencia en la reconstrucción, lo cual indicaría que el RC ha capturado correctamente los patrones dinámicos de las series temporales procesadas.

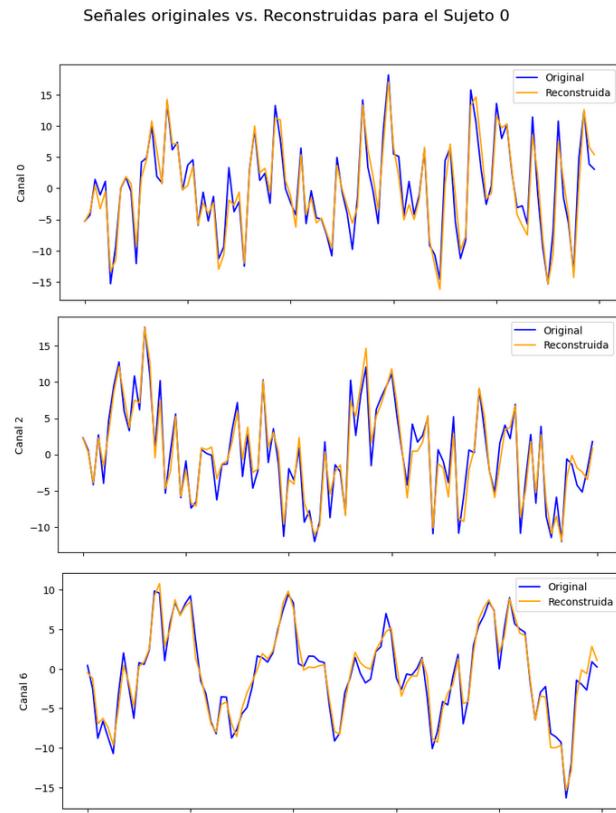


Figura 5.1: Reconstrucción de señales del EEG para el sujeto 0

Visualmente vemos que la reconstrucción es casi perfecta, viendo como la señal reconstruida se solapa con la original. En teoría, cuando usemos datos reales, y debido a la gran cantidad de ruido presente en los datos EEG y las interacciones entre canales (electrodos) del BCI, las señales al reconstruirse no deben ser del todo perfectas. Aunque en los datos sintéticos hemos introducido ruido, y dos procesos que simulan la dinámica temporal y la interacción entre canales, se pueden encontrar de forma rápida los hiperparámetros óptimos para obtener una predicción casi perfecta. En los casos de datos reales veremos que esta situación es idílica y tenemos muchísimos dolores de cabeza, primero para encontrar los hiperparámetros adecuados y segundo para obtener unos resultados tan óptimos

Aunque vemos visualmente un solapamiento casi perfecto (Figura 5.1), utilizaremos una métrica para comparar series temporales como es la **coherencia**. La coherencia es una medida estadística que evalúa la relación lineal y la sincronización temporal entre dos series temporales. En el contexto del EEG (Electroencefalografía), aunque se suele aplicar para determinar la sincronización o relación lineal entre las señales de dos canales diferentes en un mismo EEG, lo cual es crucial para entender cómo diferentes regiones del cerebro están interactuando durante actividades cognitivas específicas. En nuestro caso la utilizaremos para comparar la señal original con la reconstruida y comprobar el porcentaje de fidelidad de la reconstrucción. Y por tanto, calcular la bondad del modelo RC_ESN para obtener los patrones de las señales que permitan una reconstrucción y predicción óptima. La coherencia de los canales del EEG del sujeto seleccionado se muestra en la (Figura 5.2).

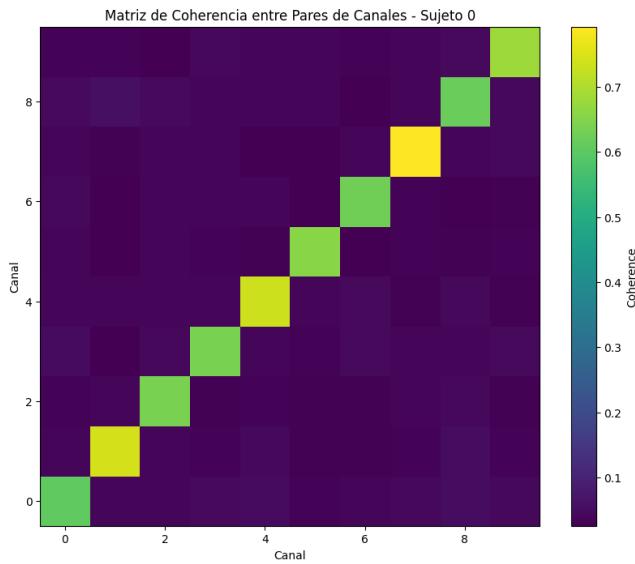


Figura 5.2: Matriz Coherencia para la reconstrucción de los datos sintéticos

Vemos que la coherencia no llega a ser perfecta, esto se debe al ruido e interacciones entre los canales. Utilizaremos dicha métrica también para el caso de los datos reales.

5.1.2. Resultados del análisis no supervisado

En este enfoque, buscamos desarrollar un modelo de aprendizaje no supervisado que utilice la representación interna del modelo RC_ESN para obtener clústers basados en los patrones de la dinámica temporal de las señales de EEG de cada sujeto. Esperamos que el modelo pueda identificar una configuración con dos clústers distintos y homogéneos, donde un clúster agrupe a los sujetos jóvenes adultos y otro a los mayores. Para evaluar la calidad de los clústers y modelos no supervisados, utilizaremos medidas como la homogeneidad, la matriz de confusión y las métricas asociadas a la curva ROC como son el accuracy y el F1-score. Estas métricas nos permitirán determinar la coherencia interna de los clústers y su capacidad para discriminar entre sujetos jóvenes adultos y mayores, dado que conocemos las etiquetas de edad de cada sujeto.

Para lograr esto, primero calculamos la distancia coseno y representamos la matriz de similitud de la representación interna del RC para cada sujeto.

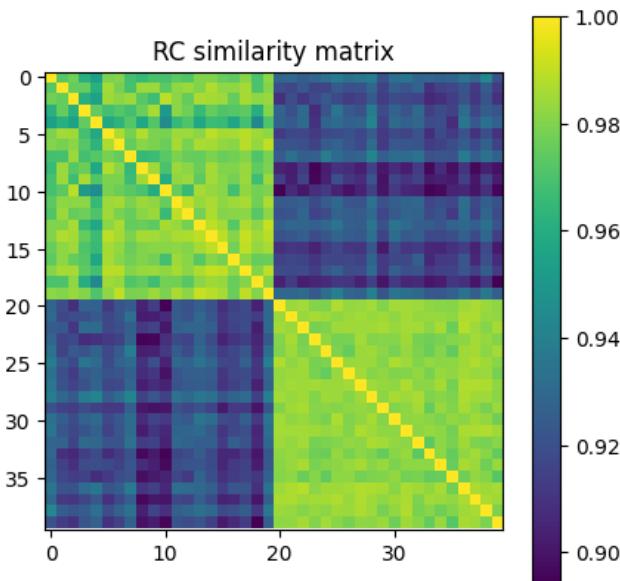


Figura 5.3: Matriz Similitud representación interna del RC_ESN([0-19]:Sujetos jóvenes adultos; [20-40] sujetos mayores).

La matriz de similitud revela dos agrupamientos distintos a lo largo de la diagonal, separando claramente a los sujetos jóvenes adultos de los mayores. Esto sugiere que el modelo RC_ESN es efectivo para distinguir las dinámicas temporales únicas entre estos grupos de edad. Además, dentro del grupo de jóvenes adultos, se observan variaciones sutiles que podrían reflejar diferencias individuales en las señales EEG, posiblemente relacionadas con la plasticidad neuronal más pronunciada en este grupo.

La homogeneidad observada en los clústers de sujetos mayores en la matriz de similitud sugiere una actividad cerebral más estable y uniforme en comparación con los jóvenes adultos. Esta cohesión puede atribuirse a la disminución de la plasticidad neuronal con la edad, lo que resulta en patrones de señales EEG más consistentes entre los individuos mayores. Estos hallazgos resaltan la importancia de considerar la plasticidad neuronal como un factor clave en la variabilidad de las señales EEG entre diferentes grupos de edad.

En conjunto, estos resultados subrayan la capacidad del modelo RC_ESN para capturar y diferenciar las características temporales complejas de las señales EEG en función de la edad. La mayor heterogeneidad en los jóvenes adultos podría indicar una adaptabilidad neuronal más alta, mientras que la homogeneidad en los mayores podría reflejar una menor capacidad de cambio neuronal. Estos insights son fundamentales para comprender cómo evolucionan las señales EEG a lo largo de la vida y para investigar posibles implicaciones en el envejecimiento y la plasticidad cerebral.

Los datos sintéticos utilizados en este estudio han demostrado ser efectivos para modelar y simular características relevantes de las señales EEG reales. Esto se evidencia por la capacidad de estos datos sintéticos para reflejar patrones similares a los que se esperarían encontrar en datos EEG auténticos. Este enfoque valida la metodología utilizada para generar los datos sintéticos, proporcionando una base sólida para investigaciones futuras en el campo de la neurociencia computacional.

La clara separación observada entre los grupos de edad en la representación de la matriz de similitud confirma la eficacia del modelo RC_ESN en la identificación de patrones significativos en datos EEG. Esta dinámica temporal capturada por el modelo se revela como un indicador robusto de las diferencias relacionadas con la edad en las señales EEG, destacando su relevancia tanto en datos sintéticos como en posibles aplicaciones con datos reales. Además, el uso de

medidas como la distancia coseno y la representación en un espacio de similitud facilita la visualización intuitiva de estas diferencias, proporcionando un punto de partida valioso para la implementación de técnicas avanzadas de clustering que podrían mejorar la clasificación detallada de los sujetos.

Posteriormente, esta distancia se utilizará para aplicar tanto un modelo de clustering jerárquico como un modelo de k-means, evaluando la eficacia de cada uno. Hacer hincapié que estas técnicas de clustering pueden separar adecuadamente estos grupos, incluso cuando hay alta disimilitud dentro de cada grupo, como es el caso que nos atañe.

En este problema, tenemos una matriz de similitud con 40 sujetos, donde los primeros 20 son jóvenes adultos y los siguientes 20 son mayores. El objetivo es entender cómo las técnicas de clustering pueden separar adecuadamente estos dos grupos, incluso cuando hay alta disimilitud dentro de cada grupo.

Al analizar los resultados del clustering jerárquico, se observa que se logró una clasificación perfecta con una precisión, recall y F1-score de 1.00 para ambas clases (jóvenes adultos y mayores). Esto indica una separación clara y efectiva de los grupos basada en las características de las señales EEG. La alta precisión y recall sugieren que el método de clustering jerárquico pudo capturar de manera precisa las similitudes y diferencias entre los grupos de sujetos. Estos resultados son alentadores y respaldan la capacidad del método utilizado para segmentar adecuadamente los datos sintéticos basados en la dinámica temporal de las señales EEG simuladas.

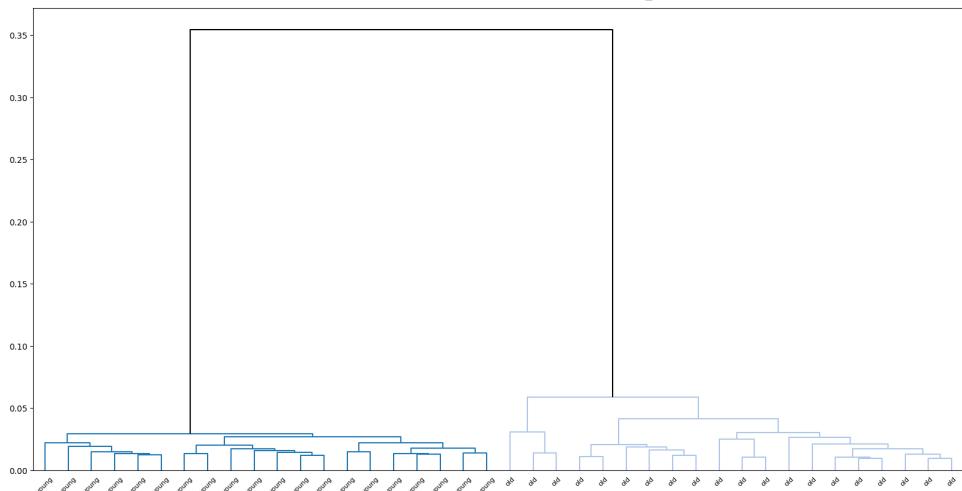


Figura 5.4: Denograma del Clúster jerárquico para los datos EEG sintéticos([0-19]:Sujetos jóvenes; [20-40] sujetos mayores).

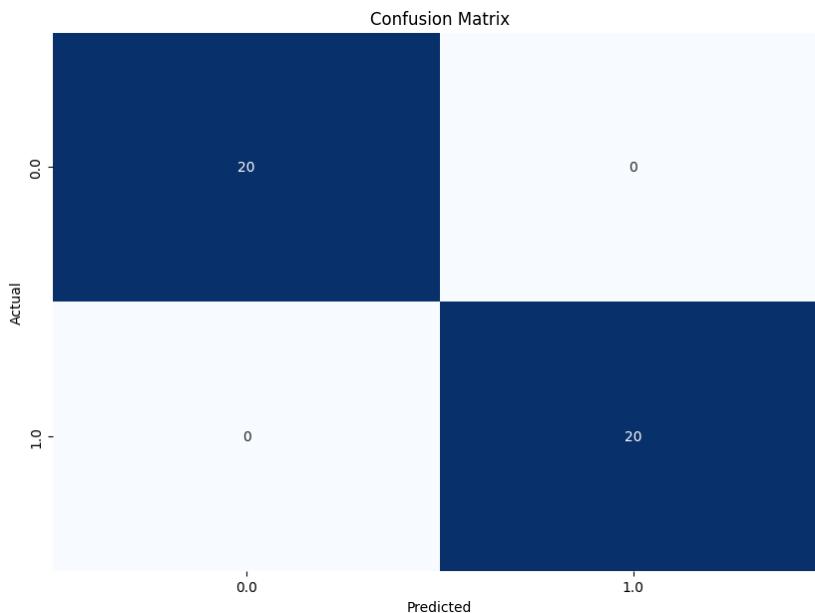


Figura 5.5: Matriz Confusión Resultados de clúster jerárquico sobre datos sintéticos(0:Grupo jóvenes adultos; 1: Grupo Mayores).

Aunque los resultados obtenidos con datos sintéticos son ideales y muestran una clasificación perfecta con métricas de 1.00 en precisión, recall y F1-score, es importante destacar que estos resultados pueden no ser replicables con datos reales. En la práctica, obtener métricas tan altas dependerá de una configuración óptima de hiperparámetros y de la complejidad inherente de los datos reales, que pueden presentar variabilidades y ruidos no presentes en los datos sintéticos.

La validez de los datos sintéticos radica en su utilidad para implementar y validar métodos y procesos asociados al trabajo, preparándose así para enfrentar datos reales. Aunque los hiperparámetros óptimos pueden diferir entre los datos sintéticos y los reales, la experiencia ganada en la implementación y evaluación con datos sintéticos proporciona una base sólida para abordar y ajustar estos parámetros de manera efectiva en aplicaciones prácticas con datos EEG reales.

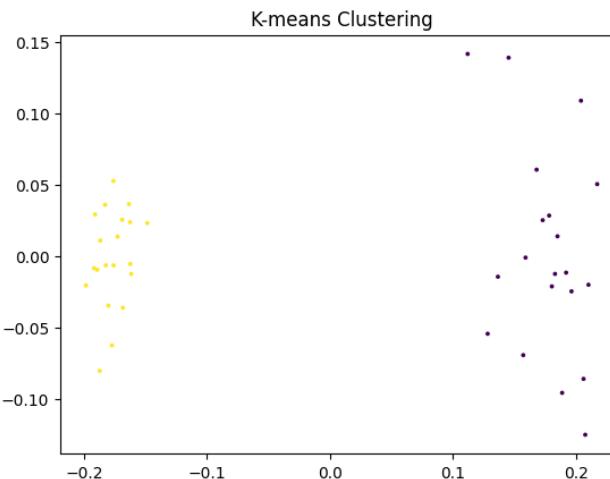


Figura 5.6: Representación Kmeans de los datos sintéticos

Nuevamente, con el método KMeans se obtuvieron resultados ideales similares a los obtenidos con el clustering jerárquico, con métricas de precisión, recall y F1-score perfectas (1.00). Estos resultados refuerzan las conclusiones previas obtenidas con el clustering jerárquico, destacando la efectividad del método en la clasificación de los datos sintéticos utilizados en este estudio.

Además, para validar los patrones capturados por la representación interna del RC, emplearemos técnicas como t-SNE y otros modelos no supervisados para verificar si pueden representarse adecuadamente con dos componentes, evaluando la varianza explicada por estas componentes.

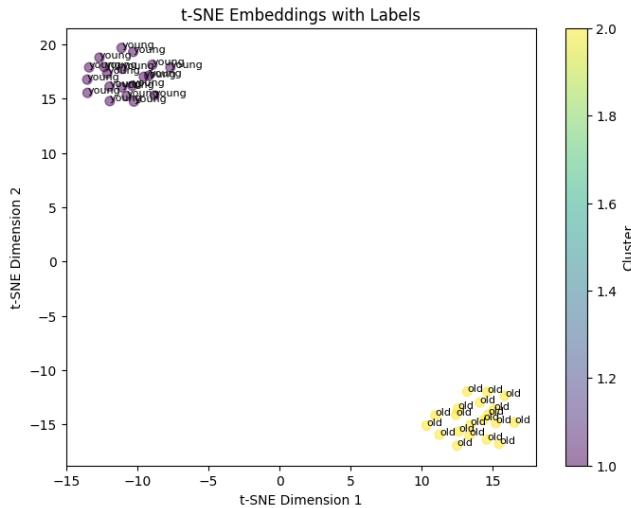


Figura 5.7: Resultado T-SNE de datos sintéticos para las dos componentes

Con un Coeficiente de Silhouette promedio de 0.9275074, se evidencia que los clústers formados en el análisis poseen una estructura interna cohesiva y están adecuadamente distanciados unos de otros en el espacio de características.

Las diferentes pruebas realizadas concluyen que la distribución de la varianza explicada por los componentes principales puede servir como un indicador de la calidad y homogeneidad del agrupamiento en los datos. Un agrupamiento fuerte y bien definido resultará en pocos componentes principales explicando la mayor parte de la varianza, mientras que un agrupamiento débil y menos homogéneo requerirá más componentes para explicar la misma cantidad de varianza.

Estos resultados son importantes ya que se deberán validar a la hora de trabajar con los datos reales.

Gráficos de recurrencia

Para visualizar patrones distintivos entre jóvenes adultos y mayores capturados por la representación interna del modelo RC_ESN, emplearemos gráficos de recurrencia. Estos gráficos nos permitirán identificar posibles patrones retenidos por el modelo. La idea es verificar la existencia de patrones similares entre sujetos jóvenes adultos y distintivos entre éstos y los sujetos mayores.

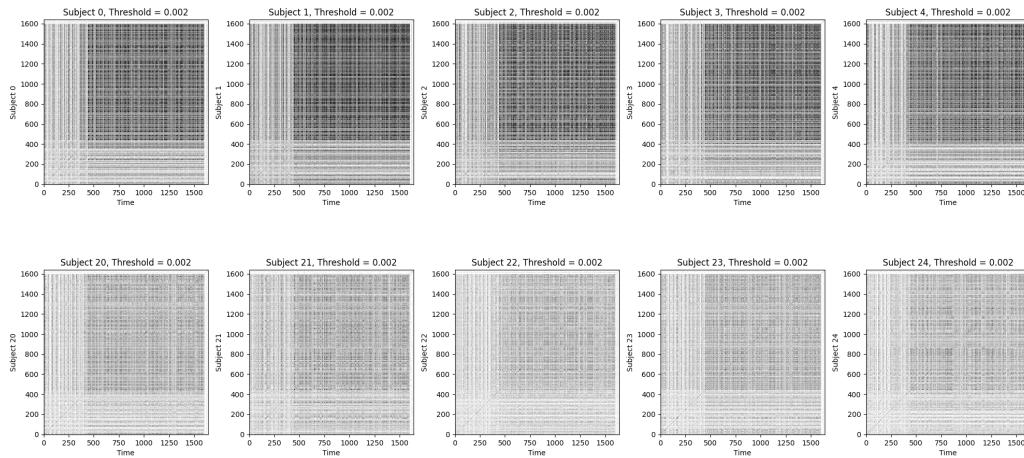


Figura 5.8: Gráficos de recurrencia para los datos sintéticos. Fila : sujetos jóvenes adultos, fila inferior: mayores.

En la figura 5.8 donde la primera fila son sujetos jóvenes adultos y la segunda fila son sujetos mayores. Observamos que los sujetos jóvenes y mayores muestran representaciones distintas. Además, notamos que los gráficos entre los sujetos de cada grupo son algo heterogéneos, lo que indica diferencias en la actividad neuronal entre los jóvenes y un envejecimiento variado entre los mayores. Incluso podemos observar que algunos sujetos jóvenes muestran patrones más similares a los de los mayores y viceversa. Aunque estamos trabajando con datos sintéticos en este caso, estos resultados son fundamentales para nuestra investigación en datos reales. Nos permiten identificar patrones de envejecimiento neuronal distintos y entender cómo la edad, los estilos de vida y las estrategias individuales influyen en la respuesta de cada sujeto ante diversas situaciones o problemas similares. Los gráficos de recurrencia más oscuros (en los jóvenes) reflejan una mayor coherencia lo que sugiere que sus cerebros están operando de manera más sincronizada, con patrones de actividad más uniformes y predecibles. Los gráficos de recurrencia de las personas mayores son más claros y dispersos, sugiere una mayor variabilidad en su actividad cerebral, con menos patrones repetitivos y más cambios en los estados neuronales

Además de la visualización mediante gráficos de recurrencia, otra alternativa relevante es el cálculo del potencial de memoria de las representaciones de series temporales multivariadas. Este enfoque permite evaluar la capacidad de las representaciones para retener patrones a lo largo del tiempo. Utilizando la función `calculate_potential_memory`, se determina el momento en el cual cada serie comienza a repetir patrones dentro de un umbral de tolerancia establecido. Este análisis complementario proporciona una perspectiva adicional sobre la estructura dinámica y la estabilidad de los datos procesados por el modelo RC_ESN, facilitando una comprensión más profunda de las diferencias observadas entre sujetos jóvenes adultos y mayores en los datos de EEG.

Potencial de memoria

Se observa una considerable variabilidad en la memoria potencial entre los sujetos jóvenes adultos (Figura 5.9), con valores que van desde 153 hasta 2295. Esta diversidad podría atribuirse a la actividad cerebral diferenciada presente en individuos más jóvenes, reflejando distintos perfiles de memoria y procesamiento cognitivo. En contraste, los sujetos mayores (Figura 5.9) muestran una memoria potencial más homogénea, con valores predominantemente alrededor de 561, salvo algunas excepciones que alcanzan hasta 102 o descienden hasta 408. Esta uniformidad sugiere una estandarización en los patrones de actividad cerebral en el grupo de mayores, posiblemente relacionada con cambios neurofisiológicos asociados al envejecimiento. Estas ob-

servaciones corroboran lo anticipado por la matriz de similitud, donde se evidenció una mayor variabilidad entre los sujetos jóvenes adultos y una homogeneidad más marcada en los mayores.

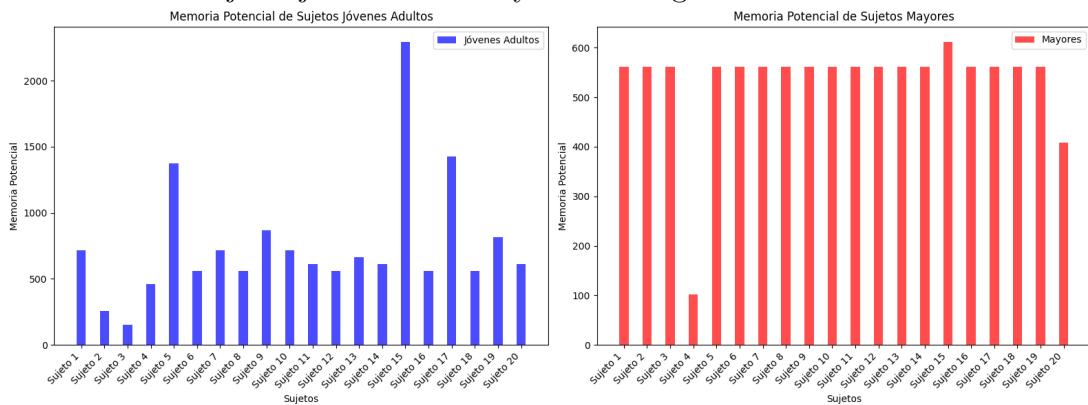


Figura 5.9: Potencial de memoria jóvenes vs mayores

Este análisis subraya cómo las diferencias en la memoria potencial reflejan no solo características individuales sino también cambios generacionales en la actividad cerebral, ofreciendo perspectivas importantes sobre el envejecimiento cognitivo y la diversidad funcional del cerebro en diferentes etapas de la vida.

Es importante recordar que estos datos son sintéticos; sin embargo, reflejan de manera efectiva posibles datos reales de EEG. Esta observación subraya la validez del método de generación de datos para aproximarse a la complejidad y variabilidad que se podría encontrar en contextos reales de EEG. Asimismo, esta conclusión servirá como hipótesis de trabajo al aplicar este enfoque a datos reales, anticipando que podríamos encontrar patrones similares de variabilidad en sujetos jóvenes adultos y homogeneidad en sujetos mayores. Este enfoque no solo valida nuestro método sintético, sino que también orienta hacia futuras investigaciones en la caracterización de la actividad cerebral en diferentes grupos etarios.

5.1.3. Resultados del análisis supervisado

Para el modelo supervisado obtendremos primero la representación interna y usaremos el API creado para los diferentes modelos de readout que tenemos. Recordar que como salida de la evaluación del modelo supervisado implementado dentro del API obtendremos tanto la matriz de , el accuracy y el f1-score. Por tanto primero usamos el metodo **myrc.fit(X_train, y_train)** para entrenar la capa de readout y actualizar los pesos de dicha capa. Y luego usamos el método **myrc.fit_evaluate (X_test, y_test)** para obtener el resultado de las predicciones de clasificación. Notar que tanto en el método fit como en fit_evaluate, en este caso, se introduce los valores de y_train e y_test, para realizar el entrenamiento y la predicción. Así como para evaluar la bondad de dichas predicciones.

Los resultados obtenidos utilizando una capa readout totalmente conectada ('mlp') son 1 para todas las métricas, siendo una clasificación perfecta y no teniendo ningún error de clasificación.

Los demás ejemplos con las otras opciones de readout se pueden ver en el notebook creado para el trabajo de datos sintéticos **synthetic_eeg_v10.ipynb** presnete en la web del proyecto¹

¹Disponible en GitHub: <https://github.com/jogugil/MyRC>

5.2. Datos reales: sujetos jóvenes adultos vs mayores

Después de haber creado el framework que contiene el API que implementa el modelo de Reservoir Computing utilizando datos sintéticos, procederemos a utilizarlo para procesar señales EEG reales de cada sujeto. En el apartado de análisis, ya se estudiaron los datos sintéticos con los que vamos a tratar, intentando utilizar el modelo de Reservoir Computing para comprobar si dicho modelo es capaz de extraer patrones dinámicos de las series temporales de los EEG de cada usuario, de tal forma que sea capaz de agruparlos en dos grupos: jóvenes adultos y mayores. Con ello, y relacionándolo con el entorno de neurociencia, investigaremos si existen diferencias cognitivas con diferentes patrones de activación cerebral en cada grupo de edad, así como si entre sujetos del mismo grupo existen algunas diferencias debidas a otros factores.

A tenor de los resultados obtenidos con los datos sintéticos, acometeremos el estudio de los datos EEG reales bajo una serie de hipótesis que deseamos comprobar:

1. Diferencias en la plasticidad cerebral

El cerebro de los jóvenes tiene mayor plasticidad, lo que significa que es más adaptable y puede responder a una mayor variedad de estímulos de manera flexible. Esta plasticidad podría hacer que las señales originales del EEG de los jóvenes sean más variables y menos coherentes que las señales de los sujetos mayores, que podrían estar reflejando un estado más estable o una representación interna menos variable.

2. Diferencias en la estructura y función cerebral

Sabemos que a medida que envejecemos, hay cambios en la estructura y función del cerebro que pueden afectar la señal del EEG. Los adultos pueden tener una mayor estabilidad en ciertas redes neuronales, lo que podría traducirse en una mayor coherencia entre las señales originales y corregidas. Por otro lado, estos cambios estructurales y funcionales pueden hacer que la señal corregida sea más representativa de la actividad cerebral subyacente en los adultos en comparación con los jóvenes.

3. Ruido y variabilidad en las medidas de EEG

La señal de EEG en jóvenes puede contener más ruido o variabilidad debido a factores como mayor movimiento, menor capacidad de mantenerse quietos, o diferencias en la actividad mental y emocional durante la medición. Este ruido adicional podría reducir la coherencia entre la señal original y la corregida en los jóvenes.

4. Factores cognitivos y emocionales

Los adultos pueden tener patrones de actividad cerebral más estables debido a diferencias en la carga cognitiva y emocional durante las mediciones. Los jóvenes pueden experimentar más fluctuaciones en estos estados, afectando la coherencia de las señales. En este sentido, los factores emocionales y cognitivos en los jóvenes pueden contribuir a una mayor variabilidad en la señal del EEG.

Es importante notar que, si bien con los datos sintéticos no se aplicaron técnicas de procesamiento de señales, en el estudio con datos reales será necesario realizar la primera fase descrita en la sección de análisis y diseño, donde se detalla un paso previo de preprocesamiento de señales debido a la gran cantidad de ruido e interacciones presentes en los datos EEG.

Trabajaremos con los datos reales en dos fases. En la primera fase, se recogen los datos EEG en crudo y se realiza un preprocesamiento de las señales, almacenando el dataset resultante en disco. Este se guarda en una matriz tridimensional con la estructura [número de sujetos, número

de muestras, número de canales]. Esto nos permite optimizar el uso de la memoria RAM, un aspecto crítico que ha sido un desafío constante para nosotros.

Para la primera fase, se crea un script que permite generar los datasets de las señales preprocesadas. Este script permite decidir si se desean eliminar artefactos durante el preprocesamiento y si se desea realizar una extracción de características en lugar de mantener las señales de los canales EEG. Dicho script se puede encontrar ². El script se llama `eeg_dataset_creator.ipynb`.

Para la segunda fase, donde utilizamos las señales preprocesadas como entrada al RC-ESN, tenemos dos scripts. El primer script, `channel_selector_models.py`, recoge un dataset con todos los canales y permite seleccionar los canales o lista de canales sobre los cuáles se desea trabajar. Alternativamente, se puede utilizar el script `eeg_dataset_creator.ipynb` para crear un dataset solo con los canales deseados y luego usar el segundo script, `rc_esn_model.py`, que recoge los datasets preprocesados y filtrados y aplica directamente el modelo RC-ESN. Ambos scripts se pueden encontrar ³

Ambos scripts trabajan con las salidas del RC-ESN para evaluar si dicho modelo es capaz de capturar los patrones de dinámica temporal de las señales EEG de cada sujeto. Estos estados reflejan la dinámica temporal de las entradas, capturando patrones complejos y no lineales. Para ello, implementan dos modelos: uno no supervisado con k-means, que busca agrupar los estados internos de cada sujeto en dos clústers, y otro supervisado, que permite realizar una clasificación de los mismos. Notar que la API permite trabajar con dos salidas del RC: por un lado, los estados internos de la capa interna del RC y, por otro, su representación, que a su vez, tal como se vio en el análisis y diseño, tiene varias opciones. Trabajar con una opción u otra abre una línea de investigación distinta que se dejará como trabajo futuro; aquí simplemente se demostrará que se pueden realizar correctamente ambas vías. De igual modo, para el modelo supervisado, la API permite escoger entre diferentes modelos de aprendizaje automático, pero siguiendo un paralelismo con los datos sintéticos, en este caso también utilizaremos un modelo MLP.

5.2.1. Análisis no supervisado

Para este apartado, primero trabajaremos con todos los canales del EEG de cada sujeto. Posteriormente, repetiremos el modelo no supervisado con un dataset de canales filtrados para ver si mejora la distinción entre jóvenes adultos y mayores. Al igual que con los datos sintéticos, cargamos los datos reales ya procesados y calculamos la matriz de similitud a partir de los estados de salida del RC. Con esta matriz, probamos los métodos de clustering y evaluamos los resultados.

La matriz de similitud obtenida a partir de la salida del modelo RC-ESN se presenta en la figura 5.10. Observamos que se cumple una de las hipótesis iniciales, donde se distinguen dos agrupaciones claras en la diagonal correspondientes a jóvenes adultos y mayores. Además, se aprecia una mayor homogeneidad entre los mayores y una variabilidad más amplia en la actividad entre los jóvenes. Este hallazgo cuestiona la idea de la mayor plasticidad neuronal en los jóvenes, que genera diferencias en la actividad neuronal dentro de este grupo según sus actividades diarias y experiencias. Las posibles diferencias entre los mayores deberían atribuirse a los procesos de envejecimiento, aunque aún así muestran una mayor homogeneidad en comparación.

²en la web del proyecto

³en la web del proyecto

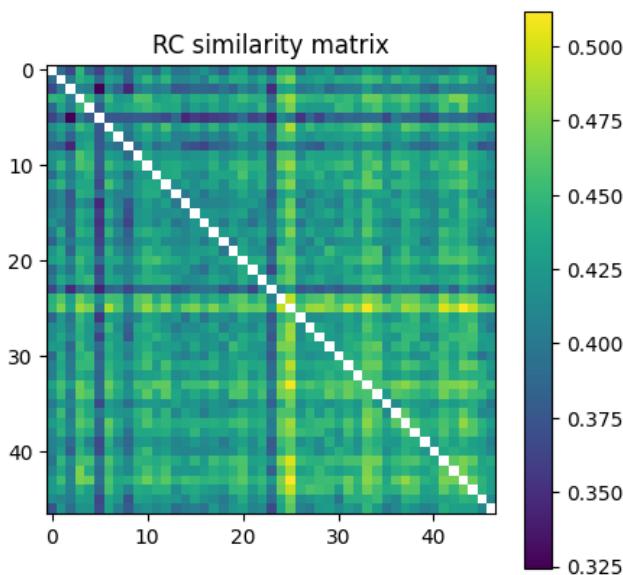


Figura 5.10: Matriz de similitud de datos reales preprocesados y con eliminación de artefactos ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).

La agrupación obtenida con Kmeans utilizando la salida del RC-ESN para estos datos reales se muestra en la figura 5.11, con un valor de precisión (accuracy) de 0.72 como se indica en la figura 5.12.

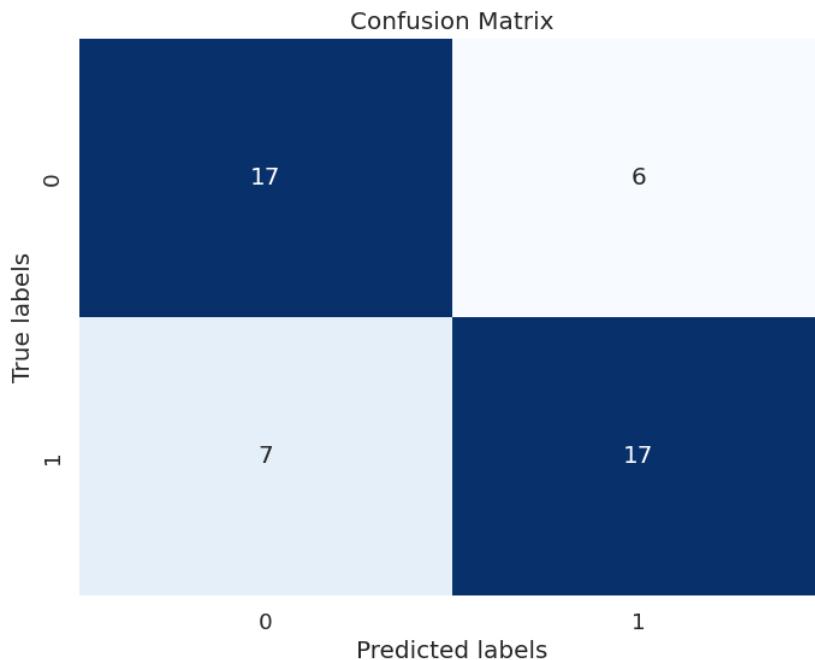


Figura 5.11: Matriz confusión datos reales con eliminación artefactos(0:Grupo jóvenes adultos; 1: Grupo Mayores).

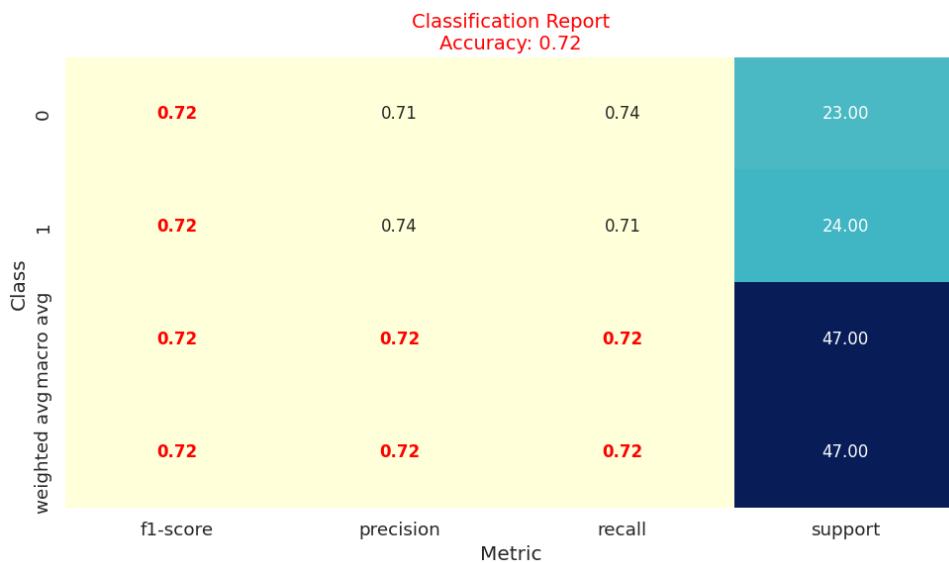


Figura 5.12: Métricas agrupación datos reales con eliminación artefactos mediante Kmeans (0:Grupo jóvenes adultos; 1: Grupo Mayores)

El valor de 0.72 para la precisión (accuracy) en la agrupación de jóvenes y mayores utilizando la salida del modelo RC-ESN sugiere que este modelo es capaz de capturar patrones distintivos en la dinámica temporal de las series de EEG procesadas. Esta precisión indica que, en general, el modelo puede distinguir con una precisión razonable entre los patrones neuronales asociados con los grupos de jóvenes y mayores.

Esta capacidad es fundamental en aplicaciones de análisis de EEG, donde la identificación precisa de patrones neuronales puede ofrecer información crucial sobre las diferencias en la actividad cerebral entre grupos demográficos. Un valor de 0.74 refuerza la utilidad del modelo RC-ESN en la clasificación y agrupación de datos EEG, proporcionando una herramienta efectiva para investigaciones que buscan entender cómo varían los patrones neuronales con la edad.

Como se mencionó previamente, se utilizó una regresión ridge para evaluar la importancia de los estados a partir de la representación interna. Agrupamos a los sujetos según su actividad neuronal común, pero el análisis no supervisado mediante esta representación no mostró resultados óptimos, con una precisión máxima de 0.60. Esto resalta la alta sensibilidad del modelo RC-ESN a los hiperparámetros, los cuales necesitan un ajuste preciso para cada línea de investigación.

Ahora, podemos enfocarnos en los canales del hemisferio izquierdo del cerebro. Este enfoque es crucial debido a que en esta región se encuentran funciones cognitivas críticas que tienden a deteriorarse con el envejecimiento, como el lenguaje, la memoria verbal y habilidades numéricas. Estos aspectos son fundamentales para comprender el impacto del proceso de envejecimiento en la dinámica cerebral. A continuación, exploraremos los resultados obtenidos al analizar específicamente estos canales, buscando entender cómo la dinámica temporal de las series de EEG refleja cambios en estas capacidades cognitivas críticas.

En la matriz de similitud (figura 5.13) observamos una tendencia similar a la mencionada anteriormente. Se forman dos agrupamientos distintos en la diagonal: uno para los adultos jóvenes y otro para los adultos mayores. Sin embargo, la similitud entre los sujetos mayores es más homogénea que entre los sujetos jóvenes. Es importante destacar que en este caso la similitud es menor en comparación con la obtenida al considerar todos los canales de EEG. Esto puede explicarse ya que la dinámica temporal de la actividad cerebral es altamente compleja y puede involucrar interacciones complejas y no lineales entre diferentes regiones cerebrales. Al considerar todos los canales, se capturan estas interacciones de manera más completa, lo que

podría resultar en una similitud más alta entre los sujetos.

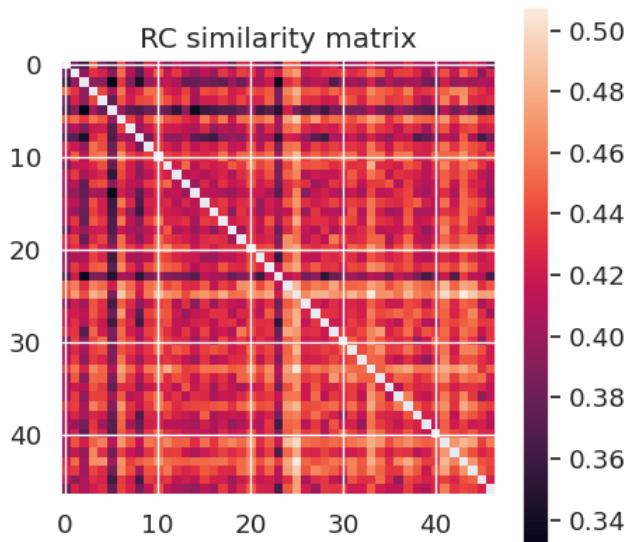


Figura 5.13: Matriz similitud canales hemisferio izquierdo([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).

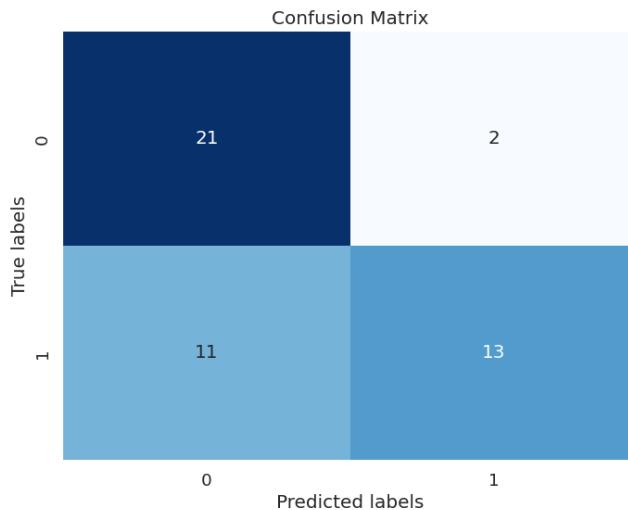


Figura 5.14: Matriz confusión agrupamiento mediante Kmeans para los estados internos de los canales del hemisferio izquierdo(0:Grupo jóvenes adultos; 1: Grupo Mayores).

Vemos también una alta precisión (figura 5.14) en la agrupación de este caso, lo cual era esperable dado que ya obteníamos una precisión aceptable con todos los canales. En la matriz de confusión (figura 5.15), observamos que en este caso la agrupación de los adultos jóvenes es mejor que la de los mayores. Esto podría explicarse por las diferencias en el proceso de envejecimiento entre los sujetos, que afectan la capacidad de generar patrones distintivos relacionados con la edad.

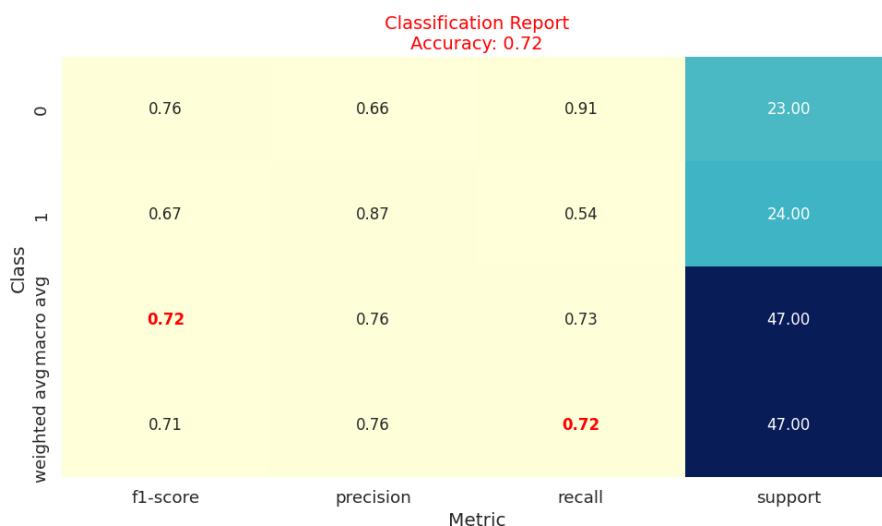


Figura 5.15: Métricas del agrupamiento de los estados RC-ESN de los canales del hemisferio izquierdo con Kmeans(0:Grupo jóvenes adultos; 1: Grupo Mayores).

Es importante mencionar que se han llevado a cabo muchas más pruebas de las que se muestran en esta memoria, las cuales pueden reproducirse utilizando los notebooks y scripts disponibles en el repositorio del proyecto en GitHub. Sin embargo, por motivos de simplicidad y claridad, hemos optado por presentar solo algunos ejemplos representativos. No obstante, es fundamental destacar que el verdadero objetivo del proyecto es la construcción del framework que facilita su utilización y la exploración de diversas líneas de investigación en el futuro, con sus respectivas opciones de configuración.

Gráficos de recurrencia

Los resultados de las gráficas de recurrencia para los datos reales entre jóvenes y mayores con los 64 canales de su EEG se presentan en la figura 5.16. A partir de estos gráficos, se observan diferencias significativas. Los jóvenes adultos muestran gráficos de recurrencia más densos y oscuros en comparación con los mayores. Esta mayor densidad sugiere una actividad cerebral más coherente y regular en los jóvenes, reflejando patrones de actividad más uniformes y predecibles. En contraste, los gráficos de recurrencia de los mayores muestran menor densidad o mayor claridad, indicando una actividad cerebral más variable y menos predecible, con más cambios en los estados neuronales.

Estas diferencias pueden estar relacionadas con la complejidad y conectividad en las representaciones mentales y procesos cognitivos de los jóvenes. La mayor coherencia observada en los gráficos más oscuros de los jóvenes sugiere una mayor sincronización en la actividad neuronal, lo cual podría implicar una mayor eficiencia en la comunicación entre áreas cerebrales. Esto podría asociarse con procesos cognitivos más eficientes y una menor propensión a la distracción o desviación de la atención, en comparación con los mayores, cuya actividad cerebral muestra más variabilidad.

Estos hallazgos subrayan la importancia de considerar la edad como un factor crucial en la comprensión de cómo evolucionan y organizan los procesos cognitivos a lo largo de la vida. Esto puede traducirse en una mayor eficiencia para procesar información de manera rápida y precisa en los adultos jóvenes, así como en un mejor control motor para movimientos coordinados y precisos. Además, la estabilidad en los patrones de actividad cerebral puede influir en la estabilidad emocional y en la capacidad para regular las respuestas emocionales y comportamentales ante situaciones cambiantes. Asimismo, la regularidad en la actividad neuronal puede facilitar

la comprensión y la adaptación a nuevos contextos y desafíos, contribuyendo a mantener una respuesta adaptativa y flexible.

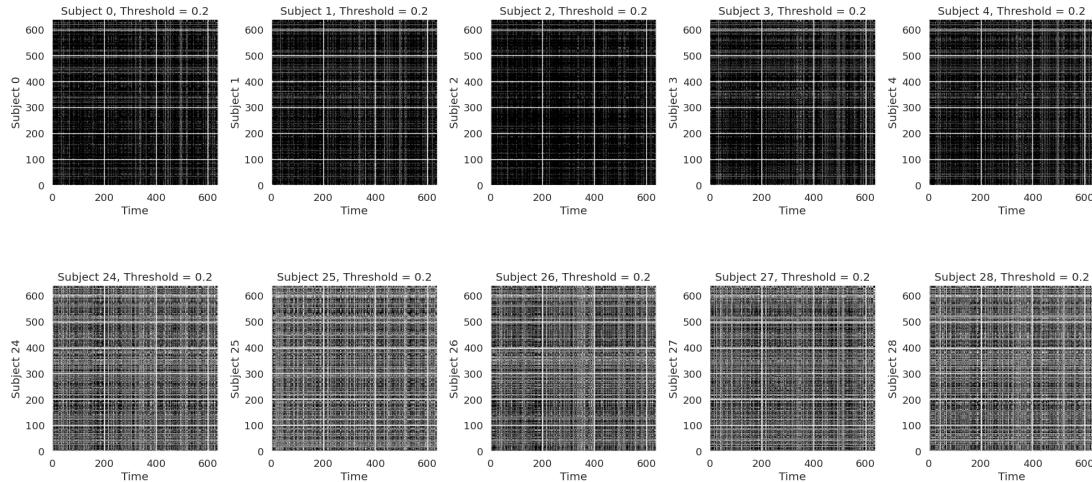


Figura 5.16: Gráficas recurrencia entre jóvenes vs mayores ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).

Potencial de memoria

El resultado del potencial de memoria de los datos reales de jóvenes adultos y mayores se muestra en la figura 5.17. Se observa una variabilidad significativa en el potencial de memoria entre los grupos de jóvenes y mayores. Esta variabilidad en los jóvenes puede atribuirse a diferencias en la plasticidad neuronal y la adaptabilidad cerebral, mientras que en los adultos mayores, la homogeneidad relativa puede deberse a una mayor reserva cognitiva y una experiencia de vida más consolidada. Estos hallazgos subrayan la importancia de considerar tanto factores neurobiológicos como ambientales al investigar las diferencias en la capacidad de memoria entre diferentes grupos etarios.

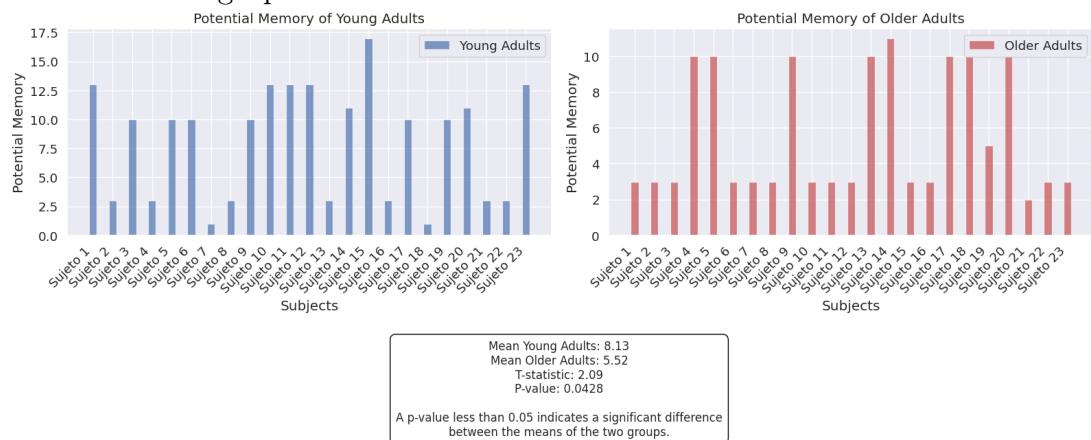


Figura 5.17: Potencial de memoria de datos jóvenes adultos vs mayores con T-test sobre la H0: Existe una diferencia estadísticamente significativa de potencial de memoria entre los dos grupos de sujetos.

Los resultados del análisis estadístico muestran una diferencia significativa en el potencial de memoria entre los jóvenes adultos y los mayores. El valor del T-test ($t(48) = 2.09$, $p = 0.0428$) indica que existe una diferencia estadísticamente significativa entre las medias de los valores del potencial de memoria de ambos grupos. Además, aunque el Levene's test ($F = 1.85$, $p = 0.1805$) no muestra una diferencia significativa en la variabilidad de las dos muestras, la gráfica

de potencia sugiere que los jóvenes exhiben una mayor variabilidad en sus valores de potencial de memoria, lo que puede atribuirse a la mayor plasticidad cerebral en este grupo. En contraste, los adultos mayores presentan una menor variabilidad, reflejando una mayor homogeneidad en sus capacidades de memoria, lo cual es coherente con la disminución de la plasticidad cerebral con la edad.

5.2.2. Análisis supervisado

Como comentamos en secciones anteriores, para el proceso de clasificación mediante modelos supervisados, donde se aplica la capa de readout del modelo RC-ESN. Se tienen implementados varios modelos base que se pueden parametrizar con la configuración del reservoir. Recordar que en el caso de los datos sintéticos, hemos incluido en la memoria el uso del modelo MLP para la clasificación, aunque en el notebook (**synthetic_eeg_v10.ipynb** presente ⁴) se pueden ver sus resultados con cada uno de los modelos. Para el caso de datos reales, vamos a probar primero con el modelo Ridge y posteriormente usaremos el modelo MLP. Al igual que en el caso supervisado, hay que probar y validar los valores de los hiperparámetros del RC-ESN para obtener las representaciones internas del RC-ESN, con las que se aplica el entrenamiento y validación de la capa de readout. Los resultados también se pueden encontrar en el notebook **channel_selector_models.ipynb** presente ⁵.

Readaout:lin (Regresión ridge)

En primer lugar debemos dividir los datos en datos de entrenamiento y test. En este caso se dividen el conjunto de sujetos con su correspondientes señales EEG para entrenar y evaluar la clasificación de dichos sujetos mediante el modelo ridge. En este caso se dejan 28 sujetos entre jóvenes adultos y mayores para datos de entrenamiento y 19 sujetos para test. La clasificación de estos 19 sujetos nos proporciona una matriz de confusión (figura 5.18) que indica un accuracy cercano al 80% (tabla 5.1), logrado sin optimizar exhaustivamente los hiperparámetros tanto del modelo RC-ESN como de la capa de readout. Y que podemos ver en la curva ROC del resultado de la misma (figura 5.19).

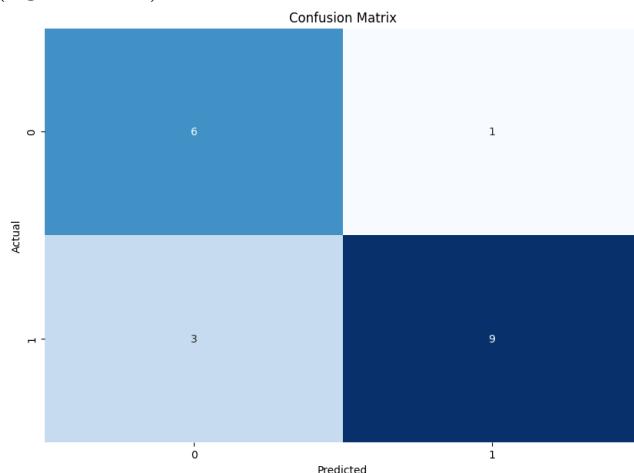


Figura 5.18: Matriz confusión proceso de clasificación de los sujetos jóvenes adultos vs mayores mediante un modelo ridge para la capa readout del modelo RC-ESN(0:Grupo jóvenes adultos; 1: Grupo Mayores).

⁴en la web del proyecto: <https://github.com/jogugil/MyRC>

⁵en la web del proyecto: <https://github.com/jogugil/MyRC>

Clase	Precisión	Recall	F1-score	Soporte
0	0.67	0.86	0.75	7
1	0.90	0.75	0.82	12
Exactitud	0.79			
Promedio macro	0.78	0.80	0.78	19
Promedio ponderado	0.81	0.79	0.79	19

Tabla 5.1: Informe de evaluación del modelo RC-ESN con readout MLP para la clasificación de los sujetos en estudio entre jóvenes y mayores(0:Grupo jóvenes adultos; 1: Grupo Mayores).

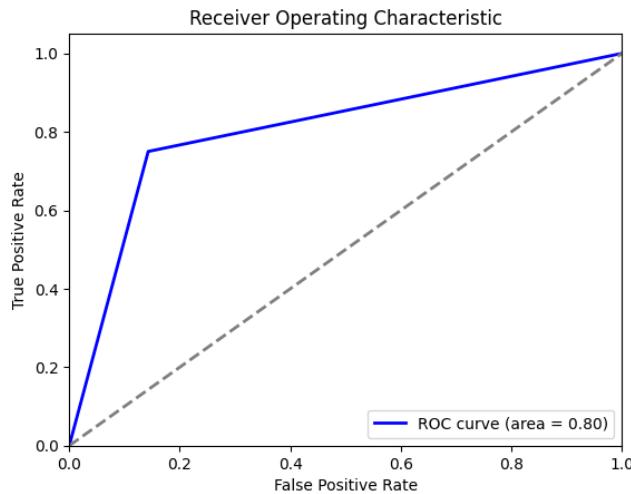


Figura 5.19: Curva roc de la evaluación del proceso de clasificación de los sujetos jóvenes adultos vs mayores mediante la capa readout ridge del modelo RC-ESN

Basado en los resultados obtenidos al emplear la capa de readout con el modelo Ridge para el RC-ESN en la clasificación de sujetos jóvenes adultos y mayores a partir de señales EEG, podemos concluir lo siguiente. La precisión alcanzada con un 78.95 % y un accuracy ROC del 80.03 % de exactitud indica que **el modelo es capaz de distinguir efectivamente entre las categorías de sujetos basado en las características extraídas de las señales cerebrales**. Esto sugiere que **el enfoque utilizado, combinando la capacidad de representación del RC-ESN con la capacidad de clasificación del modelo Ridge, es prometedor para aplicaciones de diagnóstico y análisis en neurociencia cognitiva y clínica**.

Readaout:mlp (Multi-Layer Perceptron Classifier)

En este caso, hemos ajustado el parámetro de configuración '`readout_type': 'mlp'`', lo que implica el uso de los siguientes parámetros asociados a esta capa de readout: `{'mlp_num_epochs', 'mlp_batch_size', 'mlp_learning_rate', 'mlp_learning_rate_type', 'mlp_layout', 'mlp_w_12'}`.

Al igual que con el modelo de regresión ridge, logramos una clasificación efectiva con una alta precisión (0.78 %), incluso sin una optimización exhaustiva de los parámetros mencionados. Las Figuras (figura 5.20) y (figura 5.21) muestran la matriz de confusión y la curva ROC de esta clasificación con una capa de readout MLP. Estas figuras reflejan métricas elevadas que indican la eficacia del modelo RC-ESN junto con el MLP para discernir entre sujetos jóvenes adultos y mayores a partir del procesamiento de la dinámica temporal de las señales EEG, las cuales representan la actividad cerebral de cada sujeto.

Es crucial destacar que la configuración de los parámetros de la capa de readout MLP juega un papel fundamental en la mejora del rendimiento del modelo. El parámetro `mlp_num_epochs`

determina el número de épocas de entrenamiento, lo cual puede influir significativamente en la capacidad del modelo para generalizar. Por otro lado, *mlp_batch_size* afecta la eficiencia del entrenamiento y la estabilidad de la convergencia. La tasa de aprendizaje (*mlp_learning_rate*) y su tipo (*mlp_learning_rate_type*) son cruciales para asegurar que el modelo se ajuste adecuadamente a los datos sin caer en mínimos locales. La disposición de la red (*mlp_layout*) define la arquitectura de la MLP, influenciando su capacidad para capturar patrones complejos en los datos. Finalmente, la regularización L2 (*mlp_w_l2*) ayuda a prevenir el sobreajuste, manteniendo el equilibrio entre el ajuste del modelo y su capacidad de generalización.

Estos resultados (Tabla 5.2) sugieren que el modelo RC-ESN, complementado con una capa de readout MLP bien configurada, es altamente efectivo para clasificar las señales EEG de sujetos de diferentes grupos de edad. La precisión alcanzada y las métricas derivadas de la matriz de confusión (figura 5.20) y la curva ROC (figura 5.21) demuestran la robustez del enfoque propuesto. Esto subraya el potencial del modelo para aplicaciones en neurociencia y medicina, donde la clasificación precisa de señales EEG es crucial para el diagnóstico y monitoreo de diversas condiciones neurológicas.

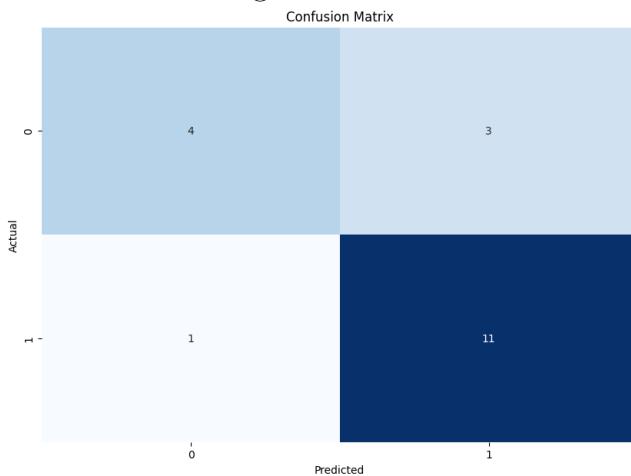


Figura 5.20: Matriz confusión proceso de clasificación mediante capa de redaout 'mlp' para las representaciones internas del RC-ESN de los sujetos de estudio(0:Grupo jóvenes adultos; 1: Grupo Mayores).

Clase	Precisión	Recall	F1-score	Sopporte
0	0.80	0.57	0.67	7
1	0.79	0.92	0.85	12
Exactitud	0.79			
Promedio macro	0.79	0.74	0.76	19
Promedio ponderado	0.79	0.79	0.78	19

Tabla 5.2: Informe de resultados del modelo RC-ESN con readout 'mlp'para el proceso de clasificación de los sujetos en estudio entre jóvenes y mayores(0:Grupo jóvenes adultos; 1: Grupo Mayores).

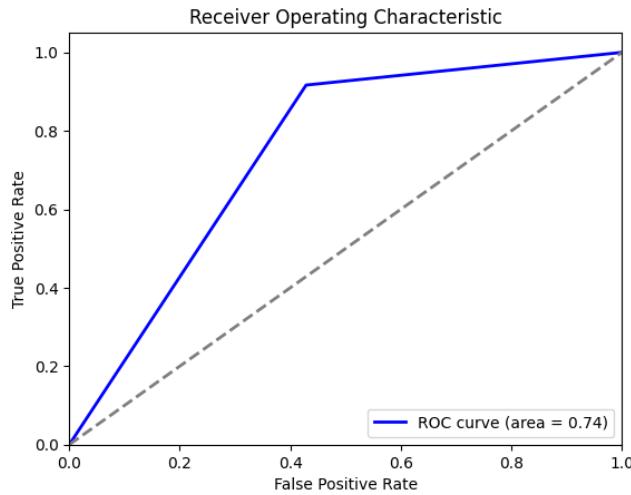


Figura 5.21: Curva ROC del proceso de clasificación de los patrones de dinámica temporal asociadas a las señales EEG de los sujetos de estudio mediante un modelo RC-ESN con capa readout mlp

5.2.3. Deep reservoir computing

El API desarrollado también permite trabajar con una arquitectura profunda del RC-ESN [78], [79], [80], mediante la clase `DeepMyRC`. Esta clase facilita la aplicación de configuraciones no supervisadas para la clusterización de las salidas generadas. En la página web del proyecto⁶ se encuentra un notebook con el código y la configuración de la clase. Los resultados de aplicar el algoritmo k-means a los estados de salida de `DeepMyRC` están disponibles en las figuras correspondientes.

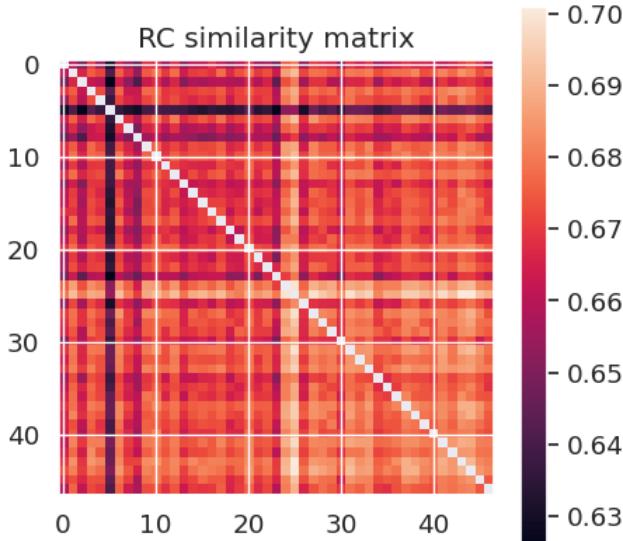


Figura 5.22: Matriz Similitud DeepMyRC sin reducción de dimensionalidad ([0-23]:Sujetos jóvenes adultos; [24-47] sujetos mayores).

Aunque el estudio se puede ver en la web del proyecto, es reseñable mencionar el resultado obtenido sobre la matriz de similitud (Figura 5.22) revela una distinción más clara entre los grupos de sujetos utilizando la arquitectura profunda del RC-ESN en comparación con configuraciones anteriores. Esta arquitectura permite capturar patrones más sutiles en la dinámica

⁶<https://github.com/jogugil/MyRC>

temporal de las señales EEG, facilitando la separación entre jóvenes adultos y mayores. Se observa que las dos agrupaciones principales en la diagonal de la matriz corresponden a los dos grupos etarios, indicando una mayor nitidez en la separación. La agrupación de los adultos mayores muestra una alta consistencia en su actividad neuronal, mientras que la de los jóvenes adultos presenta una mayor variabilidad, reflejando la dinámica de aprendizaje y adaptación en esta etapa. Aunque la configuración de DeepMyRC no incluyó una reducción de dimensionalidad, lo que podría haber disminuido la similitud general, la tendencia de separación entre los grupos se mantiene claramente.

Capítulo 6

Conclusiones

6.1. Conclusiones

En este trabajo, se ha desarrollado el framework RC_ESN para el procesamiento de señales EEG utilizando Python. Este framework es altamente completo recorriendo cada una de las fases pertinentes a la naturaleza de este tipo de proyectos. Además está detalladamente documentado en el repositorio de GitHub¹.

A partir del análisis y la aplicación del modelo RC_ESN para el procesamiento de datos sintéticos y reales de EEG en jóvenes adultos y adultos mayores, se pueden extraer las siguientes conclusiones:

- **Robustez ante ruido:** El modelo RC_ESN es resistente al ruido en los datos EEG, lo que es esencial en entornos de medición ruidosos.
- **Captura dinámica temporal:** RC_ESN captura eficazmente las dinámicas temporales en las series de datos EEG, identificando cambios y tendencias significativas.
- **Sin extracción previa de características:** RC_ESN trabaja directamente con datos crudos, eliminando la necesidad de extraer características temporales o frecuenciales previamente.
- **Eficiencia computacional:** En comparación con métodos complejos, RC_ESN requiere menos recursos computacionales, favoreciendo aplicaciones en tiempo real o sistemas limitados.
- **Sencillez de implementación:** La implementación de RC_ESN es relativamente simple, facilitando su uso en diversos contextos y por usuarios con distintos niveles de experiencia.
- **Sensibilidad a hiperparámetros:** El rendimiento de RC_ESN depende significativamente de la configuración de hiperparámetros, requiriendo ajuste cuidadoso para optimizarlo.
- **Dependencia de datos y características:** El desempeño de RC_ESN varía según el tipo y características de los datos EEG, destacando la necesidad de adaptar el modelo a las particularidades del estudio.

El modelo RC_ESN ofrece varias ventajas significativas para el procesamiento de datos EEG en diferentes grupos de edad, aunque es crucial considerar sus sensibilidades y requerimientos específicos para maximizar su eficacia en aplicaciones prácticas.

¹<https://github.com/jogugil/MyRC>

6.2. Trabajo futuro

Las direcciones futuras para la investigación basadas en los resultados obtenidos y las teorías de neurociencia que distinguen entre jóvenes adultos y mayores en relación con diferentes estados neuronales y situaciones neurocientíficas. A continuación, se detallan varios puntos clave que guiarán el desarrollo futuro:

1. Estudio basado en los resultados y teorías de neurociencia sobre la distinción entre jóvenes adultos y mayores en relación a los tipos de estados neuronales o situaciones neurocientíficas.

Este punto explorará cómo los hallazgos del presente estudio pueden ser interpretados a la luz de las teorías de neurociencia que diferencian entre jóvenes adultos y personas mayores en términos de estados neuronales específicos o situaciones neurocientíficas relevantes.

2. Pruebas con GA y optimización bayesiana para la búsqueda automática de hiperparámetros óptimos del Reservoir Computing para este problema.

Se investigará cómo los algoritmos genéticos (GA) y la optimización bayesiana pueden ser aplicados para ajustar los hiperparámetros del Reservoir Computing de manera automatizada, mejorando así la eficiencia y precisión del modelo en contextos donde existen diferencias significativas entre grupos de edad en términos de estados neuronales.

3. Pruebas con la implementación de DeepESN para la resolución de este problema.

Se discutirá la implementación y los beneficios de DeepESN (Deep Echo State Network) en la resolución del problema específico abordado en este trabajo. Se explorará cómo la profundización de las capas puede mejorar la capacidad del modelo para capturar características complejas de los datos, particularmente aquellas relacionadas con las diferencias observadas entre jóvenes adultos y mayores.

4. Técnicas de extracción de características del estado interno del Reservoir Computing como entrada al readout.

Este punto detallará cómo las técnicas de extracción de características del estado interno del Reservoir Computing pueden ser optimizadas y adaptadas para mejorar la precisión del readout. Se explorará la aplicación de estas técnicas para capturar de manera efectiva las diferencias en estados neuronales entre jóvenes adultos y mayores, mejorando así la capacidad predictiva del modelo.

5. Utilización de la implementación del API del RC para la resolución de otro tipo de problemas asociados al procesamiento de señales EEG.

Finalmente, se discutirá cómo la implementación del API del Reservoir Computing puede extenderse o aplicarse a otros problemas relacionados con el procesamiento de señales EEG. Se considerará su aplicación en el análisis de patrones cerebrales específicos que pueden variar entre jóvenes y mayores, contribuyendo al avance en la comprensión de las diferencias neurocientíficas asociadas con la edad.

Bibliografía

- [1] Y. Sakemi, K. Morino, T. Leleu, et al. Model-size reduction for reservoir computing by concatenating internal states through time. *Scientific Reports*, 10:21794, 2020.
- [2] F. Duport, A. Smerieri, A. Akrout, et al. Fully analogue photonic reservoir computer. *Scientific Reports*, 6:22381, 2016.
- [3] Qiyuan An, Kangjun Bai, Lingjia Liu, Fangyang Shen, and Yang Yi. A unified information perceptron using deep reservoir computing. *Computers & Electrical Engineering*, 85:106705, 2020.
- [4] Dhireesha Kudithipudi, Qutaiba Saleh, and Cory Merkel. Design and analysis of a neuromemristive reservoir computing architecture for biosignal processing. *Frontiers in Neuroscience*, 9:502, 2015.
- [5] Gouhei Tanaka, Tetsuya Yamane, Jean-Baptiste Héroux, Ryohei Nakane, Naoya Kanazawa, Shuichi Takeda, and Akihiko Hirose. Recent advances in physical reservoir computing: A review. *Neural Networks*, 115:100–123, 2019.
- [6] Andrew P Wickens. *A history of the brain: From stone age surgery to modern neuroscience*. Psychology Press, 2014.
- [7] Jia Jie Chai, Colm O’Sullivan, Aoife A Gowen, Brian Rooney, and Jun Xu. Augmented/mixed reality technologies for food: A review. *Trends in Food Science & Technology*, 124:182–194, 2022.
- [8] Giuseppe Matassi and Paula Martinez. The brain-computer analogy—“a special issue”. *Frontiers in Ecology and Evolution*, 10:1099253, 2023.
- [9] Patricia Smith Churchland. *Neurophilosophy: Toward a unified science of the mind-brain*. MIT press, 1989.
- [10] Larry W Swanson and Jeff W Lichtman. From cajal to connectome and beyond. *Annual Review of Neuroscience*, 39:197–216, 2016.
- [11] Susan Bookheimer. Functional mri of language: New approaches to understanding the cortical organization of semantic processing. *Annual Review of Neuroscience*, 25(1):151–188, 2002.
- [12] Egidio D’Angelo and Viktor Jirsa. The quest for multiscale brain modeling. *Trends in Neurosciences*, 45(10):777–790, 2022.
- [13] Denis Mareschal, Mark H Johnson, Sylvain Sirois, Michael Spratling, Michael S.C Thomas, and Gert Westermann. *Neuroconstructivism-I: How the brain constructs cognition*. Oxford University Press, 2007.

- [14] Riitta Hari and Miia Maaria V Kujala. Brain basis of human social interaction: From concepts to brain imaging. *Physiological Reviews*, 89(2):453–479, 2009.
- [15] Jeffrey Tseng and Jordan Poppenk. Brain meta-state transitions demarcate thoughts across task contexts exposing the mental noise of trait neuroticism. *Nature communications*, 11(1):1–12, 2020.
- [16] Steven E Petersen and Olaf Sporns. Brain networks and cognitive architectures. *Neuron*, 88(1):207–219, 2015.
- [17] Abraham Vázquez-Guardado, Yiyuan Yang, Amay J Bandodkar, and John A Rogers. Recent advances in neurotechnologies with broad potential for neuroscience research. *Nature Neuroscience*, 23(12):1522–1536, 2020.
- [18] Sang Min Won, Enming Song, Jonathan T Reeder, and John A Rogers. Emerging modalities and implantable technologies for neuromodulation. *Cell*, 181(1):115–135, 2020.
- [19] A. I. Luppi, F. E. Rosas, P. A. M. Mediano, D. K. Menon, and E. A. Stamatakis. Information decomposition and the informational architecture of the brain. *Trends in Cognitive Sciences*, 28(4):352–368, 2024.
- [20] Subhaneil Chung and L. F. Abbott. Neural population geometry: An approach for understanding biological and artificial neural networks. *Current Opinion in Neurobiology*, 70:137–144, 2021.
- [21] Emma L. Newman, Thomas F. Varley, Vijay K. Parakkattu, Stephen P. Sherrill, and John M. Beggs. Revealing the dynamics of neural information processing with multivariate information decomposition. *Entropy*, 24(7):930, 2022.
- [22] J. H. Martínez Huartos. *Análisis de la actividad neuronal y cerebral mediante técnicas de redes complejas*. PhD thesis, Agronomos, 2015.
- [23] P. Ariza Bono. *Software BNA4D: Análisis de redes cerebrales funcionales mediante técnicas de redes complejas*. PhD thesis, Telecomunicacion, 2018.
- [24] Boris Kotchoubey, Felix Tretter, Hans A Braun, Thomas Buchheim, Andreas Draguhn, Thomas Fuchs, Christine Mohr, Silke Nolte, Guido and-Walther, Harald Welzer, et al. Methodological problems on the way to integrative human neuroscience. *Frontiers in Integrative Neuroscience*, 10:41, 2016.
- [25] William Bechtel. The challenge of characterizing operations in the mechanisms underlying behavior. *Journal of the experimental analysis of behavior*, 84(3):313–325, 2005.
- [26] Jill X O'Reilly and Rogier B Mars. Bayesian models in cognitive neuroscience: a tutorial. In *An introduction to model-based cognitive neuroscience*, pages 179–197. 2015.
- [27] Amy Perfors, Joshua B Tenenbaum, Thomas L Griffiths, and Fei Xu. A tutorial introduction to bayesian models of cognitive development. *Cognition*, 120(3):302–321, 2011.
- [28] Nick Chater, Mike Oaksford, Ulrike Hahn, and Evan Heit. Bayesian models of cognition. *Wiley Interdisciplinary Reviews: Cognitive Science*, 1(6):811–823, 2010.
- [29] K Friston. A theory of cortical responses. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 360(1456):815–836, 2005.

- [30] Marcelo Arce Fonollá. Los sistemas dinámicos como teoría cognitiva. *SUMMA Psicológica UST*, 2(2):47–52, 2005. Copyright 2004 by SU MMA Psicológica U 'T. ISSN 0718-0446. Recepción: Noviembre 2005 - Aceptación: Diciembre 2005.
- [31] Nikolaus Kriegeskorte and Pamela K Douglas. Cognitive computational neuroscience. *Nature Neuroscience*, 21(9):1148–1160, 2018.
- [32] Martin Schrimpf, Jonas Kubilius, Michael J Lee, N Apurva Ratan Murty, Robert Ajemian, and James J DiCarlo. Integrative benchmarking to advance neurally mechanistic models of human intelligence. *Neuron*, 108(3):413–423, 2020.
- [33] A Pouget, J M Beck, W J Ma, and P E Latham. Probabilistic brains: knowns and unknowns. *Nature neuroscience*, 16(9):1170–1178, 2013.
- [34] Guangyu Robert Yang and Xiao-Jing Wang. Artificial neural networks for neuroscientists: a primer. *Neuron*, 107(6):1048–1070, 2020.
- [35] Duncan E Astle, Mark H Johnson, and Doga Akarca. Toward computational neuroconstructivism: a framework for developmental systems neuroscience. *Trends in Cognitive Sciences*, 2023.
- [36] Brenden Baker, Benjamin Lansdell, and Konrad P Kording. Three aspects of representation in neuroscience. *Trends in Cognitive Sciences*, 26(11):942–958, 2022.
- [37] Anna Doerig, Rosemary P Sommers, Karolin Seeliger, Benjamin Richards, Jon Ismael, Grace W Lindsay, and Tim C Kietzmann. The neuroconnectionist research programme. *Nature Reviews Neuroscience*, 24(7):431–450, 2023.
- [38] James L McClelland and Timothy T Rogers. The parallel distributed processing approach to semantic cognition. *Nature Reviews Neuroscience*, 4(4):310–322, 2003.
- [39] Luis H. Favela. Cognitive science as complexity science. *Wiley Interdisciplinary Reviews: Cognitive Science*, 11(4):1525, 2020.
- [40] E. Gkintoni and I. Dimakos. An overview of cognitive neuroscience in education. In *EDULEARN22 Proceedings*, pages 5698–5707, 2022.
- [41] Michael J Rivkin. Developmental neuroimaging of children using magnetic resonance techniques. *Mental retardation and developmental disabilities research reviews*, 6(1):68–80, 2000.
- [42] Ghazala Mustafa and Hina Rashid. Exploring cognitive development through the lens of neuroscience. *Cosmic Journal of Linguistics*, 2(1):60–75, 2023.
- [43] L Zhu and J Lv. Review of studies on user research based on eeg and eye tracking. *Applied Sciences*, 13(11):6502, 2023.
- [44] Joachim K Krauss, Nir Lipsman, Tipu Aziz, Alexandre Boutet, Peter Brown, Jin Woo Chang, and Andres M Lozano. Technology of deep brain stimulation: current status and future directions. *Nature Reviews Neurology*, 17(2):75–87, 2021.
- [45] Marcus Kaiser. Brain architecture: a design for natural computation. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 365(1861):3033–3045, 2007.

- [46] James M Shine, Erik J Müller, Bradley Munn, Joana Cabral, Rosalyn J Moran, and Michael Breakspear. Computational models link cellular mechanisms of neuromodulation to large-scale neural dynamics. *Nature Neuroscience*, 24(6):765–776, 2021.
- [47] Daniel Durstewitz, Georgia Koppe, and Moritz I Thurm. Reconstructing computational system dynamics from neural data with recurrent neural networks. *Nature Reviews Neuroscience*, 24(11):693–710, 2023.
- [48] Matias Cucchi, Samuel Abreu, Guido Ciccone, Daniel Brunner, and Hans Kleemann. Hands-on reservoir computing: a tutorial for practical implementation. *Neuromorphic Computing and Engineering*, 2(3):032002, 2022.
- [49] Ming Yan, Cheng Huang, Peter Bienstman, Peter Tino, Weiqiang Lin, and Jianwei Sun. Emerging opportunities and challenges for the future of reservoir computing. *Nature Communications*, 15(1):2056, 2024.
- [50] Devi Sarishma, Swati Sangwan, Ritu Tomar, and Rakesh Srivastava. *A review on cognitive computational neuroscience: overview, models, and applications*, pages 217–234. 2022.
- [51] Jean-Paul Noel and Dora E Angelaki. Cognitive, systems, and computational neurosciences of the self in motion. *Annual Review of Psychology*, 73:103–129, 2022.
- [52] Herbert Jaeger. Echo state network. *Scholarpedia*, 2(9):2330, 2007.
- [53] Pramuditha Wijesinghe, Ganesh Srinivasan, Pranab Panda, and Kaushik Roy. Analysis of liquid ensembles for enhancing the performance and accuracy of liquid state machines. *Frontiers in Neuroscience*, 13:454715, 2019.
- [54] Mehmet C. Ozturk, Dong Xu, and Jose C. Principe. Analysis and design of echo state networks. *Neural Computation*, 19(1):111–138, 2007.
- [55] Santiago Basterrech and Gerardo Rubino. Evolutionary echo state network: A neuroevolutionary framework for time series prediction. *Applied Soft Computing*, 144:110463, 2023.
- [56] Qi Ma, Zibin Zheng, Wei Zhuang, Enhong Chen, Jie Wei, and Jian Wang. Echo memory-augmented network for time series classification. *Neural Networks*, 133:177–192, 2021.
- [57] Xue Wang, Yu Jin, and Kuangrong Hao. Echo state networks regulated by local intrinsic plasticity rules for regression. *Neurocomputing*, 351:111–122, 2019.
- [58] Šimon Babinec and Jiří Pospíchal. Improving the prediction accuracy of echo state neural networks by anti-oja’s learning. In *International Conference on Artificial Neural Networks*, pages 19–28, Berlin, Heidelberg, September 2007. Springer Berlin Heidelberg.
- [59] S. X. Lun, X. S. Yao, and H. F. Hu. A new echo state network with variable memory length. *Information Sciences*, 370:103–119, 2016.
- [60] Yannick Roy, Hubert Banville, Isabela Albuquerque, Alexandre Gramfort, Tiago H Falk, and Jocelyn Faubert. Deep learning-based electroencephalography analysis: a systematic review. *Journal of neural engineering*, 16(5):051001, 2019.
- [61] Herbert Jaeger. The “echo state” approach to analysing and training recurrent neural networks—with an erratum note. Technical Report 148(34), German National Research Center for Information Technology GMD Technical Report, Bonn, Germany, 2001.

- [62] Kohei Nakajima. Physical reservoir computing—an introductory perspective. *Japanese Journal of Applied Physics*, 59(6):060501, 2020.
- [63] Mantas Lukoševičius and Herbert Jaeger. Reservoir computing approaches to recurrent neural network training. *Computer Science Review*, 3(3):127–149, 2009.
- [64] Bin He, Han Yuan, Jia Meng, and Shangkai Gao. Brain–computer interfaces. In *Neural Engineering*, pages 131–183. 2020.
- [65] Herbert Jaeger and Harald Haas. Harnessing nonlinearity: Predicting chaotic systems and saving energy in wireless communication. *Science*, 304(5667):78–80, 2004.
- [66] Chunhong Wan, Ming Pei, Kai Shi, Han Cui, Hao Long, Lili Qiao, and Qing Wan. Toward a brain-neuromorphics interface. *Advanced Materials*, 2311288, 2024.
- [67] Fernando C Cardoso, Ricardo A Berri, Eduardo N Borges, Bruno L Dalmazo, Guilherme Lucca, and Vinícius L D de Mattos. Echo state network and classical statistical techniques for time series forecasting: A review. *Knowledge-Based Systems*, page 111639, 2024.
- [68] Eduardo E. Benarroch. *Neocortical Organization and Circuits*. Oxford Academic, New York, online edition edition, 2021.
- [69] Luca Manneschi, Andrew C Lin, and Eleni Vasilaki. Sparce: Improved learning of reservoir computing systems through sparse representations. *IEEE Transactions on Neural Networks and Learning Systems*, 2021.
- [70] Sebastian Bobadilla-Suarez, Christian Ahlheim, Ankit Mehrotra, et al. Measures of neural similarity. *Computational Brain & Behavior*, 3(4):369–383, 2020.
- [71] A. L. Roskies. Representational similarity analysis in neuroimaging: proxy vehicles and provisional representations. *Synthese*, 199(1-2):5917–5935, 2021.
- [72] Alejandro Barredo Arrieta, Sergio Gil-Lopez, Ibai La na, Miren Nekane Bilbao, and Javier Del Ser. On the post-hoc explainability of deep echo state networks for time series forecasting, image and video classification. In *Proceedings of the International Conference on Deep Learning Applications*, Location, Country, 2024. TECNALIA, Basque Research and Technology Alliance (BRTA), University of the Basque Country (UPV/EHU). Manuscript submitted for publication.
- [73] Charles L. Webber Jr and Joseph P. Zbilut. Recurrence quantification analysis of nonlinear dynamical systems. *Tutorials in contemporary nonlinear methods for the behavioral sciences*, 94(2005):26–94, 2005.
- [74] Norbert Marwan and K. Hauke Kraemer. Trends in recurrence analysis of dynamical systems. *The European Physical Journal Special Topics*, 232(1):5–27, 2023.
- [75] Andrew M. Fraser and Harry L. Swinney. Independent coordinates for strange attractors from mutual information. *Physical Review A*, 33(2):1134–1140, 1986.
- [76] Herbert Jaeger. Tutorial on training recurrent neural networks, covering bppt, rtrl, ekf and the .echo state network.^pproach. *GMD-Forschungszentrum Informationstechnik*, 2002.
- [77] Wolfgang Maass, Thomas Natschläger, and Henry Markram. Real-time computing without stable states: A new framework for neural computation based on perturbations. *Neural computation*, 14(11):2531–2560, 2002.

- [78] Claudio Gallicchio, Alessio Micheli, and Luca Pedrelli. Design of deep echo state networks. *Neural Networks*, 108:33–47, December 2018.
- [79] Zuohua Song, Keyu Wu, and Jie Shao. Destination prediction using deep echo state network. *Neurocomputing*, 355:184–192, 2019.
- [80] Ziqiang Li and Gouhei Tanaka. Multi-reservoir echo state networks with sequence resampling for nonlinear time-series prediction. *Neurocomputing*, 467:115–129, 2022.