


Desarrollo de un Framework de Reservoir Computing para el Análisis de Señales EEG en el Estudio del Envejecimiento Neuronal

José Javier Gutiérrez Gil

jogugil@alumni.uv.es, jogugil@gmail.com

Grado en Ciencia de Datos, Universidad Valencia. Escuela Técnica Superior de Ingeniería (ETSE-UV), Valencia, España.



Problema

Se presenta un framework modular de Reservoir Computing (RC) para analizar señales de electroencefalografía (EEG) con el objetivo de identificar patrones predictivos del envejecimiento neuronal y sus efectos en las funciones cognitivas. Utilizando dinámicas temporales en datos reales, el estudio demuestra cómo RC captura complejas dinámicas temporales y su potencial para mejorar la comprensión de los procesos neurobiológicos del envejecimiento. Este enfoque avanza en la neurociencia computacional al ofrecer nuevas herramientas para el análisis de EEG y la identificación de marcadores de envejecimiento neuronal.

Conceptos Base

Adquisición y Preprocesamiento de Datos EEG

El dataset consistió en 47 sujetos (23 jóvenes adultos y 24 adultos mayores) con 64 canales EEG y 7 canales especiales. Las señales fueron normalizadas y truncadas, y la frecuencia de muestreo se redujo por un factor de 4 desde 512 Hz. El preprocesamiento incluyó la eliminación de ruido y artefactos, la corrección por eventos oculares y musculares, y la detección de amplitudes extremas en las señales EEG.

Análisis de Dinámicas Temporales

Una gráfica recurrente [3] es una representación bidimensional que muestra cuándo un sistema dinámico retorna a estados similares, basada en el concepto de "recurrencia".

Para una serie temporal $\{x_i\}_{i=1}^N$, se define una matriz R donde:

$$R_{i,j} = \Theta(\epsilon - \|\mathbf{x}_i - \mathbf{x}_j\|), \quad (1)$$

donde \mathbf{x}_i y \mathbf{x}_j son puntos en el espacio de fases (reconstruido por retardos), $\|\cdot\|$ es la norma euclidiana, ϵ es el umbral de recurrencia y Θ es la función escalón de Heaviside (1 si el argumento es positivo, 0 en caso contrario).

El potencial de memoria [4] se define como el instante t cuando la distancia euclidiana entre el estado inicial y_0 y el estado y_t cae por debajo de ϵ :

$$t = \min \{t \in N \mid \|y_t - y_0\| < \epsilon\} \quad (2)$$

donde y_0 es el estado inicial, y_t es el estado en el tiempo t , y ϵ es el umbral de tolerancia para la repetición del patrón.

Modelo


El modelo RC-ESN usa conexiones recurrentes para mantener memoria a corto plazo, esencial para capturar la dinámica temporal de las señales [1], [2]. La formulación incluyendo los parámetros de fuga α y ruido \mathbf{W}_{noise} , es:

$$\begin{aligned} \mathbf{x}(t) = & (1 - \alpha)\mathbf{x}(t-1) \\ & + \sigma (\mathbf{W}_{in}\mathbf{u}(t) + \mathbf{W}_{res}\mathbf{x}(t-1)) \\ & * \mathbf{W}_{noise} \end{aligned} \quad (3)$$

donde: - \mathbf{W}_{in} y \mathbf{W}_{res} : matriz de pesos de entrada y del reservorio, - σ : función de activación, - α : parámetro de fuga, - \mathbf{W}_{noise} : aplica ruido a los estados internos.

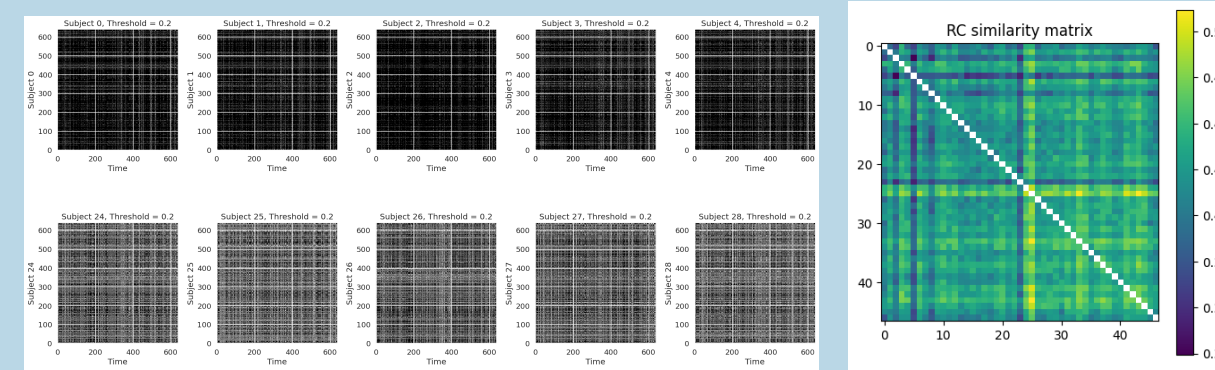
Resultados

El modelo RC-ESN demostró una alta precisión en el agrupamiento/clasificación de las señales EEG según el grupo etario, sugiriendo que estos patrones pueden servir como marcadores predictivos del envejecimiento neuronal. Los resultados indican que el modelo puede ser efectivo llegando a obtener un 0.74 en el agrupamiento mediante k-means como se ve en la matriz de confusión y las métricas asociadas.




La matriz de similitud identifica claramente dos grupos: jóvenes adultos y mayores, lo que demuestra la eficacia del modelo RC-ESN en distinguir las dinámicas temporales entre estos grupos. Las sutiles variaciones entre los jóvenes podrían reflejar diferencias individuales, mientras que la actividad cerebral más uniforme en los mayores sugiere una menor plasticidad neuronal.

Las gráficas de recurrencia muestran una mayor coherencia en los jóvenes, lo que indica una mejor sincronización neuronal en comparación con los mayores, quienes presentan un deterioro en las redes neuronales. Esta disminución en la coherencia podría afectar funciones cognitivas como la memoria y la atención, sugiriendo que mantener la coherencia neuronal en la vejez podría ser crucial.



Los potenciales de memoria muestran una mayor plasticidad en los jóvenes, con diferencias estadísticamente significativas respecto a los mayores. Esta reducción en la plasticidad cerebral en los mayores puede servir como biomarcador para intervenciones dirigidas a mejorar la función cognitiva en la vejez. El valor del t-test, menor a 0.05, confirma la significancia estadística entre los grupos, subrayando la necesidad de estudios longitudinales para desarrollar estrategias efectivas.



Conclusiones

- El framework implementado es robusto, completo y flexible, permitiendo la creación de diversas arquitecturas RC-ESN como el DeepRC, y ha demostrado su eficacia en investigaciones futuras en neurociencia [5].

- El modelo RC-ESN captura eficazmente las dinámicas temporales neuronales, facilitando la investigación del envejecimiento cerebral.

- Se observa mayor sincronización y adaptabilidad en cerebros jóvenes, mientras que los mayores muestran menor plasticidad neuronal. Estas diferencias respaldan las hipótesis sobre la disminución de la funcionalidad cognitiva con la edad y podrían contribuir a la detección temprana de alteraciones cognitivas.

- Futuras investigaciones podrían optimizar el framework y explorar su aplicación en el análisis de otras señales neurofisiológicas.

Para mayor compresión del rabajo e puede visitar la wweb del proyecto [5]

Referencias

- [1] G. Tanaka, T. Yamane, J.-B. Héron, R. Nakane, N. Kanazawa, S. Takeda, and A. Hirose, *Recent advances in physical reservoir computing: A review*, Neural Networks, vol. 115, pp. 100–123, 2019.
- [2] M. Lukosevicius and H. Jaeger, *Reservoir computing approaches to recurrent neural network training*, Computer Science Review, vol. 3, no. 3, pp. 127–149, 2009.
- [3] C. L. Webber Jr and J. P. Zbilut, *Recurrence quantification analysis of nonlinear dynamical systems*, Tutorials in Contemporary Nonlinear Methods for the Behavioral Sciences, vol. 94, no. 2005, pp. 26–94, 2005.
- [4] H. Jaeger, *Tutorial on training recurrent neural networks, covering bppt, rtntl, ekf and the "echo state network" approach*, GMD-Forschungszentrum Informationstechnik, 2002.
- [5] Jogugil, *MyRC: Página web del proyecto*, <https://github.com/jogugil/MyRC>, accedido el 12 de julio de 2024.

Acknowledgements

Agradecemos al equipo de investigación y al profesorado del Grado de Ciencias de Datos de la Universidad de Valencia por su colaboración esencial en la realización de este estudio.