

# MODELIZACIÓ DE PATRONES NEURONALES A PARTIR DE SEÑALES EEG

*“Reservoir Computing Echo State Network”*



**José Javier Gutiérrez Gil**

[jogugil@alumni.uv.es](mailto:jogugil@alumni.uv.es)

*Tutora: Yolanda Vives*

VNIVERSITAT  
ID VALÈNCIA

Grau en Ciència de Dades  
Escola Tècnica Superior d'Enginyeria (ETSE-UV)


# Tabla de contenidos



- 1. Introducción*
- 2. Señales EEG*
- 3. MyRC (ESN)*
- 4. Resultados*
- 5. Conclusiones y Discusión*




# Introducción: Estado del arte




*Tendencia temporal en investigaciones sobre el procesamiento y uso del EEG.*

Research Area	Record Count ( % of 65,195)
Neurosciences Neurology	51,641 (79.210 %)
Computer Science	33,204 (50.930 %)
Engineering	32,400 (49.697 %)
Radiology Nuclear Medicine Medical Imaging	31,437 (48.220 %)
Mathematical Computational Biology	27,990 (42.933 %)
Behavioral Sciences	23,667 (36.302 %)
Communication	22,608 (34.678 %)
Psychology	21,867 (33.541 %)
Mathematics	20,288 (31.119 %)
Science Technology Other Topics	12,882 (19.759 %)
Physiology	6,735 (10.331 %)
Psychiatry	6,269 (9.616 %)
Pediatrics	6,099 (9.355 %)
Ophthalmology	5,694 (8.734 %)
Instruments Instrumentation	4,895 (7.508 %)
Automation Control Systems	4,438 (6.807 %)

*Área de conocimiento (WoS)*



*Investigaciones última década sobre el procesamiento EEG con RC-ESN*

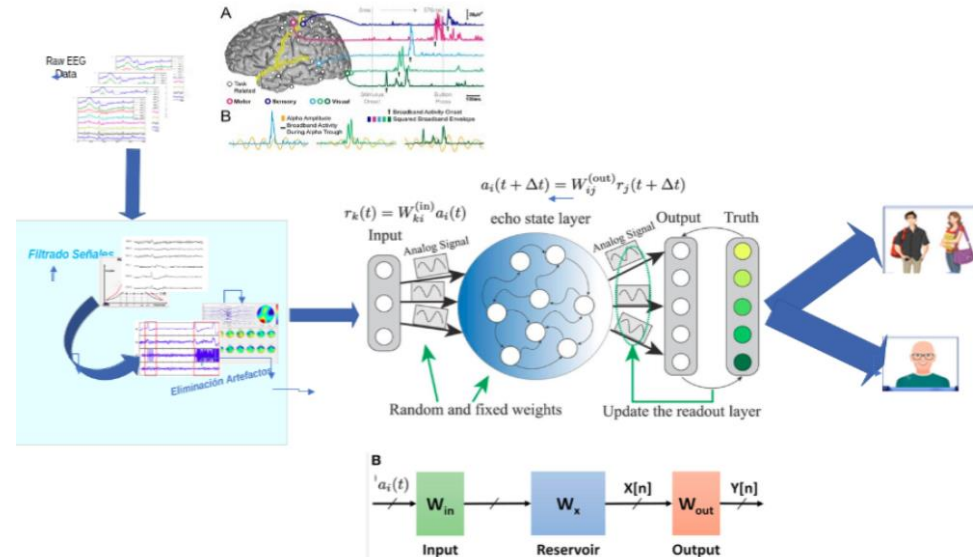
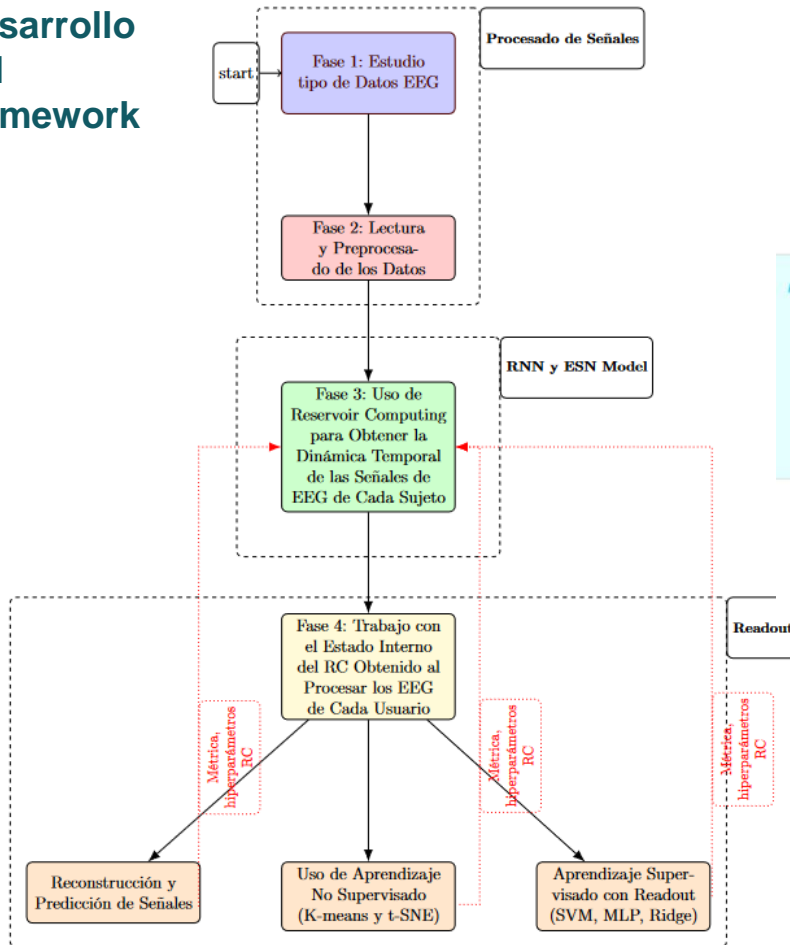


*Neurociencia y Deep learning*

*J. Neural Eng. 16 (2019) 051001 (37pp): Deep learning-based electroencephalo-graphy analysis: a systematic review*

# Objetivos: EEG - RC ESN

## 1. Desarrollo del framework




## 2. Uso del framework con:


- Datos sintéticos
- Datos reales

*Diagrama principal del proceso de desarrollo de RC ESN para señales EEG*

# Señales EEG: Datos sintéticos




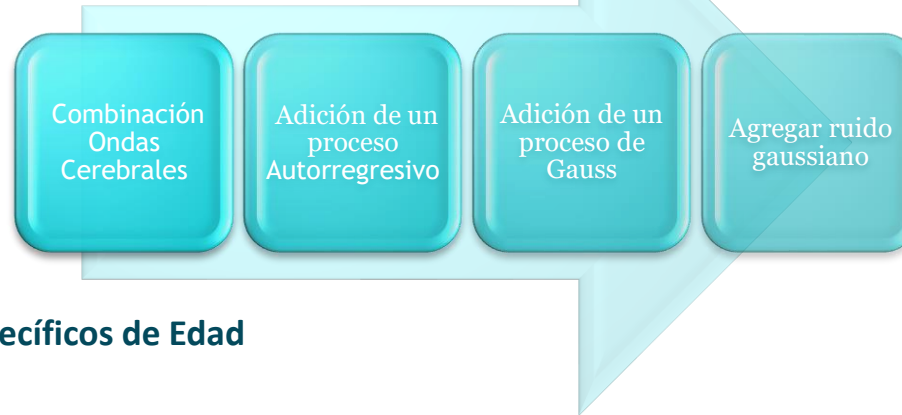
Enfoque Basado en  
Bandas de Frecuencia



Incorporación de Patrones Específicos de Edad

Diferencia Amplitud y  
Frecuencia en onda Beta

Procesos estocásticos



20 Sujetos jóvenes Adultos  
20 Sujetos Mayores

$n_{\text{subjects\_per\_group}} = 20$   
 $n_{\text{samples\_per\_subject}} = 1000$   
 $n_{\text{channels}} = 10$


Dinámica Temporal : Autorregresivo




# Señales EEG: Datos reales

23 sujetos adultos jóvenes  
24 sujetos adultos mayores  
Estado de reposo


(i) 64-channel Raw EEG Signals Acquisition  
+ 4 EOG + 4 EMG + Status



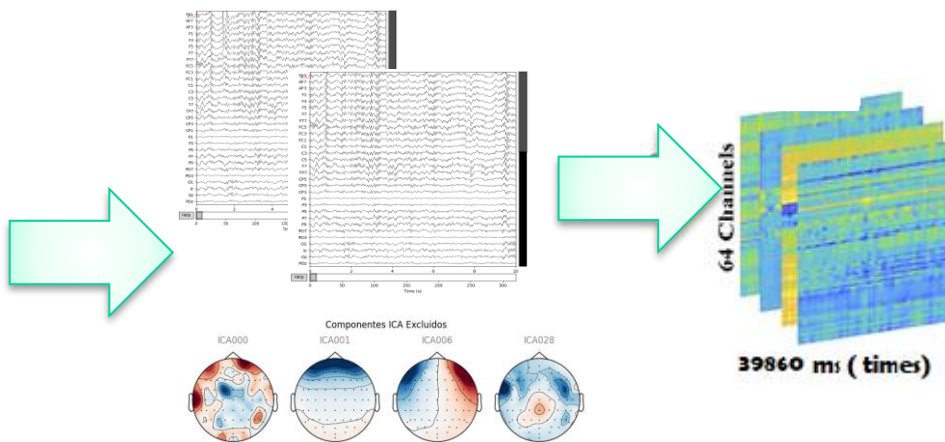

Filtro Paso bajo: 30Khz  
Remuestreamos 512Khz / 4



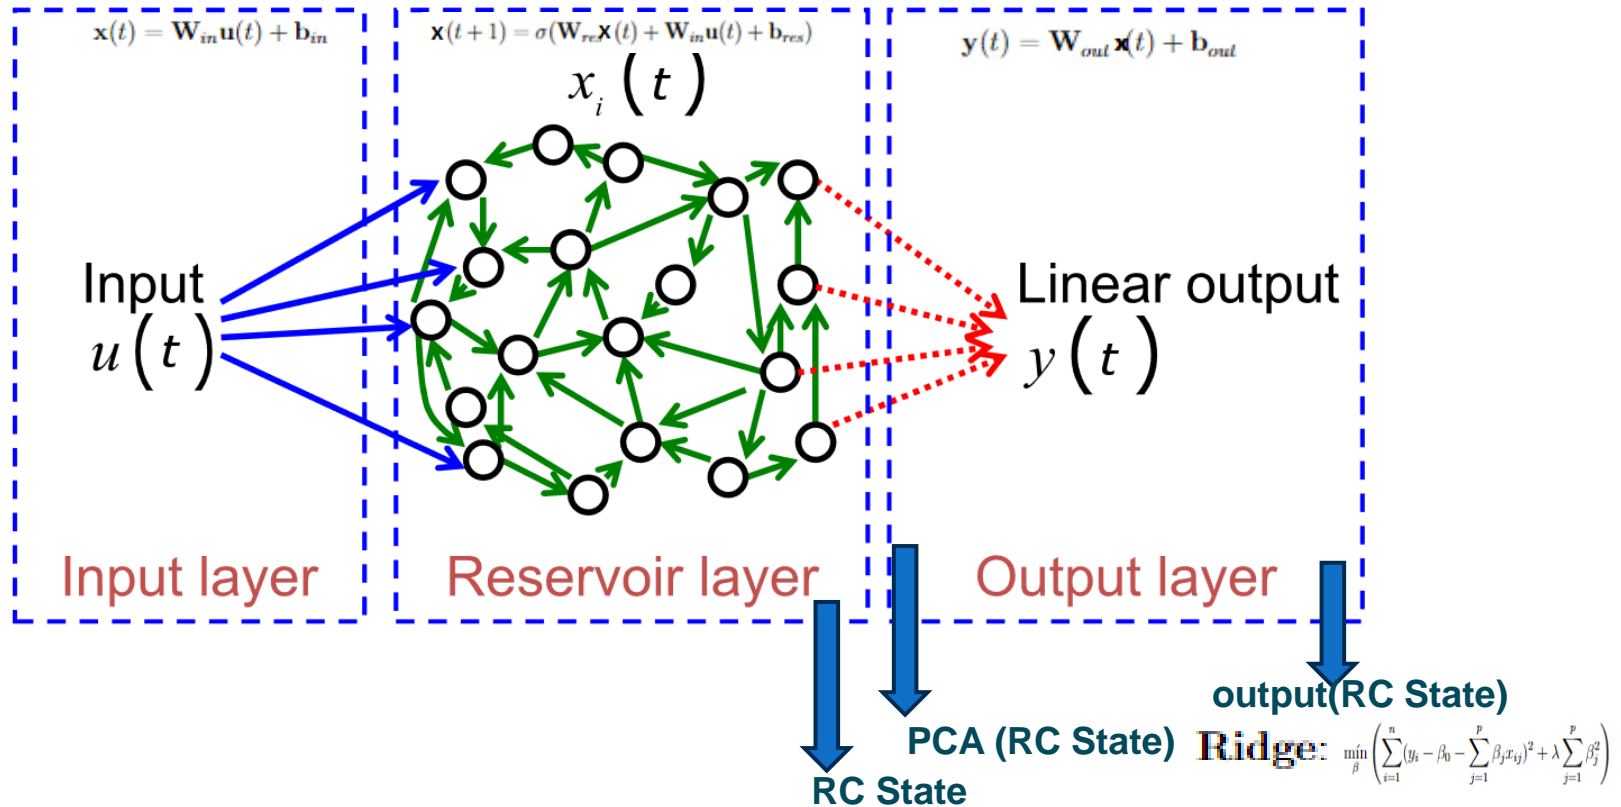
TIPOS Y FRECUENCIAS DE RITMOS CEREBRALES




Eliminación  
Artefactos:  
(EOG, EMG) ICA



# MyRC (ESN): API-Framework





# MyRC (ESN): Config-API

<i>Hiperparámetro</i>	<i>Relación</i>
Cantidad de Neuronas en el Reservorio (N )	$x(t) \in \mathbb{R}_N$
Conectividad del Reservorio	$W_{res}$ y $W_{fb}$
Radio espectral	$\rho$ (rho): Magnitud máxima de los valores propios de la matriz de pesos de la capa interna del RC
Función de Activación	$f(\cdot)$ controla la no linealidad de las dinámicas del reservorio
Fuga ( $\alpha$ ) (leak):	Tasa a la que la actividad de las neuronas en el reservorio decaen con el tiempo.
Ruido ( $\sigma$ )	componente estocástica en las ecuaciones de estado de las neuronas
Dimensión PCA	Reducción número neuronas en el estado del RC
Ouput RC	Salida del RC (last, mean, ridge)



# MyRC (ESN): Métricas


## Gráficos de recurrencia

*Momentos en los que un sistema dinámico retorna a estados similares.*

Para una **serie temporal**  $(\{X_i\}_{i=1}^N)$ , la **gráfica recurrente** se define como una **matriz (R)** donde cada elemento  $(R_{i,j})$  se determina de la siguiente manera:

$$R_{i,j} = \Theta(\epsilon - \|x_i - x_j\|)$$

$\Theta$  es la función escalón de Heaviside, que es 1 si el argumento es positivo y 0 en caso contrario.



**A** señal aleatoria ( $m = 4$  y  $d = 1$ ), **B**: determinista ( $m = 2$  y  $d = 3$ ) y **C**: caótica ( $m = 2$  y  $d = 16$ ). Mateos Salgado, Erik & Domínguez, Benjamín. (2011). [9]

## Potencial de memoria






*Instante de tiempo  $t$  en el cual la distancia euclidiana entre el estado inicial  $y_0$  y el estado  $y_t$  de la serie temporal cae por debajo de un umbral de tolerancia  $\epsilon$*


$$t = \min \{t \in N \mid \|y_t - y_0\| < \epsilon\}$$

$t$  indica primer momento en el cual se detecta que el sistema retorna a un estado similar a la situación inicial. (duración de los patrones recurrentes en los datos de EEG)

# RESULTADOS: *RECON - PREDICCIÓN*

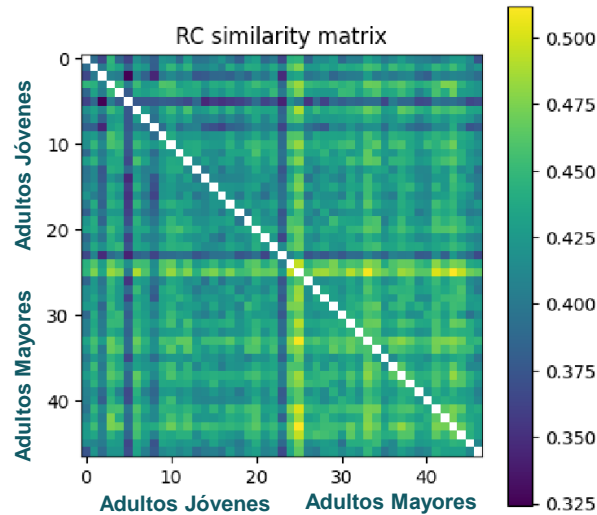
## *Datos sintéticos*






# Resultados: No supervisado (datos reales)

## Matriz similitud




## Gráficos de Recurrencia

### Adultos Jóvenes



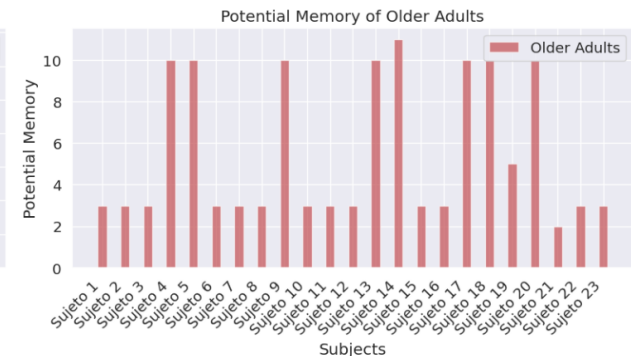

### Adultos Mayores



## Potencial de memoria

Métrica	Valor
Mean young	8.13
Mean older	5.52
T-statistic	2.09
P-value	0.0428

Con un p-valor menor 0.05 podemos indicar que existe suficiente significancia estadística para indicar una diferencia entre las dos clases.



# Resultados: No supervisado (K-means)

Classification Report  
Accuracy: 0.72

	f1-score	precision	recall	support
0	0.72	0.71	0.74	23.00
1	0.72	0.74	0.71	24.00
weighted avg macro avg	0.72	0.72	0.72	47.00
	0.72	0.72	0.72	47.00

Métricas agrupación datos reales con eliminación artefactos mediante Kmeans  
(0:Grupo jóvenes adultos; 1: Grupo Mayores)

Confusion Matrix

	0	1
0	17	6
1	7	17

Matriz confusión datos reales con eliminación artefactos(0:Grupo jóvenes adultos; 1: Grupo Mayores).


# Resultados: Supervisado (datos reales)

Conjunto de train: 80%  
Conjunto de test: 20%


Readaout:mlp (Multi-Layer Perceptron Classifier)


Clase	Precisión	Recall	F1-score	Soporte
0	0.80	0.57	0.67	7
1	0.79	0.92	0.85	12
Exactitud	0.79			
Promedio macro	0.79	0.74	0.76	19
Promedio ponderado	0.79	0.79	0.78	19

Matriz de confusión de test



*0: Jóvenes adultos*  
*1: Adultos mayores*





# Conclusiones

## **Beneficios**

- ☐ Robustez ante ruido.
- ☐ Obtención dinámica temporal series temporales.
- ☐ No se necesita obtención de características(Temporales/Frecuenciales).
- ☐ Menor capacidad computo
- ☐ Facilidad de implementación


## **Desventajas**

- ☐ Gran sensibilidad ante valores hiperparámetros.
- ☐ Dependencia al tipo de dato y a las características de los mismos.

## **Web del Proyecto MyRC (GitHub)**

<https://github.com/jogugil/MyRC>






# Discusión: Trabajo futuro

- ❑ Estudio extensivo basado en los resultados y teorías de neurociencia sobre la distinción entre jóvenes adultos y mayores
- ❑ Búsqueda automática de hiperparámetros óptimos del Reservoir Computing ESN
- ❑ Importancia de hiperparámetros en la resolución del problema neurocientífico
- ❑ Pruebas con la implementación de DeepMyRC para la resolución de este problema u otros similares
- ❑ Técnicas de extracción características del estado interno del RC-ESN como entrada al readout.
- ❑ Utilización de la implementación del API del RC para la resolución de otro tipo de problemas asociados al procesamiento de señales EEG





# Bibliografía

- [1] H. Jaeger, “The” echo state” approach to analysing and training recurrent neural networks-with an erratum note,” Bonn, Germany: German National Research Center for Information Technology GMD Technical Report, vol. 148, 01 2001
- [2] G. Tanaka, T. Yamane, J.-B. Héroux, R. Nakane, N. Kanazawa, S. Takeda, and A. Hirose, “Recent advances in physical reservoir computing: A review,” *Neural Networks*, vol. 115, pp. 100–123, 201
- [3] M. Lukoševičius and H. Jaeger, “Reservoir computing approaches to recurrent neural network training,” *Computer science review*, vol. 3, no. 3, pp. 127–149, 2009.
- [4] L. Lin, C. Jin, Z. Fu, B. Zhang, G. Bin, and S. Wu, “Predicting healthy older adult’s brain age based on structural connectivity networks using artificial neural networks,” *Computer Methods and Programs in Biomedicine*, vol. 125, 12 2015
- [5] A. B. Arrieta, S. Gil-Lopez, I. L. na, M. N. Bilbao, and J. D. Ser, “On the post-hoc explainability of deep echo state networks for timeseries forecasting, image and video classification,” in *Proceedings of the International Conference on Deep Learning Applications*. Location, Country: TECNALIA, Basque Research and Technology Alliance (BRTA), University of the Basque Country (UPV/EHU), 2024
- [6] C. L. Webber Jr and J. P. Zbilut “Recurrence quantification analysis of nonlinear dynamical systems,” *Tutorials in contemporary nonlinear methods for the behavioral sciences*, vol. 94, no. 2005, pp. 26–94, 200
- [7] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Design of deep echo state networks, *Neural Networks*, Volume 108, 2018, Pages 33–47, ISSN 0893-6080, <https://doi.org/10.1016/j.neunet.2018.08.002>. (<https://www.sciencedirect.com/science/article/pii/S0893608018302223>)
- [8] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Deep reservoir computing: A critical experimental analysis, *Neurocomputing*, Volume 268, 2017, Pages 87–99, ISSN 0925-2312, <https://doi.org/10.1016/j.neucom.2016.12.089>. (<https://www.sciencedirect.com/science/article/pii/S0925231217307567>)
- [9] Mateos Salgado, Erik & Dominguez, Benjamin. (2011). Análisis de recurrencia visual de temperatura periférica en la evaluación de un tratamiento psicológico del dolor basado en un diseño N = 1. *Psicología y Salud*. 21. 111–117.