

MODELIZACIÓN DE PATRONES NEURONALES A PARTIR DE SEÑALES EEG

“Reservoir Computing Echo State Network”



José Javier Gutiérrez Gil

jogugil@alumni.uv.es

VNIVERSITAT
D VALÈNCIA

Grau en Ciència de Dades

Escola Tècnica Superior d'Enginyeria (ETSE-UV)

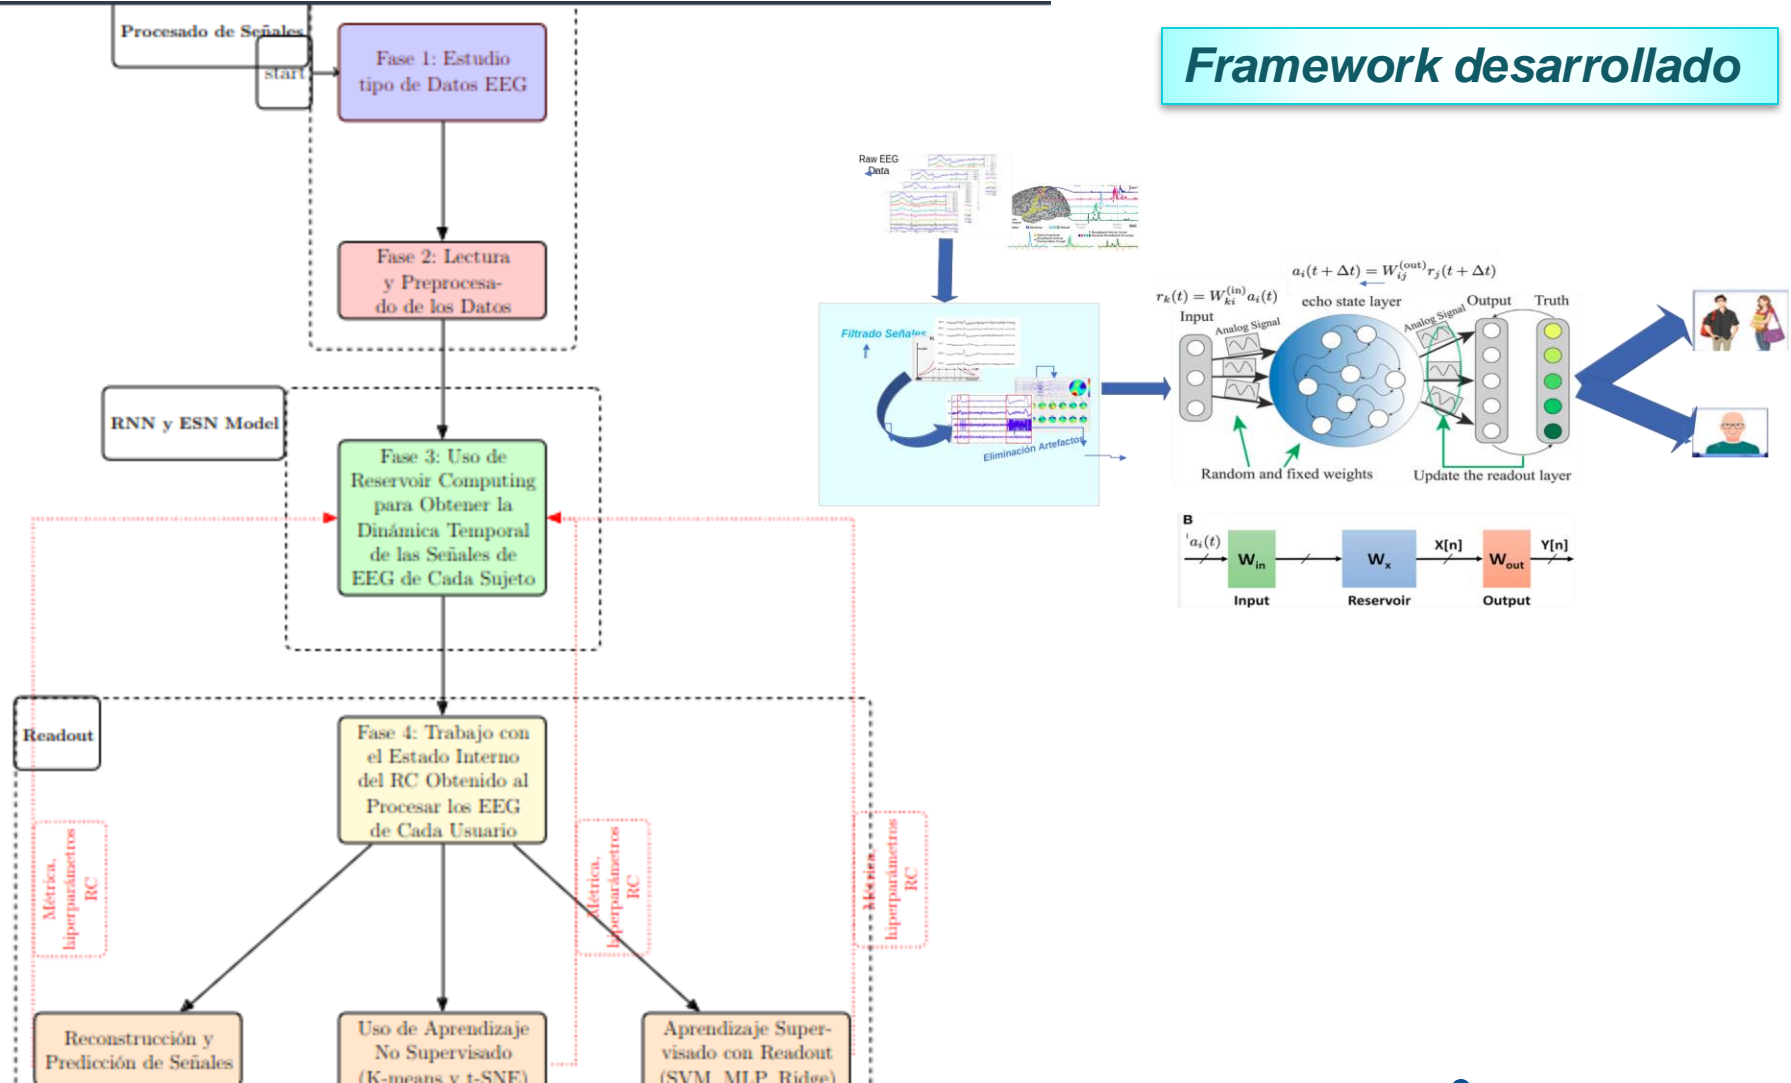
Tabla de contenidos



- 1. Introducción*
- 2. Señales EEG*
- 3. MyRC (ESN)*
- 4. Resultados*
- 5. Conclusiones y Discusión*

Introducción: EEG - RC ESN

Framework desarrollado



Introducción: Estado del arte



Figura 2.1: Tendencia temporal: EEG processing. (WoS)





Figura 2.10: Número de Investigaciones Uso RC para procesamiento de señales EEG, por Año. WoS

Research Area	Record Count (% of 65,195)
Neurosciences Neurology	51,641 (79.210 %)
Computer Science	33,204 (50.930 %)
Engineering	32,400 (49.697 %)
Radiology Nuclear Medicine Medical Imaging	31,437 (48.220 %)
Mathematical Computational Biology	27,990 (42.933 %)
Behavioral Sciences	23,667 (36.302 %)
Communication	22,608 (34.678 %)
Psychology	21,867 (33.541 %)
Mathematics	20,288 (31.119 %)
Science Technology Other Topics	12,882 (19.759 %)
Physiology	6,735 (10.331 %)
Psychiatry	6,269 (9.616 %)
Pediatrics	6,099 (9.355 %)
Ophthalmology	5,694 (8.734 %)
Instruments Instrumentation	4,895 (7.508 %)
Automation Control Systems	4,438 (6.807 %)


Cuadro 2.2: Áreas de Conocimiento. (WoS)

Subject area ↓	Documents ↓
Computer Science	32
Mathematics	14
Engineering	9
Medicine	5
Neuroscience	4
Physics and Astronomy	4
Energy	1
Materials Science	1
Psychology	1


Documents by subject area



Señales EEG: Datos sintéticos




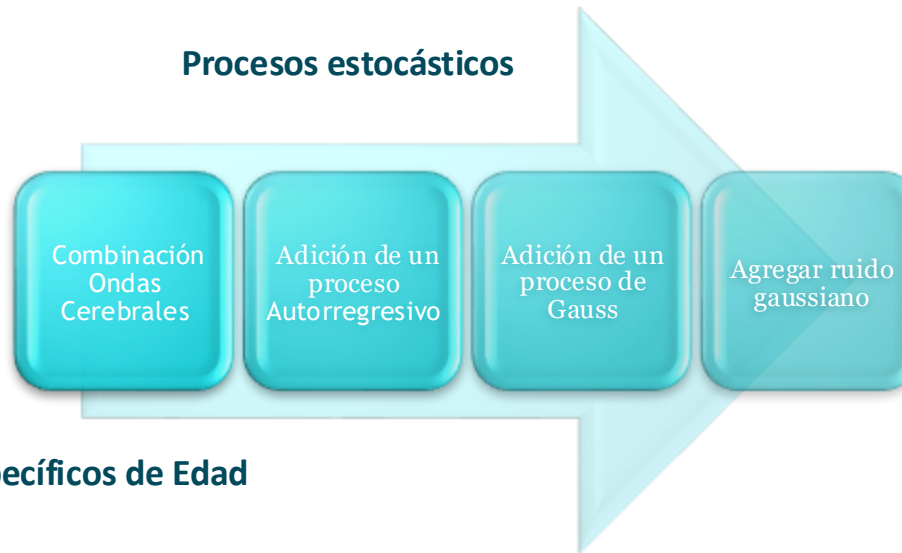
Enfoque Basado en Bandas de Frecuencia



Incorporación de Patrones Específicos de Edad

Diferencia Amplitud y Frecuencia en onda Beta

Procesos estocásticos




20 Sujetos jóvenes Adultos
20 Sujetos Mayores


$n_{\text{subjects_per_group}} = 20$
 $n_{\text{samples_per_subject}} = 1000$
 $n_{\text{channels}} = 10$

Dinámica Temporal : Autorregresivo

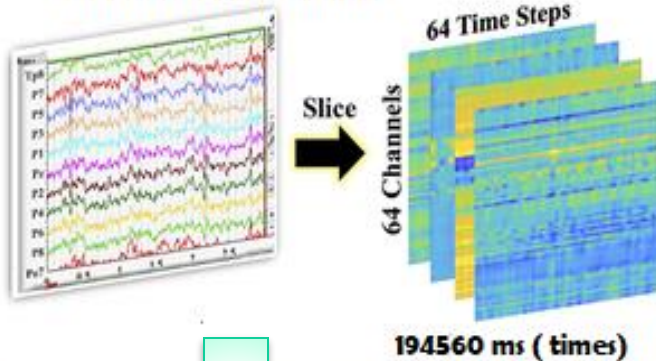
Señales EEG: Datos reales




TIPOS Y FRECUENCIAS DE RITMOS CEREBRALES








(i) 64-channel Raw EEG Signals Acquisition
+ 4 EOG + 4 EMG + Status



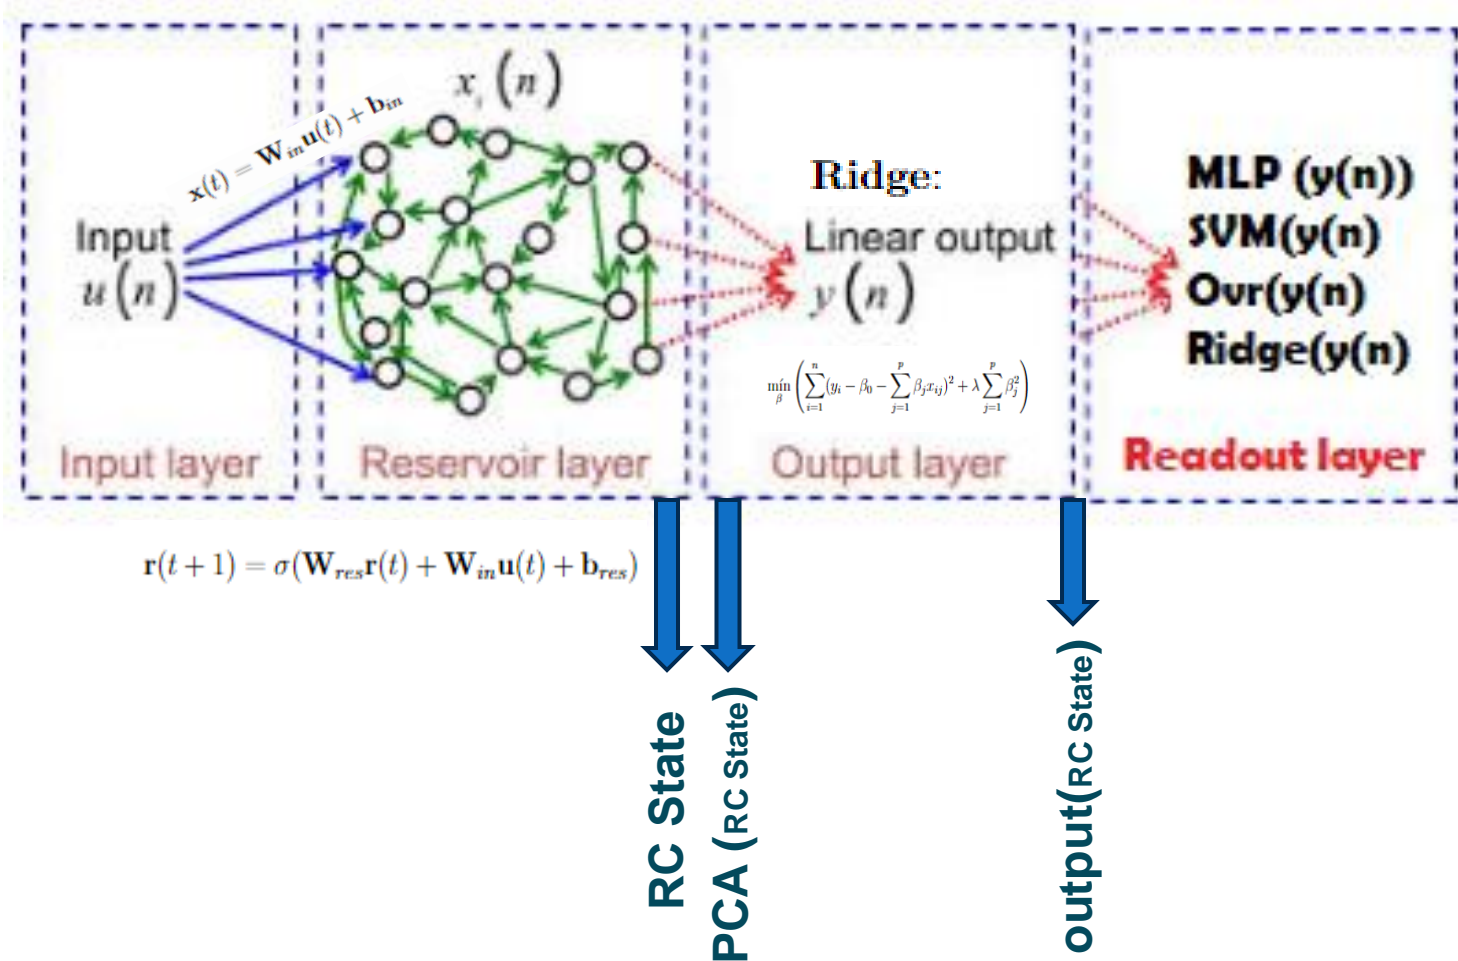
Filtro Paso bajo: 30Khz
Remuestreamos 512Khz / 4



Eliminación
Artefactos: ICA
(EOG,EMG)




MyRC (ESN): API-Framework

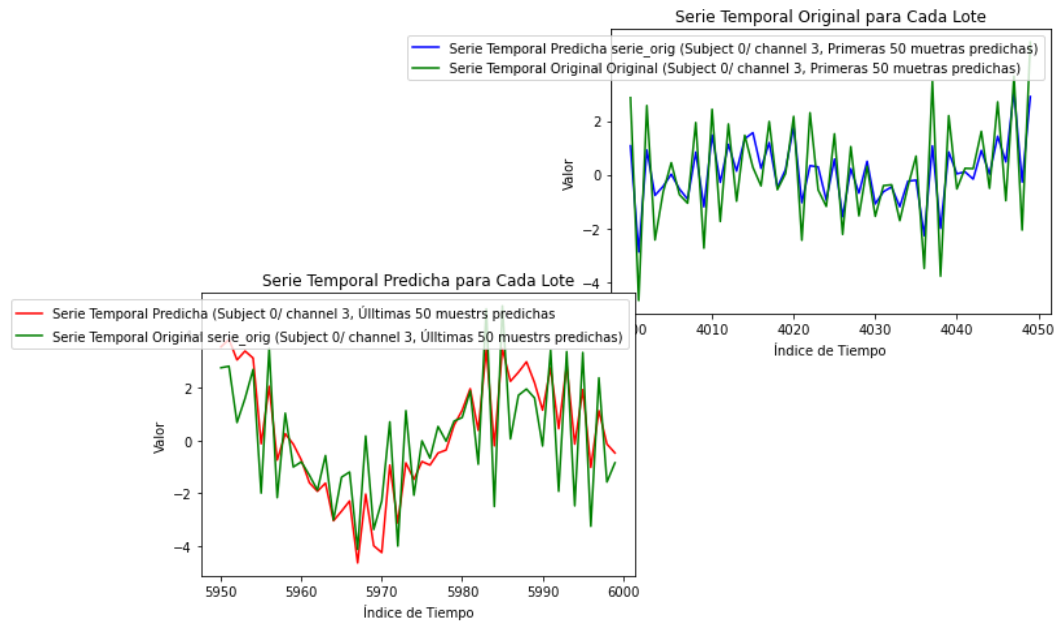





MyRC (ESN): Config-API

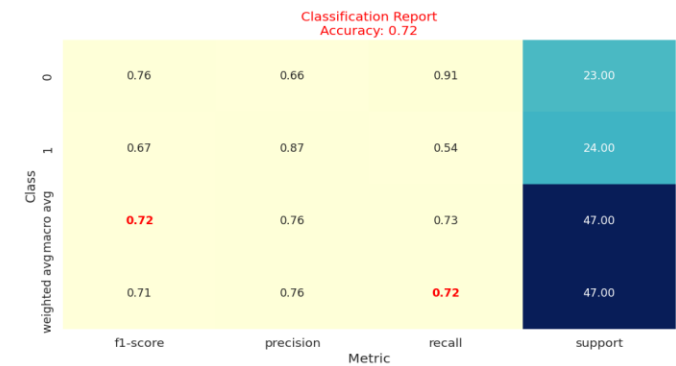
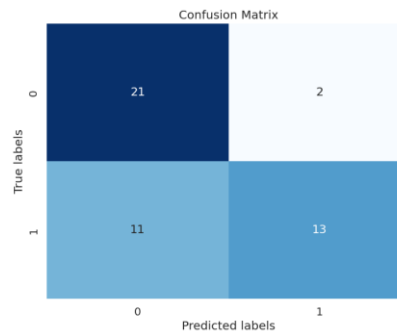

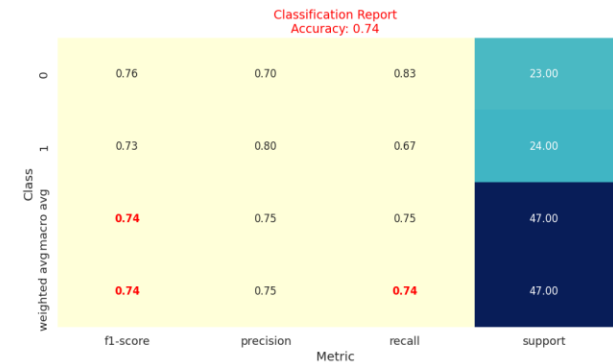

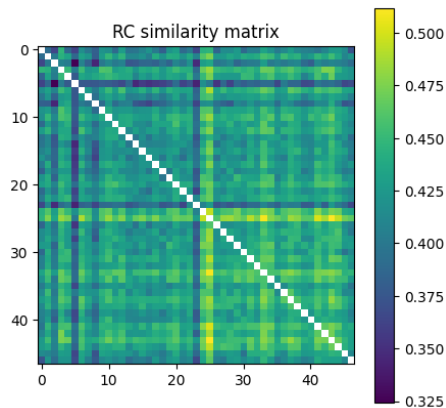
<i>Hiperparámetro</i>	<i>Relación</i>
Cantidad de Neuronas en el Reservorio (N)	$x(t) \in \mathbb{R}_N$
Conectividad del Reservorio	W_{res} y W_{fb}
Función de Activación	$f(\cdot)$ controla la no linealidad de las dinámicas del reservorio
Fuga (α) (leak):	Tasa a la que la actividad de las neuronas en el reservorio decaen con el tiempo.
Ruido (σ)	componente estocástica en las ecuaciones de estado de las neuronas
Dimensión PCA	Reducción número neuronas en el estado del RC
Ouput RC	Salida del RC (last, mean, ridge)




RESULTADOS: RECONS - PRED (I)



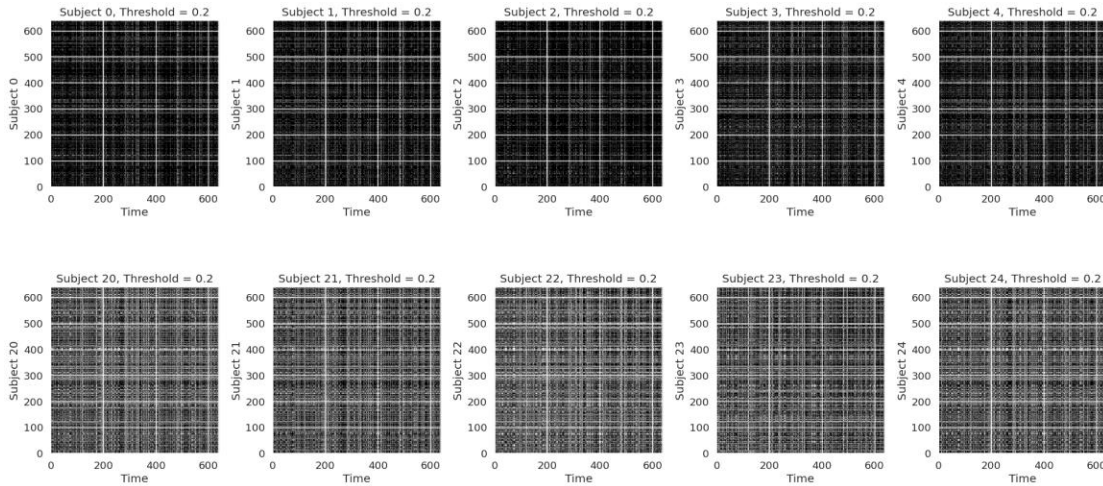
Resultados: No supervisado (K-means)



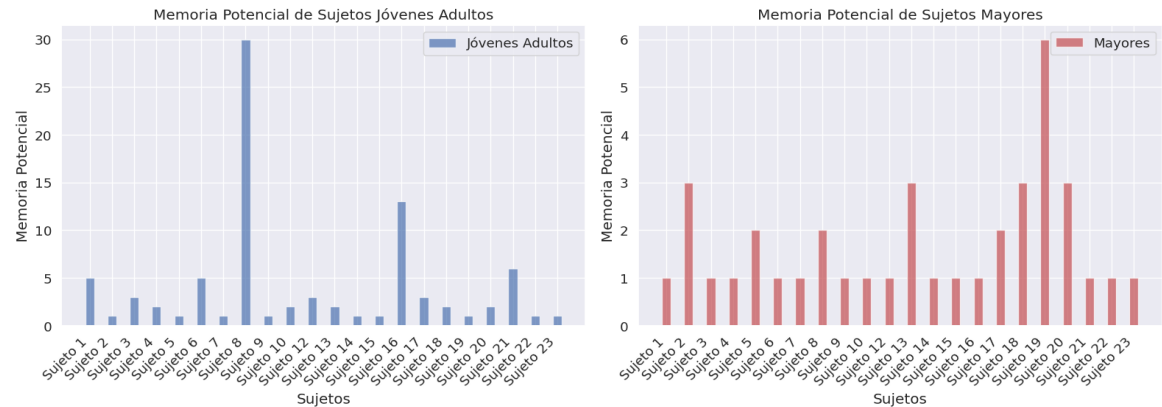



Resultados: No supervisado (Gr)

Gráficos de Recurrencia




Potencial de memoria






Resultados: Supervisado





Exactitud
0.79



Readout:mlp (Multi-Layer Perceptron Classifier)



Readout:lin (Regresión ridge)





Exactitud
0.79



Resultados: DeepMyRC


Claudio Gallicchio [1],[2]




Classification Report
Accuracy: 0.72


	f1-score	precision	recall	support
Class 0	0.75	0.67	0.87	23.00
Class 1	0.68	0.82	0.58	24.00
weighted avg macro	0.72	0.75	0.73	47.00
	0.72	0.75	0.72	47.00

Gráficos de recurrencia



Potencial de memoria





Conclusiones


Beneficios

- ☐ Robustez ante ruido.
- ☐ Obtención dinámica temporal series temporales.
- ☐ No se necesita obtención features (Temporales/Frecuenciales).
- ☐ Menor capacidad computo
- ☐ Facilidad de implementación


DesVentajas

- ☐ Gran sensibilidad ante valores hiperparámetros.
- ☐ Dependencia al tipo de dato y a las características de los mismos.






Discusión: RC-ESN y EEG




- ❑ Desafíos y oportunidades en la integración de datos multidimensionales
 - ❑ Caracterización de la actividad cerebral según la edad
 - ❑ Impacto del envejecimiento en la funcionalidad cognitiva
-
- ❑ Perspectivas futuras y desarrollo del framework
 - ❑ Implicaciones clínicas y potencial terapéutico
 - ❑ Consideraciones sobre la variabilidad y reproducibilidad del modelo



Discusión: Trabajo futuro

- ❑ Estudio extensivo basado en los resultados y teorías de neurociencia sobre la distinción entre jóvenes adultos y mayores
- ❑ Búsqueda automática de hiperparámetros óptimos del Reservoir Computing ESN
- ❑ Importancia de hiperparámetros en la resolución del problema neurocientífico
- ❑ Pruebas con la implementación de DeepMyRC para la resolución de este problema u otros similares
- ❑ Técnicas de extracción características del estado interno del RC-ESN como entrada al readout.
- ❑ Utilización de la implementación del API del RC para la resolución de otro tipo de problemas asociados al procesamiento de señales EEG



Bibliografía

- [1] H. Jaeger, “The” echo state” approach to analysing and training recurrent neural networks-with an erratum note,” Bonn, Germany: German National Research Center for Information Technology GMD Technical Report, vol. 148, 01 2001
- [2] G. Tanaka, T. Yamane, J.-B. Héroux, R. Nakane, N. Kanazawa, S. Takeda, and A. Hirose, “Recent advances in physical reservoir computing: A review,” *Neural Networks*, vol. 115, pp. 100–123, 201
- [3] M. Lukoševičius and H. Jaeger, “Reservoir computing approaches to recurrent neural network training,” *Computer science review*, vol. 3, no. 3, pp. 127–149, 2009.
- [4] L. Lin, C. Jin, Z. Fu, B. Zhang, G. Bin, and S. Wu, “Predicting healthy older adult’s brain age based on structural connectivity networks using artificial neural networks,” *Computer Methods and Programs in Biomedicine*, vol. 125, 12 2015
- [5] A. B. Arrieta, S. Gil-Lopez, I. L. na, M. N. Bilbao, and J. D. Ser, “On the post-hoc explainability of deep echo state networks for timeseries forecasting, image and video classification,” in *Proceedings of the International Conference on Deep Learning Applications*. Location, Country: TECNALIA, Basque Research and Technology Alliance (BRTA), University of the Basque Country (UPV/EHU), 2024
- [6] C. L. Webber Jr and J. P. Zbilut “Recurrence quantification analysis of nonlinear dynamical systems,” *Tutorials in contemporary nonlinear methods for the behavioral sciences*, vol. 94, no. 2005, pp. 26–94, 200
- [7] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Design of deep echo state networks, *Neural Networks*, Volume 108, 2018, Pages 33-47, ISSN 0893-6080, <https://doi.org/10.1016/j.neunet.2018.08.002>. (<https://www.sciencedirect.com/science/article/pii/S0893608018302223>)
- [8] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Deep reservoir computing: A critical experimental analysis, *Neurocomputing*, Volume 268, 2017, Pages 87-99, ISSN 0925-2312, <https://doi.org/10.1016/j.neucom.2016.12.089>. (<https://www.sciencedirect.com/science/article/pii/S0925231217307567>)

