

MODELIZACIÓ DE PATRONES NEURONALES A PARTIR DE SEÑALES EEG

“Reservoir Computing Echo State Network”



José Javier Gutiérrez Gil

jogugil@alumni.uv.es

Tutora: Yolanda Vives

VNIVERSITAT DE VALÈNCIA Grau en Ciència de Dades
Escola Tècnica Superior d'Enginyeria (ETSE-UV)


Tabla de contenidos




- 1. Introducción*
- 2. Señales EEG*
- 3. MyRC (ESN)*
- 4. Resultados*
- 5. Conclusiones y Discusión*



Introducción: Estado del arte




Tendencia temporal en investigaciones sobre el procesamiento y uso del EEG.



Investigaciones última década sobre el procesamiento EEG con RC-ESN

Research Area	Record Count (% of 65,195)
Neurosciences Neurology	51,641 (79.210 %)
Computer Science	33,204 (50.930 %)
Engineering	32,400 (49.697 %)
Radiology Nuclear Medicine Medical Imaging	31,437 (48.220 %)
Mathematical Computational Biology	27,990 (42.933 %)
Behavioral Sciences	23,667 (36.302 %)
Communication	22,608 (34.678 %)
Psychology	21,867 (33.541 %)
Mathematics	20,288 (31.119 %)
Science Technology Other Topics	12,882 (19.759 %)
Physiology	6,735 (10.331 %)
Psychiatry	6,269 (9.616 %)
Pediatrics	6,099 (9.355 %)
Ophthalmology	5,694 (8.734 %)
Instruments Instrumentation	4,895 (7.508 %)
Automation Control Systems	4,438 (6.807 %)

Área de conocimiento (WoS)



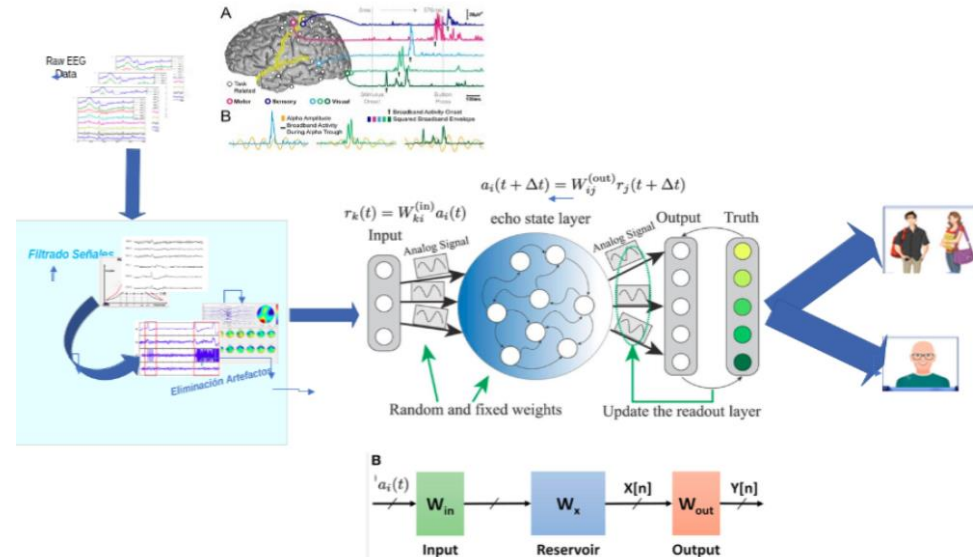
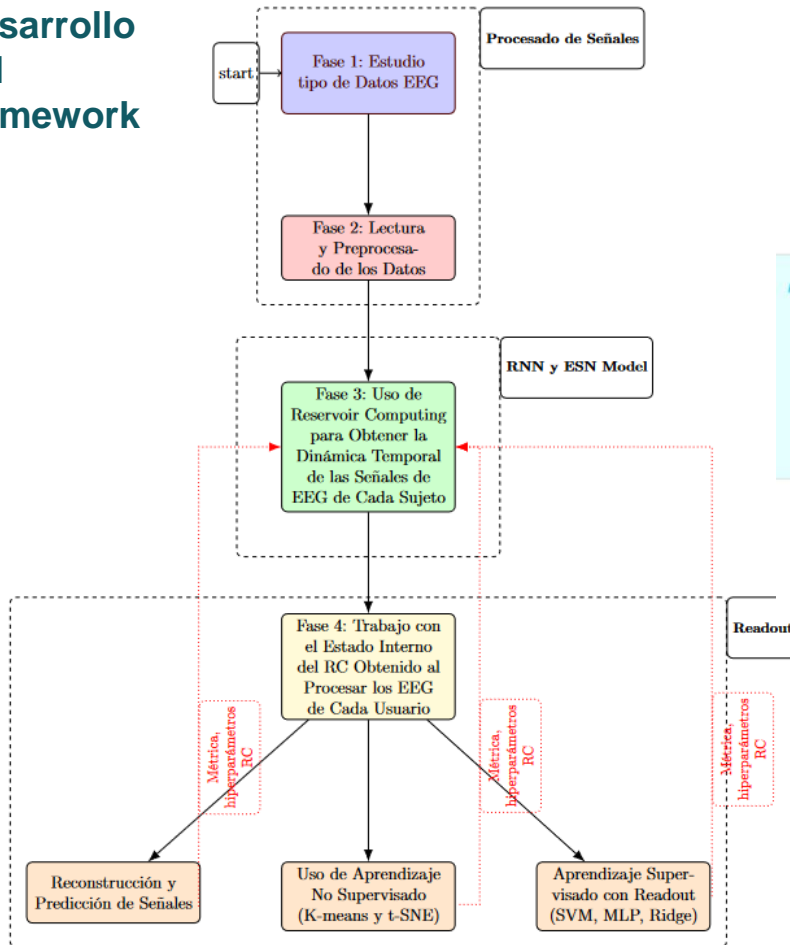
Neurociencia y Deep learning

J. Neural Eng. 16 (2019) 051001 (37pp): Deep learning-based electroencephalo-graphy analysis: a systematic review



Objetivos: EEG - RC ESN

1. Desarrollo del framework




2. Uso del framework con:


- Datos sintéticos
- Datos reales

Diagrama principal del proceso de desarrollo de RC ESN para señales EEG

Señales EEG: Datos sintéticos




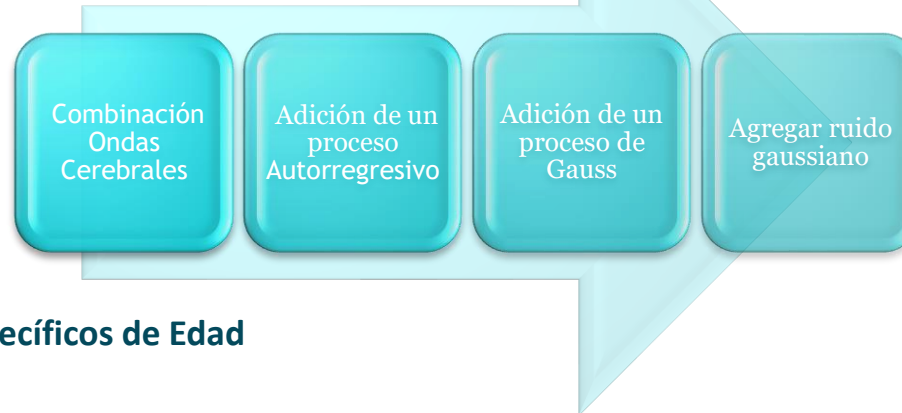
Enfoque Basado en
Bandas de Frecuencia



Incorporación de Patrones Específicos de Edad

Diferencia Amplitud y
Frecuencia en onda Beta

Procesos estocásticos



20 Sujetos jóvenes Adultos
20 Sujetos Mayores

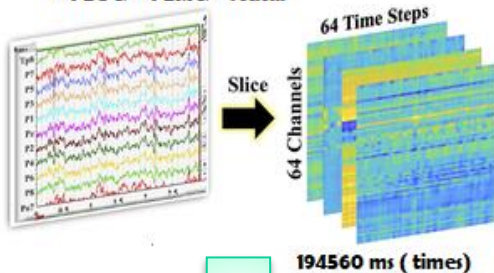
$n_{\text{subjects_per_group}} = 20$
 $n_{\text{samples_per_subject}} = 1000$
 $n_{\text{channels}} = 10$

Dinámica Temporal : Autorregresivo


Señales EEG: Datos reales

23 sujetos adultos jóvenes
24 sujetos adultos mayores
Estado de reposo


(i) 64-channel Raw EEG Signals Acquisition
+ 4 EOG + 4 EMG + Status



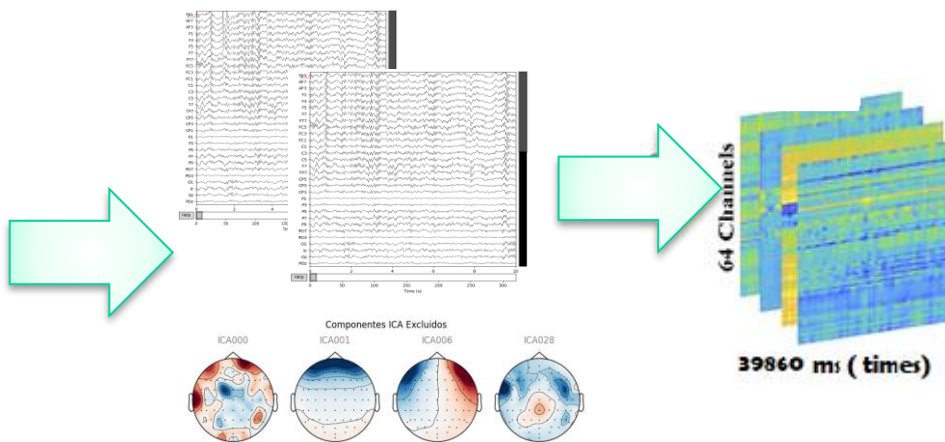

Filtro Paso bajo: 30Khz
Remuestreamos 512Khz / 4



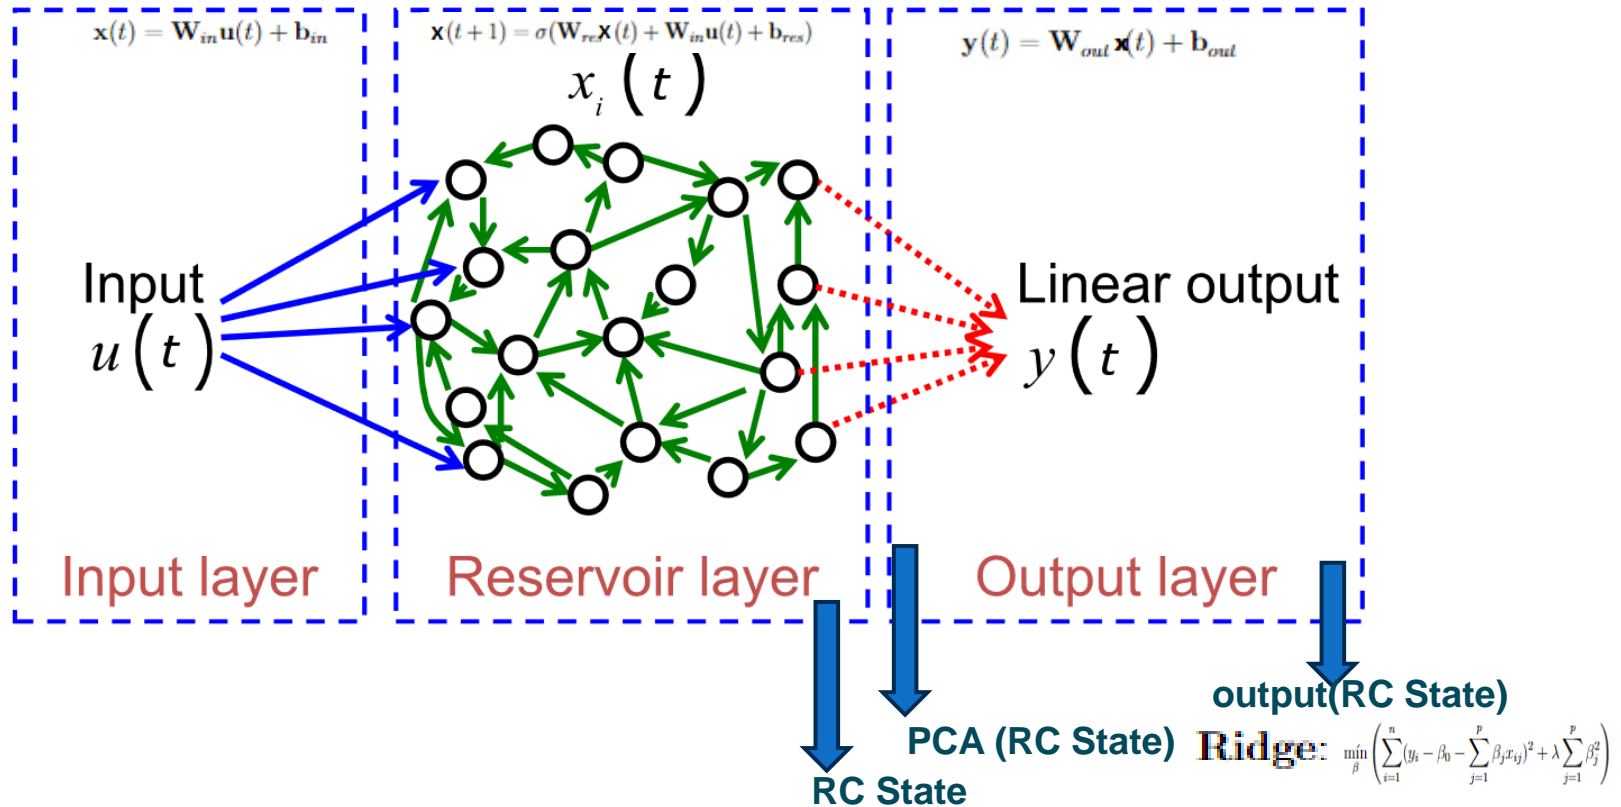
TIPOS Y FRECUENCIAS DE RITMOS CEREBRALES




Eliminación
Artefactos:
(EOG, EMG) ICA



MyRC (ESN): API-Framework





MyRC (ESN): Config-API

<i>Hiperparámetro</i>	<i>Relación</i>
Cantidad de Neuronas en el Reservorio (N)	$x(t) \in \mathbb{R}_N$
Conectividad del Reservorio	W_{res} y W_{fb}
Radio espectral	ρ (rho): Magnitud máxima de los valores propios de la matriz de pesos de la capa interna del RC
Función de Activación	$f(\cdot)$ controla la no linealidad de las dinámicas del reservorio
Fuga (α) (leak):	Tasa a la que la actividad de las neuronas en el reservorio decaen con el tiempo.
Ruido (σ)	componente estocástica en las ecuaciones de estado de las neuronas
Dimensión PCA	Reducción número neuronas en el estado del RC
Ouput RC	Salida del RC (last, mean, ridge)

MyRC (ESN): Métricas


Gráficos de recurrencia

Momentos en los que un sistema dinámico retorna a estados similares.

Para una **serie temporal** $(\{X_i\}_{i=1}^N)$, la **gráfica recurrente** se define como una **matriz (R)** donde cada elemento $(R_{i,j})$ se determina de la siguiente manera:

$$R_{i,j} = \Theta(\epsilon - \|x_i - x_j\|)$$

Θ es la función escalón de Heaviside, que es 1 si el argumento es positivo y 0 en caso contrario.



A **B** **C**
A: señal aleatoria ($m = 4$ y $d = 1$), B: determinista ($m = 2$ y $d = 3$) y C: caótica ($m = 2$ y $d = 16$). Mateos Salgado, Erik & Domínguez, Benjamín. (2011). [9]

Potencial de memoria






Instante de tiempo t en el cual la distancia euclidiana entre el estado inicial y_0 y el estado y_t de la serie temporal cae por debajo de un umbral de tolerancia ϵ


$$t = \min \{t \in N \mid \|y_t - y_0\| < \epsilon\}$$

t indica primer momento en el cual se detecta que el sistema retorna a un estado similar a la situación inicial. (duración de los patrones recurrentes en los datos de EEG)

RESULTADOS: *RECON - PREDICCIÓN*

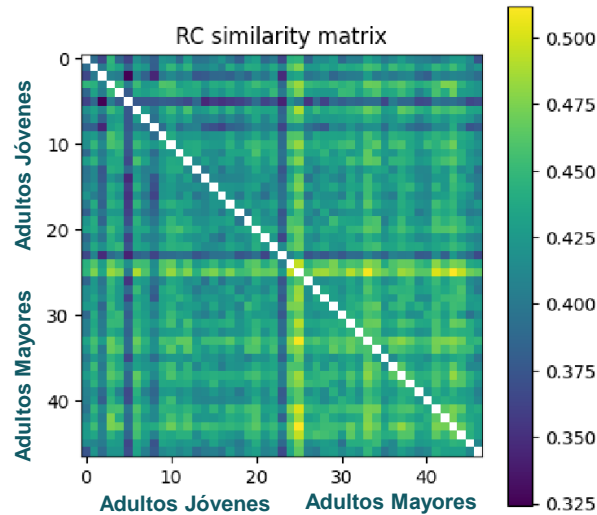
Datos sintéticos






Resultados: No supervisado (datos reales)

Matriz similitud




Gráficos de Recurrencia

Adultos Jóvenes



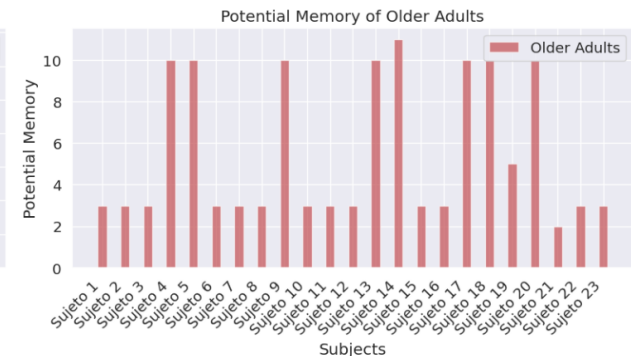

Adultos Mayores



Potencial de memoria

Métrica	Valor
Mean young	8.13
Mean older	5.52
T-statistic	2.09
P-value	0.0428

Con un p-valor menor 0.05 podemos indicar que existe suficiente significancia estadística para indicar una diferencia entre las dos clases.



Resultados: No supervisado (K-means)

Classification Report
Accuracy: 0.72

	f1-score	precision	recall	support
0	0.72	0.71	0.74	23.00
1	0.72	0.74	0.71	24.00
weighted avg macro avg	0.72	0.72	0.72	47.00
	0.72	0.72	0.72	47.00

Métricas agrupación datos reales con eliminación artefactos mediante Kmeans
(0:Grupo jóvenes adultos; 1: Grupo Mayores)

Confusion Matrix

	0	1
0	17	6
1	7	17

True labels

Predicted labels

Matriz confusión datos reales con eliminación artefactos(0:Grupo jóvenes adultos; 1: Grupo Mayores).


Resultados: Supervisado (datos reales)

Conjunto de train: 80%
Conjunto de test: 20%


Readaout:mlp (Multi-Layer Perceptron Classifier)


Clase	Precisión	Recall	F1-score	Soporte
0	0.80	0.57	0.67	7
1	0.79	0.92	0.85	12
Exactitud	0.79			
Promedio macro	0.79	0.74	0.76	19
Promedio ponderado	0.79	0.79	0.78	19

Matriz de confusión de test



0: Jóvenes adultos
1: Adultos mayores





Conclusiones

Beneficios


- ☐ Robustez ante ruido.
- ☐ Obtención dinámica temporal series temporales.
- ☐ No se necesita obtención de características(Temporales/Frecuenciales).
- ☐ Menor capacidad computo
- ☐ Facilidad de implementación

Desventajas

- ☐ Gran sensibilidad ante valores hiperparámetros.
- ☐ Dependencia al tipo de dato y a las características de los mismos.


Web del Proyecto MyRC (GitHub)

<https://github.com/jogugil/MyRC>



Discusión: Trabajo futuro

- ❑ Estudio extensivo basado en los resultados y teorías de neurociencia sobre la distinción entre jóvenes adultos y mayores
- ❑ Búsqueda automática de hiperparámetros óptimos del Reservoir Computing ESN
- ❑ Importancia de hiperparámetros en la resolución del problema neurocientífico
- ❑ Pruebas con la implementación de DeepMyRC para la resolución de este problema u otros similares
- ❑ Técnicas de extracción características del estado interno del RC-ESN como entrada al readout.
- ❑ Utilización de la implementación del API del RC para la resolución de otro tipo de problemas asociados al procesamiento de señales EEG



Bibliografía

- [1] H. Jaeger, “The” echo state” approach to analysing and training recurrent neural networks-with an erratum note,” Bonn, Germany: German National Research Center for Information Technology GMD Technical Report, vol. 148, 01 2001
- [2] G. Tanaka, T. Yamane, J.-B. Héroux, R. Nakane, N. Kanazawa, S. Takeda, and A. Hirose, “Recent advances in physical reservoir computing: A review,” *Neural Networks*, vol. 115, pp. 100–123, 201
- [3] M. Lukoševičius and H. Jaeger, “Reservoir computing approaches to recurrent neural network training,” *Computer science review*, vol. 3, no. 3, pp. 127–149, 2009.
- [4] L. Lin, C. Jin, Z. Fu, B. Zhang, G. Bin, and S. Wu, “Predicting healthy older adult’s brain age based on structural connectivity networks using artificial neural networks,” *Computer Methods and Programs in Biomedicine*, vol. 125, 12 2015
- [5] A. B. Arrieta, S. Gil-Lopez, I. L. na, M. N. Bilbao, and J. D. Ser, “On the post-hoc explainability of deep echo state networks for timeseries forecasting, image and video classification,” in *Proceedings of the International Conference on Deep Learning Applications*. Location, Country: TECNALIA, Basque Research and Technology Alliance (BRTA), University of the Basque Country (UPV/EHU), 2024
- [6] C. L. Webber Jr and J. P. Zbilut “Recurrence quantification analysis of nonlinear dynamical systems,” *Tutorials in contemporary nonlinear methods for the behavioral sciences*, vol. 94, no. 2005, pp. 26–94, 200
- [7] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Design of deep echo state networks, *Neural Networks*, Volume 108, 2018, Pages 33–47, ISSN 0893-6080, <https://doi.org/10.1016/j.neunet.2018.08.002>. (<https://www.sciencedirect.com/science/article/pii/S0893608018302223>)
- [8] Claudio Gallicchio, Alessio Micheli, Luca Pedrelli, Deep reservoir computing: A critical experimental analysis, *Neurocomputing*, Volume 268, 2017, Pages 87–99, ISSN 0925-2312, <https://doi.org/10.1016/j.neucom.2016.12.089>. (<https://www.sciencedirect.com/science/article/pii/S0925231217307567>)
- [9] Mateos Salgado, Erik & Dominguez, Benjamin. (2011). Análisis de recurrencia visual de temperatura periférica en la evaluación de un tratamiento psicológico del dolor basado en un diseño N = 1. *Psicología y Salud*. 21. 111–117.