

Modelización de patrones neuronales a partir señales EEG

José Javier Gutiérrez Gil (jogugil@alumni.uv.es, jogugil@gmail.com),

Abstract—Este estudio presenta un framework modular de Reservoir Computing (RC) diseñado para el análisis de señales de electroencefalografía (EEG), las cuales reflejan la actividad eléctrica generada por el cerebro a partir de neuronas activas, y que son registradas mediante electrodos dispuestos en el cuero cabelludo. Estas señales ofrecen una visión no invasiva del estado funcional del cerebro en tiempo real. El enfoque se centra en investigar patrones que pueden predecir el envejecimiento neuronal y sus impactos en las funciones cognitivas. A través de la aplicación de dinámicas temporales en datos reales, se exploran posibles marcadores predictivos del envejecimiento cerebral. Este enfoque destaca la eficacia de RC en la captura de dinámicas temporales complejas y subraya su potencial para avanzar en la comprensión de los procesos neurobiológicos asociados al envejecimiento. Este estudio contribuye significativamente al campo emergente de la neurociencia computacional, proporcionando nuevas herramientas para el análisis de EEG y la identificación de marcadores de envejecimiento neuronal.

Index Terms—Reservoir Computing, Electroencefalografía, Envejecimiento Neuronal, Análisis de Señales.

I. INTRODUCCIÓN

El Reservoir Computing (RC) ha emergido como una herramienta fundamental en la neurociencia computacional, especialmente en el análisis de señales complejas como las obtenidas mediante electroencefalografía (EEG). RC, incluyendo redes como Echo State Networks (ESN), se ha destacado por su capacidad única para modelar dinámicas temporales no lineales, lo cual es esencial para investigar procesos biológicos complejos como el envejecimiento neuronal y sus implicaciones en las funciones cognitivas [1].

En la última década, ha habido un notable aumento en los estudios que combinan el procesamiento de señales EEG con el avance y la mejora de técnicas de modelos de inteligencia artificial [2]. Esto ha permitido no solo capturar dinámicas temporales complejas con mayor precisión, sino también explorar nuevos métodos para analizar y predecir cambios neurofisiológicos en condiciones como el envejecimiento cerebral [3], [4].

Este estudio se enfoca en desarrollar un framework modular de RC-ESN diseñado específicamente para analizar datos EEG y explorar patrones de la dinámica temporal asociada a las señales del EEG de cada sujeto en estudio, que puedan servir como marcadores predictivos del envejecimiento cerebral. Al abordar estas cuestiones, se busca avanzar en nuestro entendimiento de los mecanismos subyacentes al envejecimiento neuronal, contribuyendo así a la neurociencia computacional

con nuevas perspectivas y aplicaciones prácticas en salud y neurología.

El desempeño de un sistema de Reservoir Computing (RC-ESN) está intrínsecamente ligado al diseño del reservorio basado en redes neuronales recurrentes (RNN). En el caso de los Echo State Networks (ESN), es esencial que el reservorio posea la propiedad de estado de eco, garantizando así la eliminación gradual de cualquier información proveniente de las condiciones iniciales. (figura 1).




Fig. 1: Estructura Base Reservoir Computing Echo State Network (fuente [5])

II. METODOLOGÍA

El framework desarrollado integra técnicas avanzadas de RC para el procesamiento de señales EEG. Así mismo, dicho framework también aporta un API que facilita la adquisición, preprocesamiento, análisis y evaluación de datos EEG, optimizado para la identificación de patrones complejos.

A. Desarrollo del Framework

El framework modular fue diseñado para ser flexible y extensible, permitiendo la incorporación de nuevos algoritmos y técnicas de análisis. La implementación del API incluye funciones para la adquisición de señales EEG, su preprocesamiento (filtrado, eliminación de artefactos), y análisis utilizando modelos de RC [6].

El API del modelo RC-ESN presente en el framework desarrollado se implementó mediante el análisis de datos sintéticos. Siendo los datos sintéticos creados mediante bandas de frecuencia concordantes con las señales EEG, a las que se le añaden procesos autorregresivos y gaussianos para acercarlos a las señales reales obtenidas mediante interfaces cerebro-maquina (BCI).

Una vez implementado el framework con el API RC-ESN, se trabajó con los datos reales que contemplan un montaje estándar ISO. Aplicando la técnica de procesamiento de un

Reservoir Computing añadiéndole componentes de fuga y ruido para estabilizar el entrenamiento del modelo (figura 2).

El modelo básico de Reservoir Computing (RC) usando Echo State Networks (ESN) se define desde las señales de entrada (EEG de cada sujeto) hasta la salida del RC-ESN como estados internos neuronales de su capa interna. Sea $\mathbf{u}(t)$ la señal de entrada (vector de características de EEG) en el tiempo t , y $\mathbf{x}(t)$ los estados internos del reservorio en el tiempo t , la formulación del RC-ESN puede expresarse como:

$$\mathbf{x}(t) = \sigma(\mathbf{W}_{in}\mathbf{u}(t) + \mathbf{W}_{res}\mathbf{x}(t-1)) \quad (1)$$

Donde: - \mathbf{W}_{in} es la matriz de pesos de entrada, - \mathbf{W}_{res} es la matriz de pesos del reservorio, - σ es la función de activación aplicada componente a componente.

Los estados internos $\mathbf{x}(t)$ representan la representación interna de las señales de EEG en el reservorio del ESN.

Para incorporar los parámetros de fuga (α) y ruido (\mathbf{W}_{noise}), la formulación del RC-ESN se ajusta de la siguiente manera:

$$\mathbf{x}(t) = (1 - \alpha)\mathbf{x}(t-1) + \sigma(\mathbf{W}_{in}\mathbf{u}(t) + \mathbf{W}_{res}\mathbf{x}(t-1)) * \mathbf{W}_{noise}(t) \quad (2)$$

Donde: - α es el parámetro de fuga que controla cuánto de los estados anteriores se conserva en $\mathbf{r}(t)$. - \mathbf{W}_{noise} es la matriz de pesos que aplica el ruido a los estados internos.

Esta formulación modificada permite que el RC-ESN tenga en cuenta la historia temporal de los estados internos mediante el parámetro de fuga α , y también incorpora ruido para mejorar la robustez y la generalización del modelo frente a variaciones en los datos de EEG.

B. Adquisición y Preprocesamiento de Datos EEG

Los datos EEG fueron adquiridos utilizando un sistema de electrodos estándar, con una frecuencia de muestreo de 512 Hz. El preprocesamiento de las señales incluyó la eliminación de ruido y artefactos mediante técnicas de filtrado digital, y la correlación con canales de eventos de movimiento ocular y muscular. Así como la detección de amplitudes extremas en la respuestas de las señales del EEG.

C. Análisis de Dinámicas Temporales

Para analizar las dinámicas temporales en los datos EEG, se utilizó el modelo de RC-ESN. Este modelo fue entrenado utilizando dichas señales EEG de sujetos jóvenes y mayores. Y se evaluó su capacidad para identificar patrones característicos del envejecimiento neuronal en los dos grupos de datos.

Después de obtener los transitorios de los estados internos $\mathbf{r}(t)$ utilizando la ecuación 2, estos pueden ser procesados de diferentes maneras para extraer información relevante de la dinámica temporal.

Las conexiones recurrentes permiten que el reservorio mantenga una memoria a corto plazo de las entradas pasadas, lo cual es crucial para capturar la dinámica temporal de las señales EEG. Las conexiones de retroalimentación en esta capa




Fig. 2: Procesado señales EEG mediante Reservoir Computing Echo State Network (fuente [7]).

permiten que las salidas anteriores del modelo se retroalimentan como entradas adicionales al reservorio, mejorando la modelización de la dinámica temporal.

Para la evaluación de los resultados obtenidos mediante el RC-ESN se usan las gráficas de recurrencia [8], [9], [10] y el potencial de memoria [8], [11], [12], [13].

Una gráfica recurrente es una representación bidimensional que muestra los momentos en los que un sistema dinámico retorna a estados similares. Se basa en el concepto de "recurrencia", que es la tendencia de los sistemas dinámicos a visitar los mismos estados o estados similares a lo largo del tiempo.

Para una serie temporal $(\{x_i\}_{i=1}^N)$, la gráfica recurrente se define como una matriz (R) donde cada elemento $(R_{i,j})$ se determina de la siguiente manera:

$$R_{i,j} = \Theta(\epsilon - \|\mathbf{x}_i - \mathbf{x}_j\|), \quad (3)$$

Aquí:

- \mathbf{x}_i y \mathbf{x}_j son los puntos en el espacio de fases (generalmente reconstruido mediante el método de retardos).
- $\|\cdot\|$ es una norma (comúnmente la norma euclidiana).
- ϵ es un umbral de recurrencia.
- Θ es la función escalón de Heaviside, que es 1 si el argumento es positivo y 0 en caso contrario.

Mientras que el potencial de memoria se define como el instante de tiempo t en el cual la distancia euclidiana entre el estado inicial y_0 y el estado y_t de la serie temporal cae por debajo de un umbral de tolerancia ϵ :

$$t = \min \{t \in \mathbb{N} \mid \|y_t - y_0\| < \epsilon\} \quad (4)$$

Donde:

- y_0 es el estado inicial de la serie temporal.
- y_t es el estado en el tiempo t .
- ϵ es el umbral de tolerancia para considerar la repetición del patrón.

III. RESULTADOS

Los resultados obtenidos al aplicar el framework a datos reales muestran patrones característicos en diferentes grupos etarios. Los análisis de dinámicas temporales revelaron diferencias significativas en la actividad neuronal entre sujetos jóvenes, adultos y mayores.

El modelo RC-ESN demostró una alta precisión en la clasificación de las señales EEG según el grupo etario, sugiriendo que estos patrones pueden servir como marcadores predictivos del envejecimiento neuronal. En las figuras 3, 4 y 5 se presentan ejemplos de los resultados obtenidos. Así mismo, en las figuras 6 y 7 vemos los estudios de las gráficas de recurrencia y potencial de memoria, asociados a la coherencia y plasticidad cerebral de los sujetos.




Fig. 3: Matriz similitud de los estados internos del modelo RC-ESN tras procesar las señales EEG de los sujetos en estudio




Fig. 4: Matriz de confusión del agrupamiento en dos clústers de los patrones de las dinámicas internas asociadas a los estados del RC-ESN tras procesar las señales EEG de los sujetos de estudio

Classification Report Accuracy: 0.74				
Class	f1-score	precision	recall	support
0	0.76	0.70	0.83	23.00
1	0.73	0.80	0.67	24.00
weighted avg	0.74	0.75	0.75	47.00
macro avg	0.74	0.75	0.74	47.00

Fig. 5: Métricas del agrupamiento en dos clústers de los patrones de las dinámicas internas asociadas a los estados del RC-ESN tras procesar las señales EEG de los sujetos de estudio

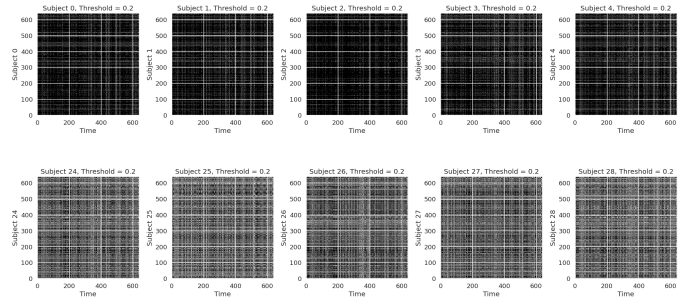


Fig. 6: Gráficas de recurrencia de las dinámicas temporales asociadas a los estados internos del RC-ESN tras procesar las señales EEG de los sujetos de estudio

IV. DISCUSIÓN

Los hallazgos sugieren que el framework desarrollado es efectivo para identificar patrones en señales EEG relacionados con el envejecimiento neuronal.

La matriz de similitud (figura 3) revela dos agrupamientos distintos a lo largo de la diagonal, separando claramente a los sujetos jóvenes adultos de los mayores. Esto sugiere que el modelo RC-ESN es efectivo para distinguir las dinámicas temporales únicas entre estos grupos de edad. Además, dentro del grupo de jóvenes adultos, se observan variaciones sutiles que podrían reflejar diferencias individuales en las señales EEG, posiblemente relacionadas con la plasticidad neuronal más pronunciada en este grupo. La homogeneidad observada en los clústers de sujetos mayores en la matriz de similitud sugiere una actividad cerebral más estable y uniforme en comparación con los jóvenes adultos, lo cual puede atribuirse a la disminución de la plasticidad neuronal con la edad, resultando en patrones de señales EEG más consistentes entre los individuos mayores.

En conjunto, estos resultados subrayan la capacidad del modelo RC-ESN para capturar y diferenciar las características temporales complejas de las señales EEG en función de la edad. La mayor heterogeneidad en los jóvenes adultos podría indicar una adaptabilidad neuronal más alta, mientras que la homogeneidad en los mayores podría reflejar una menor



Fig. 7: Potencial de memoria de los jóvenes adultos vs mayores, y un t-test sobre la significancia estadística de la diferencia entre ambos grupos.

capacidad de cambio neuronal. Estos insights son fundamentales para comprender cómo evolucionan las señales EEG a lo largo de la vida y para investigar posibles implicaciones en el envejecimiento y la plasticidad cerebral.

Estos hallazgos se refutan con los resultados obtenidos en las gráficas de recurrencia y potencial de memoria:

- Las gráficas de recurrencia (figura 6) indican una mayor coherencia en los patrones de actividad neuronal de los jóvenes en comparación con los mayores. Esto sugiere que los jóvenes tienen una mejor sincronización y coordinación entre diferentes regiones cerebrales. Una mayor coherencia podría estar relacionada con una mejor capacidad de procesamiento de información y comunicación eficiente entre neuronas. La disminución de coherencia en los mayores podría reflejar un deterioro en las redes neuronales debido al envejecimiento.

- La disminución de coherencia en los mayores observada

en las gráficas de recurrencia podría ser un indicador de envejecimiento cerebral. El envejecimiento cerebral puede estar asociado con una reducción en la sincronización de la actividad neuronal, lo que podría afectar negativamente funciones cognitivas como la memoria, la atención y el procesamiento de información. Estas observaciones pueden tener implicaciones para el desarrollo de intervenciones dirigidas a mantener o mejorar la coherencia neuronal en la vejez.

- Los potenciales de memoria (figura 7) indican una mayor plasticidad cerebral en los jóvenes en comparación con los mayores. Además, el valor del t-test menor a 0,05 indica que existe una diferencia estadísticamente significativa entre las medias de los valores del potencial de memoria de ambos grupos. La plasticidad cerebral se refiere a la capacidad del cerebro para adaptarse y reorganizarse en respuesta a nuevas experiencias. Los jóvenes, al mostrar mayor plasticidad, podrían tener una mayor capacidad para aprender y adaptarse a nuevas situaciones. En contraste, la menor plasticidad en los mayores puede estar asociada con una menor capacidad de adaptación y aprendizaje.

- Los cambios observados en los potenciales de memoria (figura 7) pueden ser utilizados como biomarcadores para evaluar la plasticidad cerebral. La reducción de la plasticidad en los mayores puede tener implicaciones para el diseño de programas de entrenamiento cognitivo y terapias destinadas a mejorar la plasticidad cerebral y, por ende, la función cognitiva en la vejez.

- La mayor coherencia y plasticidad en los jóvenes sugiere una interacción positiva entre estos dos aspectos del funcionamiento cerebral, donde una mayor coherencia facilita la plasticidad y viceversa. Este equilibrio contribuye a un cerebro más eficiente y adaptable en los jóvenes. En contraste, la disminución de ambos factores en los adultos mayores puede indicar un círculo vicioso: una reducción en la coherencia puede limitar la plasticidad y, a su vez, la capacidad de adaptación. Estas diferencias resaltan la importancia de evaluar cómo coherencia y plasticidad interactúan a lo largo del ciclo vital, lo cual es crucial para desarrollar intervenciones que mejoren la calidad de vida en la vejez. Realizar estudios longitudinales permitirá desentrañar estas relaciones y identificar momentos críticos para aplicar intervenciones más efectivas.

Además, el uso de modelos de RC permite un análisis más detallado y preciso de las señales EEG, lo que podría contribuir a mejorar la comprensión de los mecanismos subyacentes al envejecimiento neuronal y las funciones cognitivas.

V. CONCLUSIÓN

En línea con los resultados obtenidos, podemos ratificar su capacidad para captar las dinámicas temporales de la actividad neuronal proporcionando herramientas avanzadas para investigar y comprender mejor los mecanismos subyacentes al envejecimiento neuronal. Siendo una herramienta valiosa para la investigación neurocientífica.

Las diferencias observadas en las dinámicas temporales, así como la mayor capacidad de un cerebro joven para mantener sincronizadas y en interacción eficaz a las regiones cerebrales, y su superior capacidad de regeneración y creación de redes

neuronales para la resolución de nuevas situaciones frente a los sujetos mayores, refuerzan la fortaleza de estos modelos y verifican las hipótesis neurocientíficas establecidas en las últimas décadas. Esto puede proporcionar información valiosa para la detección temprana de alteraciones cognitivas. Futuras investigaciones podrían enfocarse en la mejora del framework y su aplicación en otros contextos de análisis de señales neurofisiológicas.

A lo largo del trabajo, se han fortalecido las hipótesis y estudios propuestos por la neurociencia, desentrañando cómo el cerebro interactúa en las diferentes áreas y cómo el envejecimiento afecta la funcionalidad cognitiva. En este sentido, se ha detectado una menor plasticidad y actividad neuronal, así como una disminución de la funcionalidad cognitiva a medida que los sujetos envejecen. Estas conclusiones se ratifican con las diferencias observadas en el potencial de memoria, donde dicho potencial es más homogéneo en los sujetos mayores y más variable en los jóvenes. Es importante recordar que un potencial de memoria homogéneo en los mayores indica una reducción en la flexibilidad cognitiva, mientras que la variabilidad en los jóvenes refleja una mayor capacidad de adaptación y aprendizaje.

AGRADECIMIENTOS

Agradecemos sinceramente el apoyo proporcionado por los miembros del equipo de investigación, así como al Departamento de Electrónica de la Escuela Superior de Ingeniería de la Universidad de Valencia. Su colaboración y asistencia han sido fundamentales para la ejecución y realización de este estudio.

REFERENCES

- [1] H. Jaeger, "The "echo state" approach to analysing and training recurrent neural networks-with an erratum note'," *Bonn, Germany: German National Research Center for Information Technology GMD Technical Report*, vol. 148, 01 2001.
- [2] G. Tanaka, T. Yamane, J.-B. Héroux, R. Nakane, N. Kanazawa, S. Takeda, and A. Hirose, "Recent advances in physical reservoir computing: A review," *Neural Networks*, vol. 115, pp. 100–123, 2019.
- [3] M. Lukoševičius and H. Jaeger, "Reservoir computing approaches to recurrent neural network training," *Computer science review*, vol. 3, no. 3, pp. 127–149, 2009.
- [4] L. Lin, C. Jin, Z. Fu, B. Zhang, G. Bin, and S. Wu, "Predicting healthy older adult's brain age based on structural connectivity networks using artificial neural networks," *Computer Methods and Programs in Biomedicine*, vol. 125, 12 2015.
- [5] Y. Sakemi, K. Morino, T. Leleu *et al.*, "Model-size reduction for reservoir computing by concatenating internal states through time," *Scientific Reports*, vol. 10, p. 21794, 2020.
- [6] Jogugil, "MyRC: Página web del proyecto," <https://github.com/jogugil/MyRC>, accedido el 12 de julio de 2024.
- [7] Q. An, K. Bai, L. Liu, F. Shen, and Y. Yi, "A unified information perceptron using deep reservoir computing," *Computers & Electrical Engineering*, vol. 85, p. 106705, 2020.
- [8] A. B. Arrieta, S. Gil-Lopez, I. L. na, M. N. Bilbao, and J. D. Ser, "On the post-hoc explainability of deep echo state networks for time series forecasting, image and video classification," in *Proceedings of the International Conference on Deep Learning Applications*. Location, Country: TECNALIA, Basque Research and Technology Alliance (BRTA), University of the Basque Country (UPV/EHU), 2024, manuscript submitted for publication.
- [9] C. L. Webber Jr and J. P. Zbilut, "Recurrence quantification analysis of nonlinear dynamical systems," *Tutorials in contemporary nonlinear methods for the behavioral sciences*, vol. 94, no. 2005, pp. 26–94, 2005.
- [10] N. Marwan and K. H. Kraemer, "Trends in recurrence analysis of dynamical systems," *The European Physical Journal Special Topics*, vol. 232, no. 1, pp. 5–27, 2023.
- [11] A. M. Fraser and H. L. Swinney, "Independent coordinates for strange attractors from mutual information," *Physical Review A*, vol. 33, no. 2, pp. 1134–1140, 1986.
- [12] H. Jaeger, "Tutorial on training recurrent neural networks, covering bppt, rtll, ekf and the "echo state network" approach," *GMD-Forschungszentrum Informationstechnik*, 2002.
- [13] W. Maass, T. Natschläger, and H. Markram, "Real-time computing without stable states: A new framework for neural computation based on perturbations," *Neural computation*, vol. 14, no. 11, pp. 2531–2560, 2002.